

Prédisez la consommation d'énergie des bâtiments dans la ville de Seattle.

Rafael CEREZO MARTIN

Décembre 2025

Objetifs du projet

Prédire la consommation d'énergie et les émissions de CO2 des bâtiments non-résidentiels pour optimiser les politiques publiques sans relevés coûteux.

Côté Administratif (Mairie de Seattle)

- **Aide à la Décision :** Cibler les quartiers et types de bâtiments prioritaires pour les rénovations.
- **Transparence et Reporting :** Fournir des tableaux de bord sur l'empreinte carbone actuelle et projetée.
- **Optimisation des Ressources :** Remplacer les relevés manuels coûteux par une solution prédictive instantanée.
- **Vision Stratégique :** Assurer la continuité du projet avec une visibilité totale sur les indicateurs de réussite.

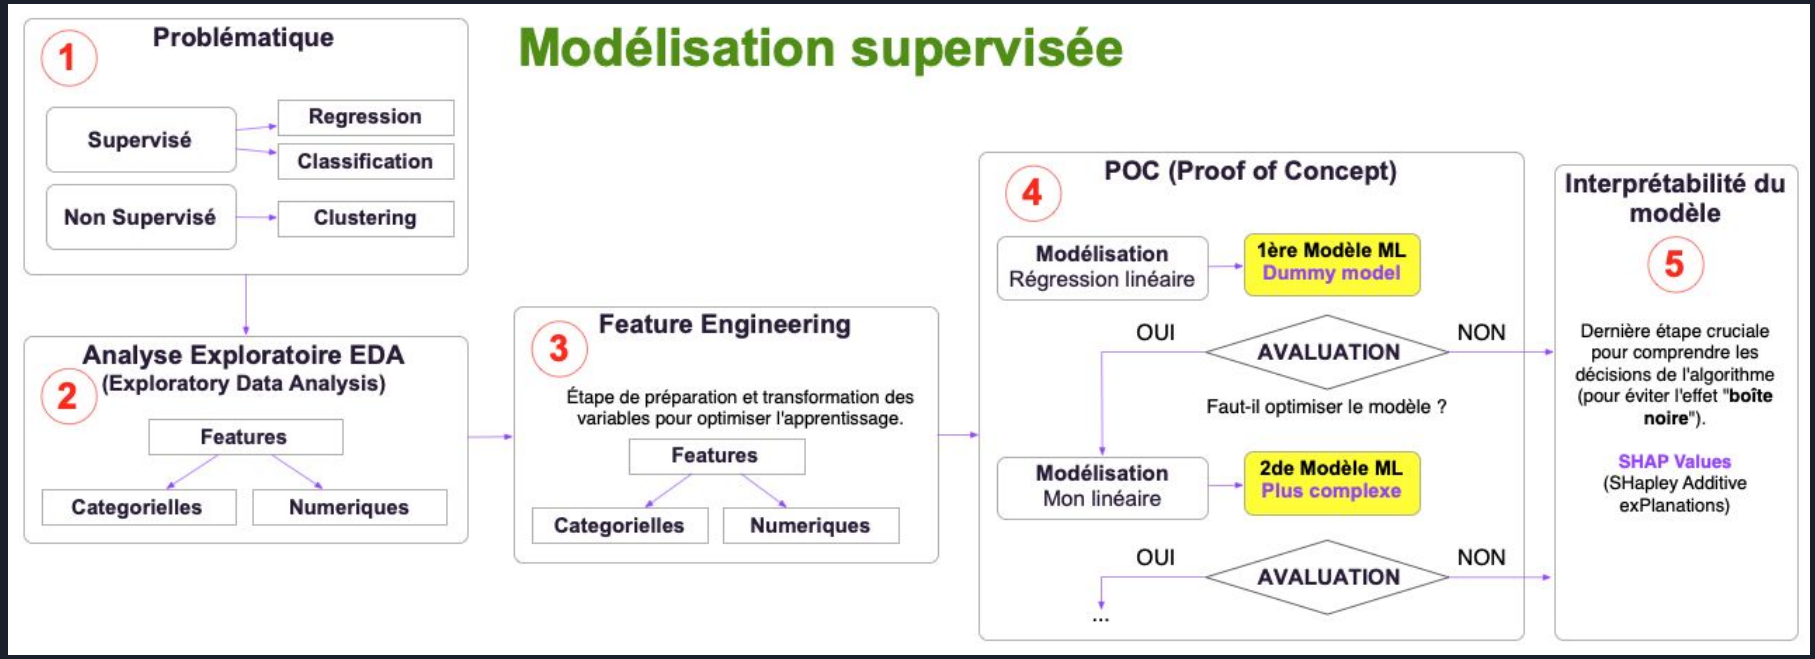
Côté Technique (Équipe Data Science)

- **Feature Engineering :** Transformer les données brutes en variables structurantes et éliminer les redondances.
- **Architecture Modèle :** Optimiser les algorithmes supervisés en minimisant l'erreur de prédiction (RMSE).
- **Interprétation:** Construire un pipeline robuste, interprétable et performant.
- **Contrôle du Surapprentissage :** Maintenir l'Overfit Gap sous 0.10 pour garantir la fiabilité des résultats.
- **Analyse de Sensibilité :** Isoler les facteurs d'influence réels pour valider la pertinence physique du modèle.

Côté Apprentissage et Didactique

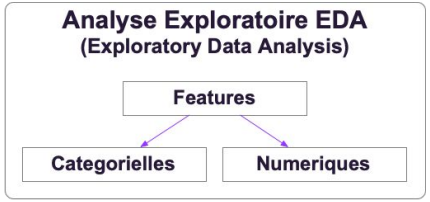
- **Maîtriser le cycle de vie d'un projet de machine learning réel, de la donnée “sale” au modèle interprétable.**
- **Transformer une question politique en un problème mathématique**
- **Rigueur Méthodologique :** Diagnostiquer la santé d'un modèle via le compromis biais-variance pour éviter de croire qu'un score élevé est synonyme de succès.
- **Esprit Critique:** pour ne jamais traiter le modèle comme une boîte noire magique.
- **Communication Technique :** Vulgariser des concepts complexes (RMSE, Hyperparamètres) pour convaincre des décideurs non techniques

Etapes du Projet



1 Analyse Exploratoire

1. Configuration et première inspection
   - 1.1 Chargement et premier aperçu des données.
   - 1.2 Analyse des features pertinentes (IDs, target, domaine...)
   - 1.3 Classification des features prédictives.
2. Analyse de la qualité des données
   - 2.1 Audit des valeurs manquantes et des types de données.
   - 2.2 Vérification de la cohérence (doublons, erreurs de saisie).
3. Détection et caractérisation des outliers
   - 3.1 Analyse de la colonne "outlier" existante (expertise Seattle).
   - 3.2 Identification statistique des valeurs extrêmes (IQR / Z-score).
4. Analyse univariée - variables numériques
   - 4.1 Statistiques descriptives (moyenne, médiane, écart-type).
   - 4.2 Visualisation des distributions et de l'asymétrie (skewness).
5. Analyse multivariée et corrélations
   - 5.1 Matrice de corrélation (heatmap des variables numériques).
   - 5.2 Pairplot des variables énergétiques (relations directes).
   - 5.3 Analyse de la redondance (identification des corrélations > 0.90).
6. Analyse par segments et contexte (domain considerations)
   - 6.1 Analyse de la cible par type d'usage ou quartier.
   - 6.2 Influence de l'année de construction sur l'efficacité.
7. Synthèse et recommandations pré-engineering
   - 7.1 Choix final des variables et stratégies de transformation.



	OSEBuildingID	DataYear	BuildingType	PrimaryPropertyType	PropertyName	Address	City	State	ZipCode	TaxParcelIdentificationNumber
0	1	2016	NonResidential	Hotel	Mayflower park hotel	405 Olive way	Seattle	WA	98101.0	0659000030
1	2	2016	NonResidential	Hotel	Paramount Hotel	724 Pine street	Seattle	WA	98101.0	0659000220
2	3	2016	NonResidential	Hotel	5673-The Westin Seattle	1900 5th Avenue	Seattle	WA	98101.0	0659000475
3	5	2016	NonResidential	Hotel	HOTEL MAX	620 STEWART ST	Seattle	WA	98101.0	0659000640
4	8	2016	NonResidential	Hotel	WARWICK SEATTLE HOTEL (ID8)	401 LENORA ST	Seattle	WA	98121.0	0659000970

ydata-profiling

Dataset statistics

Number of variables	46
Number of observations	3376
Missing cells	19952
Missing cells (%)	12.8%
Duplicate rows	0
Duplicate rows (%)	0.0%
Total size in memory	1.2 MiB
Average record size in memory	361.0 B

Variable types

Numeric	29
Categorical	10
Text	5
Boolean	1
Unsupported	1

```
================================================================================
  Source du fichier.....: 2016_Building_Energy_Benchmarking.csv
  Dimensions brutes.....: 3376 lignes | 46 colonnes
  Taille en mémoire.....: 3.47 MB
  Statut................: ✅ Données chargées dans 'dataset_raw'
================================================================================
```

1 Analyse Exploratoire

1. Configuration et première inspection
   - 1.1 Chargement et premier aperçu des données.
   - 1.2 Analyse des features pertinentes (IDs, target, domaine...)
   - 1.3 Classification des features prédictives.
2. **Analyse de la qualité des données**
   - **2.1 Audit des valeurs manquantes et des types de données.**
   - **2.2 Vérification de la cohérence (doublons, erreurs de saisie).**
3. Détection et caractérisation des outliers
   - 3.1 Analyse de la colonne "outlier" existante (expertise Seattle).
   - 3.2 Identification statistique des valeurs extrêmes (IQR / Z-score).
4. Analyse univariée - variables numériques
   - 4.1 Statistiques descriptives (moyenne, médiane, écart-type).
   - 4.2 Visualisation des distributions et de l'asymétrie (skewness).
5. Analyse multivariée et corrélations
   - 5.1 Matrice de corrélation (heatmap des variables numériques).
   - 5.2 Pairplot des variables énergétiques (relations directes).
   - 5.3 Analyse de la redondance (identification des corrélations > 0.90).
6. Analyse par segments et contexte (domain considerations)
   - 6.1 Analyse de la cible par type d'usage ou quartier.
   - 6.2 Influence de l'année de construction sur l'efficacité.
7. Synthèse et recommandations pré-engineering
   - 7.1 Choix final des variables et stratégies de transformation.

Identification des Colonnes Constantes

`DataYear` has constant value "2016"	Constant
`City` has constant value "Seattle"	Constant
`State` has constant value "WA"	Constant

Cartographie des Valeurs Manquantes

`SecondLargestPropertyUseType` has 1697 (50.3%) missing values	Missing
`SecondLargestPropertyUseTypeGFA` has 1697 (50.3%) missing values	Missing
`ThirdLargestPropertyUseType` has 2780 (82.3%) missing values	Missing
`ThirdLargestPropertyUseTypeGFA` has 2780 (82.3%) missing values	Missing
`YearsENERGYSTARCertified` has 3257 (96.5%) missing values	Missing
`ENERGYSTARScore` has 843 (25.0%) missing values	Missing
`Comments` has 3376 (100.0%) missing values	Missing
`Outlier` has 3344 (99.1%) missing values	Missing
`OSEBuildingID` has unique values	Unique
`Comments` is an unsupported type, check if it needs cleaning or further analysis	Unsupported

Custom Exploration Functions

Column	N_Unique	Missing_Pct	Dtype	Var_Norm	Dominant_Pct	Is_Constant	Is_Quasi
DataYear	1	0	int64	0	100	True	False
City	1	0	object	nan	100	True	False
State	1	0	object	nan	100	True	False
Comments	1	100	float64	nan	100	True	False
DefaultData	2	0	bool	4.23855	94.7242	False	False
Outlier	3	98.9808	object	nan	98.9808	False	False
ComplianceStatus	4	0	object	nan	92.8058	False	False
BuildingType	5	0	object	nan	87.53	False	False
CouncilDistrictCode	7	0	int64	0.502913	31.7146	False	False
NumberofBuildings	17	0.119904	float64	2.50833	93.5851	False	False

Column	Raison_Principale	Dtype	Impact_Potentiel
City	Constante (Unique)	object	Perte d'information nulle
Comments	Manquants > 95% & Constante (Unique)	float64	Perte d'information nulle
DataYear	Constante (Unique)	int64	Perte d'information nulle
Outlier	Manquants > 95%	object	Perte d'information nulle
State	Constante (Unique)	object	Perte d'information nulle

1 Analyse Exploratoire

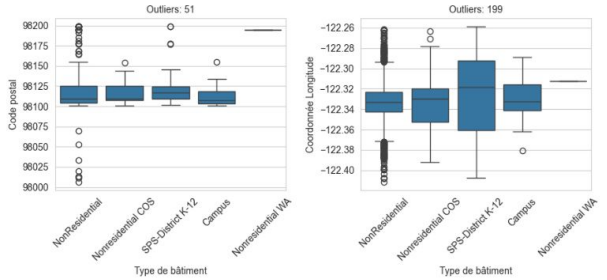
1. Configuration et première inspection
   - 1.1 Chargement et premier aperçu des données.
   - 1.2 Analyse des features pertinentes (IDs, target, domaine...)
   - 1.3 Classification des features prédictives.
2. Analyse de la qualité des données
   - 2.1 Audit des valeurs manquantes et des types de données.
   - 2.2 Vérification de la cohérence (doublons, erreurs de saisie).
3. **Détection et caractérisation des outliers**
   - **3.1 Analyse de la colonne "outlier" existante (expertise Seattle).**
   - **3.2 Identification statistique des valeurs extrêmes (IQR / Z-score).**
4. Analyse univariée - variables numériques
   - 4.1 Statistiques descriptives (moyenne, médiane, écart-type).
   - 4.2 Visualisation des distributions et de l'asymétrie (skewness).
5. Analyse multivariée et corrélations
   - 5.1 Matrice de corrélation (heatmap des variables numériques).
   - 5.2 Pairplot des variables énergétiques (relations directes).
   - 5.3 Analyse de la redondance (identification des corrélations > 0.90).
6. Analyse par segments et contexte (domain considerations)
   - 6.1 Analyse de la cible par type d'usage ou quartier.
   - 6.2 Influence de l'année de construction sur l'efficacité.
7. Synthèse et recommandations pré-engineering
   - 7.1 Choix final des variables et stratégies de transformation.

Outliers Numeriques

```
🚩 ANALYSE DES OUTLIERS STATISTIQUES (IQR) : 23
 - ZipCode.............................: 51 bâtiments hors bornes (98075.0, 98155.0)
 - Longitude...........................: 199 bâtiments hors bornes (-122.38, -122.29)
 - NumberofBuildings...................: 105 bâtiments hors bornes (1.0, 1.0)
 - NumberofFloors......................: 138 bâtiments hors bornes (-3.5, 8.5)
 - PropertyGFATotal....................: 203 bâtiments hors bornes (-84293.12, 219095.88)
 - PropertyGFAParking..................: 333 bâtiments hors bornes (0.0, 0.0)
 - PropertyGFABuilding(s)..............: 181 bâtiments hors bornes (-70951.5, 194186.5)
 - LargestPropertyUseTypeGFA...........: 173 bâtiments hors bornes (-74156.88, 191668.12)
 - SecondLargestPropertyUseTypeGFA....: 120 bâtiments hors bornes (-34446.5, 71677.5)
```

Outliers Catégorieles

```
🚩 ANOMALIES DE CATÉGORIES (FRÉQUENCES FAIBLES) : 13
 - BuildingType.......................: 1 catégories trouvées
   Aperçu (top 10) : {'Nonresidential WA': 1}
--------------------------------------------------------------------------------
 - PrimaryPropertyType................: 6 catégories trouvées
   Aperçu (top 10) : {'Restaurant': 12, 'Refrigerated Warehouse': 12, 'Hospital': 10, 'Laboratory': 10, 'Low-Rise
Multifamily': 3, 'Office': 3}
--------------------------------------------------------------------------------
 - PropertyName.......................: 1664 catégories trouvées
   Aperçu (top 10) : {'Canal Building': 2, 'South Park': 2, 'Bayview Building': 2, 'Airport Way': 2, 'Fire Station 35 (New)':
1, 'Fire Station 39 (New)': 1, 'Ballard Community Center': 1, 'Ballard Pool': 1, 'Central West HQ / Brown Bear': 1,
'Conservatory Campus': 1}...
```




```python
# --- 1. SCAN NUMÉRIQUE (Méthode de l'Écart Interquartile - IQR)
 for col in numeric_cols:
    if is_polars:
        # Syntax Polars
        q1 = df.select(pl.col(col).quantile(0.25)).item()
        q3 = df.select(pl.col(col).quantile(0.75)).item()
        iqr = q3 - q1
         lower, upper = q1 - 1.5 * iqr, q3 + 1.5 * iqr
```

```python
# --- 2. SCAN QUALITATIF (Détection des catégories rares) ---
for col in categorical_cols:
    if is_polars:
        comptage = df.group_by(col).agg(pl.count().alias("n"))
        rares = comptage.filter(pl.col("n") < (total_lignes * threshold_freq))
        valeurs = rares.select(col).to_series().to_list()
        freqs = rares.select("n").to_series().to_list()
    else:
        counts  = df[col].value_counts()
        rares   = counts[counts < (total_lignes * threshold_freq)]
        valeurs = rares.index.tolist()
        freqs   = rares.values.tolist()
```

1 Analyse Exploratoire

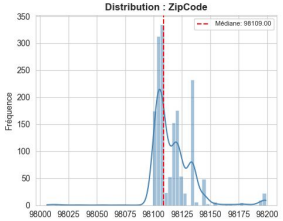
1. Configuration et première inspection
   - 1.1 Chargement et premier aperçu des données.
   - 1.2 Analyse des features pertinentes (IDs, target, domaine...)
   - 1.3 Classification des features prédictives.
2. Analyse de la qualité des données
   - 2.1 Audit des valeurs manquantes et des types de données.
   - 2.2 Vérification de la cohérence (doublons, erreurs de saisie).
3. Détection et caractérisation des outliers
   - 3.1 Analyse de la colonne "outlier" existante (expertise Seattle).
   - 3.2 Identification statistique des valeurs extrêmes (IQR / Z-score).
4. **Analyse univariée - variables numériques**
   - **4.1 Statistiques descriptives (moyenne, médiane, écart-type).**
   - **4.2 Visualisation des distributions et de l'asymétrie (skewness).**
5. Analyse multivariée et corrélations
   - 5.1 Matrice de corrélation (heatmap des variables numériques).
   - 5.2 Pairplot des variables énergétiques (relations directes).
   - 5.3 Analyse de la redondance (identification des corrélations > 0.90).
6. Analyse par segments et contexte (domain considerations)
   - 6.1 Analyse de la cible par type d'usage ou quartier.
   - 6.2 Influence de l'année de construction sur l'efficacité.
7. Synthèse et recommandations pré-engineering
   - 7.1 Choix final des variables et stratégies de transformation.

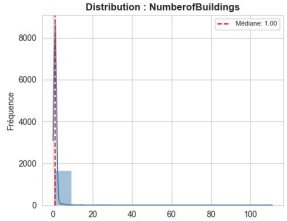
ANALYSE STATISTIQUE ET DIAGNOSTIC DES ÉCHELLES

```
Variables numériques analysées.......: 30
Variables à échelles critiques.......: 14
Variables fortement asymétriques.....: 22

⚠️ ALERTE ÉCHELLES :
   - DataYear                    : Moyenne = 2.02e+03
   - CouncilDistrictCode         : Moyenne = 4.36e+00
   - Latitude                    : Moyenne = 4.76e+01
   - Longitude                   : Moyenne = -1.22e+02
   - YearBuilt                   : Moyenne = 1.96e+03

📊 ALERTE ASYMÉTRIE :
   - ZipCode                     : Skewness = 1.31
   - NumberofBuildings           : Skewness = 32.48
   - NumberofFloors              : Skewness = 6.04
   - PropertyGFATotal            : Skewness = 19.16
   - PropertyGFAParking          : Skewness = 5.22
```






```
================================================================================
ÉTAPE 3.5 : INTERPRÉTATION AUTOMATIQUE DU DATASET
================================================================================
```

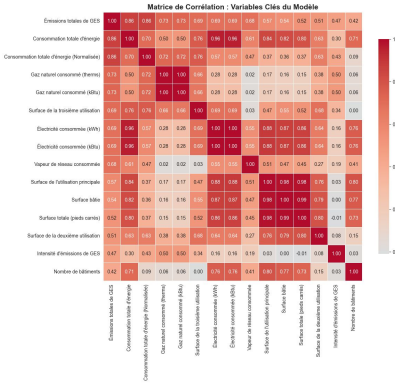
Variable	Asymétrie	Type_Queues	Outliers_IQR	Action_Data
OSEBuildingID	Symétrique (Normale)	Queues normales	Aucun	Standardize
DataYear	Symétrique (Normale)	Queues normales	Aucun	Standardize
ZipCode	Asymétrie Positive (1.3)	Queues lourdes (Outliers probables)	Modérée (3.1%)	Standardize
CouncilDistrictCode	Symétrique (Normale)	Distribution plate (Uniforme)	Aucun	Standardize
Latitude	Symétrique (Normale)	Queues normales	Aucun	Standardize
Longitude	Symétrique (Normale)	Queues normales	Critique (11.9%)	Log + Robust Scaling

1 Analyse Exploratoire

1. Configuration et première inspection
   - 1.1 Chargement et premier aperçu des données.
   - 1.2 Analyse des features pertinentes (IDs, target, domaine...)
   - 1.3 Classification des features prédictives.
2. Analyse de la qualité des données
   - 2.1 Audit des valeurs manquantes et des types de données.
   - 2.2 Vérification de la cohérence (doublons, erreurs de saisie).
3. Détection et caractérisation des outliers
   - 3.1 Analyse de la colonne "outlier" existante (expertise Seattle).
   - 3.2 Identification statistique des valeurs extrêmes (IQR / Z-score).
4. Analyse univariée - variables numériques
   - 4.1 Statistiques descriptives (moyenne, médiane, écart-type).
   - 4.2 Visualisation des distributions et de l'asymétrie (skewness).
5. **Analyse multivariée et corrélations**
   - **5.1 Matrice de corrélation (heatmap des variables numériques).**
   - **5.2 Pairplot des variables énergétiques (relations directes).**
   - **5.3 Analyse de la redondance (identification des corrélations > 0.90).**
6. Analyse par segments et contexte (domain considerations)
   - 6.1 Analyse de la cible par type d'usage ou quartier.
   - 6.2 Influence de l'année de construction sur l'efficacité.
7. Synthèse et recommandations pré-engineering
   - 7.1 Choix final des variables et stratégies de transformation.

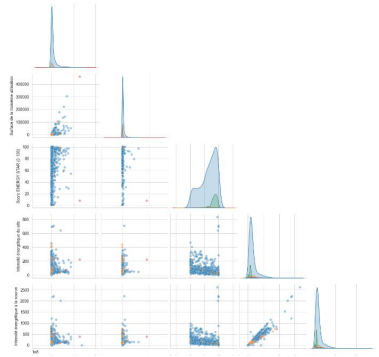
Matrice de Corrélation (Heatmap des variables numériques pertinentes)

Sélection automatique des variables corrélées à plus de 40% (0.4) avec la cible
Cela nous permet de voir ce qui influence réellement la consommation.



Pairplot des variables énergétiques (relations directes)

Diagonale (KDE): la distribution (concentration) de chaque fluide énergétique ;
on y voit que la plupart des bâtiments ont une consommation faible, avec quelques valeurs extrêmes (pics).
Nuages de points (Scatter): Relations entre variables.
Par exemple, une ligne droite indique une corrélation parfaite entre deux intensités énergétiques.



Analyse de la redondance

Identification des corrélations > 0.90

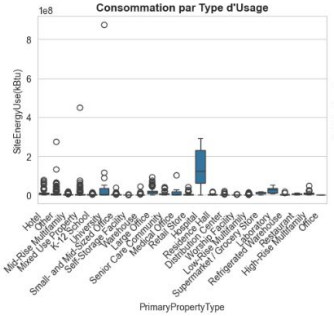
```
================================================================================
🚩 IDENTIFICACIÓN DE REDUNDANCIAS (Correlación > 0.90):
--------------------------------------------------------------------
⚠️ Surface totale (pieds carrés) (PropertyGFATotal)  <--->  Surface bâtie (PropertyGFABuilding(s))
   Indice de corrélation : 0.9905
--------------------------------------------------------------------
⚠️ Surface totale (pieds carrés) (PropertyGFATotal)  <--->  Surface de l'utilisation principale
(LargestPropertyUseTypeGFA)
   Indice de corrélation : 0.9776
```

1 Analyse Exploratoire

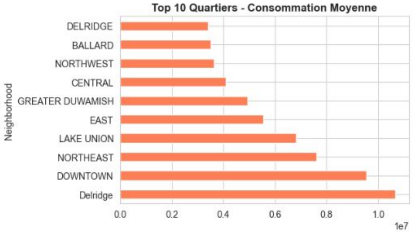
1. Configuration et première inspection
   - 1.1 Chargement et premier aperçu des données.
   - 1.2 Analyse des features pertinentes (IDs, target, domaine...)
   - 1.3 Classification des features prédictives.
2. Analyse de la qualité des données
   - 2.1 Audit des valeurs manquantes et des types de données.
   - 2.2 Vérification de la cohérence (doublons, erreurs de saisie).
3. Détection et caractérisation des outliers
   - 3.1 Analyse de la colonne "outlier" existante (expertise Seattle).
   - 3.2 Identification statistique des valeurs extrêmes (IQR / Z-score).
4. Analyse univariée - variables numériques
   - 4.1 Statistiques descriptives (moyenne, médiane, écart-type).
   - 4.2 Visualisation des distributions et de l'asymétrie (skewness).
5. Analyse multivariée et corrélations
   - 5.1 Matrice de corrélation (heatmap des variables numériques).
   - 5.2 Pairplot des variables énergétiques (relations directes).
   - 5.3 Analyse de la redondance (identification des corrélations > 0.90).
6. **Analyse par segments et contexte (domain considerations)**
   - **6.1 Analyse de la cible par type d'usage ou quartier.**
   - **6.2 Influence de l'année de construction sur l'efficacité.**
7. Synthèse et recommandations pré-engineering
   - 7.1 Choix final des variables et stratégies de transformation.

Analyse par segments et contexte

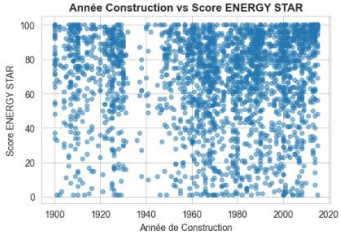
TYPE D'USAGE



QUARTIER



ÂGE CONSTRUCTION



Segment d'Usage
Identifie les "gros consommateurs" par usage (ex: Hôpitaux/Hôtels) et révèle de nombreux bâtiments atypiques (outliers) avec des pics de consommation extrêmes.

Géographie & Quartier
Classe les quartiers par intensité énergétique ; le secteur Downtown domine nettement, confirmant une concentration géographique du besoin énergétique.

Âge du Bâtiment
Bâtiments post-2000 : -30% de consommation.
Avant 1980 : Performance critique avec un Score Energy Star < 50.

```
# 6.1 Consommation par Type d'Usage
sns.boxplot(
    data=building_consumption,
    x='PrimaryPropertyType',
    y='SiteEnergyUse(kBtu)',
    ax=axes[0]
)
```

```
# 6.2 Consommation moyenne par Quartier (Top 10)
top_neighborhoods = (building_consumption

.groupby('Neighborhood')['SiteEnergyUse(kBtu)']
                    .mean()
                    .sort_values(ascending=False)
                    .head(10))
top_neighborhoods.plot(kind='barh', ax=axes[1], color='coral')
```

```
# 6.3 Année de Construction vs Efficacité
axes[2].scatter(
    building_consumption['YearBuilt'],
    building_consumption['ENERGYSTARScore'],
    alpha=0.5, s=20
)
```

1 Analyse Exploratoire

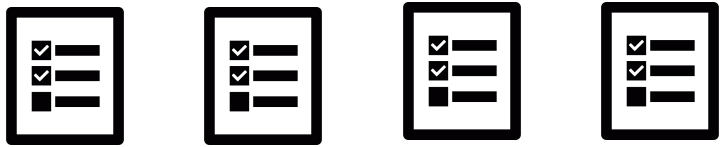
1. Configuration et première inspection
   - 1.1 Chargement et premier aperçu des données.
   - 1.2 Analyse des features pertinentes (IDs, target, domaine...)
   - 1.3 Classification des features prédictives.
2. Analyse de la qualité des données
   - 2.1 Audit des valeurs manquantes et des types de données.
   - 2.2 Vérification de la cohérence (doublons, erreurs de saisie).
3. Détection et caractérisation des outliers
   - 3.1 Analyse de la colonne "outlier" existante (expertise Seattle).
   - 3.2 Identification statistique des valeurs extrêmes (IQR / Z-score).
4. Analyse univariée - variables numériques
   - 4.1 Statistiques descriptives (moyenne, médiane, écart-type).
   - 4.2 Visualisation des distributions et de l'asymétrie (skewness).
5. Analyse multivariée et corrélations
   - 5.1 Matrice de corrélation (heatmap des variables numériques).
   - 5.2 Pairplot des variables énergétiques (relations directes).
   - 5.3 Analyse de la redondance (identification des corrélations > 0.90).
6. Analyse par segments et contexte (domain considerations)
   - 6.1 Analyse
   - de la cible par type d'usage ou quartier.
   - 6.2 Influence de l'année de construction sur l'efficacité.
7. **Synthèse et recommandations pré-engineering**
   - **7.1 Choix final des variables et stratégies de transformation.**

Synthèse et recommandations pré-engineering

Cette étape permet d'identifier la cible et l'ensemble d'actions à réaliser sur les features.

On finalise avec un ensemble de listes avec les différents features ..

- **A eliminer (constants, redondantes (doublons mathématiques),**
- **A reduire l'asymétrie et outliers (Transformation logarithmique , Limiter les extrêmes IQR ou Percentile)**
- **A numeriser les catégorielles (A travers de One-Hot Encoding ou Target encoding)**
- **A comprendre le problème du métier et pouvoir créer des nouvelles Features**



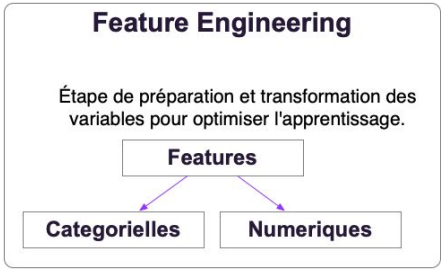
```
================================================================================
cols_a_supprimer  = ['DataYear', 'City', 'State', 'Comments' ....
cols_a_log        = ['PropertyGFATotal', 'PropertyGFABuilding(s)' ....
cols_a_ohe        = ['PrimaryPropertyType', 'BuildingType', ....
cols_a_target     = ['Neighborhood', ....
```

2 Feature Engineering

P. Prétraitement

- **P.1 Chargement du dataset. (shape avant et après)**
- P.2 Filtrage du périmètre métier : exclusion du résidentiel
- P.3 Choisir la cible du modèle
- P.4 Normalisation initiale (cruciale pour la cohérence)

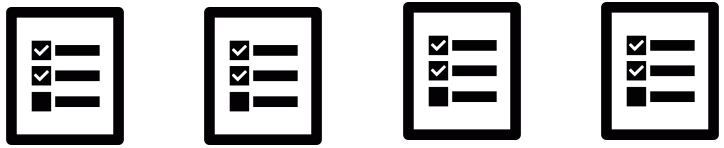
1. Nettoyage initial et élimination
2. Gestion des valeurs manquantes
3. Traitement de l'asymétrie et outliers
   - 3.2. Transformation logarithmique: appliquer aux variables d'énergie et surface.
   - 3.3. Winsorisation/écrêtage: capper les valeurs aux percentiles 1% et 99%.
4. Création de nouvelles features
5. Codification catégorielle
   - 5.1 One-hot encoding
   - 5.2 Target encoding
6. Réduction de la redondance
   - 6.1. Analyse de corrélation: calculer la matrice de pearson post-transformations
   - 6.2. Élimination des corrélées: supprimer si |rho| > 0.99 (garder la plus liée à y)
7. Standardisation. Mise à l'échelle finale



Dataset en brute

	OSEBuildingID	DataYear	BuildingType	PrimaryPropertyType	PropertyName	Address	City	State	ZipCode	TaxParcelIdentificationNumber
0	1	2016	NonResidential	Hotel	Mayflower park hotel	405 Olive way	Seattle	WA	98101.0	0659000030
1	2	2016	NonResidential	Hotel	Paramount Hotel	724 Pine street	Seattle	WA	98101.0	0659000220
2	3	2016	NonResidential	Hotel	5673-The Westin Seattle	1900 5th Avenue	Seattle	WA	98101.0	0659000475
3	5	2016	NonResidential	Hotel	HOTEL MAX	620 STEWART ST	Seattle	WA	98101.0	0659000640
4	8	2016	NonResidential	Hotel	WARWICK SEATTLE HOTEL (ID8)	401 LENORA ST	Seattle	WA	98121.0	0659000970

Liste de recommandations de l'étape précédente.



```
================================================================================
CHARGEMENT DU DATASET RÉUSSI
================================================================================
  Source du fichier.....: 2016_Building_Energy_Benchmarking.csv
  Dimensions brutes.....: 3376 lignes | 46 colonnes
  Taille en mémoire.....: 3.47 MB
  Statut................: ✅ Données chargées dans 'dataset_raw'
================================================================================
```

2 Feature Engineering

P. Prétraitement
- P.1 Chargement du dataset. (shape avant et après)
- **P.2 Filtrage du périmètre métier : exclusion du résidentiel**
- P.3 Choisir la cible du modèle
- P.4 Normalisation initiale (cruciale pour la cohérence)

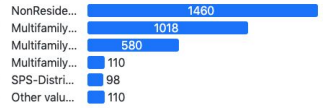
1. Nettoyage initial et élimination
2. Gestion des valeurs manquantes
3. Traitement de l'asymétrie et outliers
   - 3.2. Transformation logarithmique: appliquer aux variables d'énergie et surface.
   - 3.3. Winsorisation/écrêtage: capper les valeurs aux percentiles 1% et 99%.
4. Création de nouvelles features
5. Codification catégorielle
   - 5.1 One-hot encoding
   - 5.2 Target encoding
6. Réduction de la redondance
   - 6.1. Analyse de corrélation: calculer la matrice de pearson post-transformations
   - 6.2. Élimination des corrélées: supprimer si |rho| > 0.99 (garder la plus liée à y)
7. Standardisation. Mise à l'échelle finale

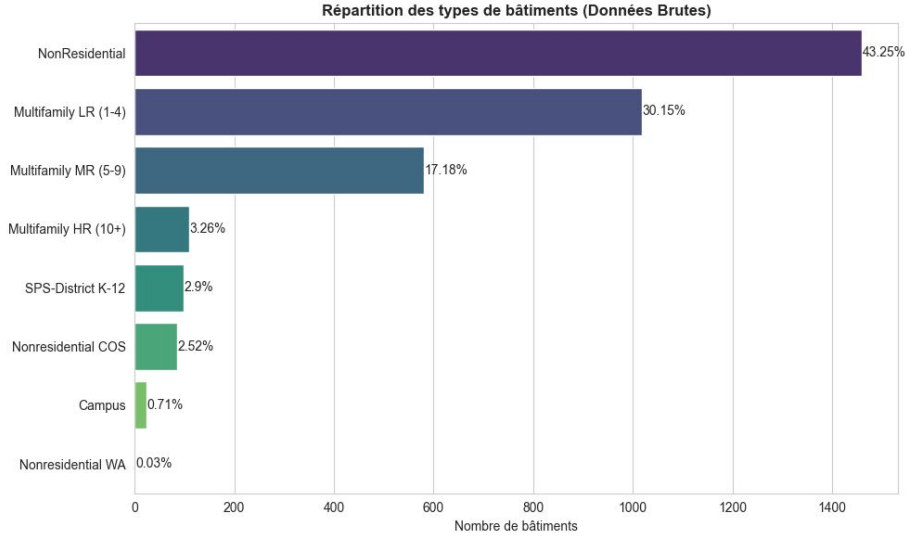
BuildingType

Pour prédire les émissions des bâtiments "non-résidentiels", On vérifie s'il reste des habitations multifamiliales (Multifamily) qui pourraient fausser les résultats.

BuildingType
Categorical
High correlation

Distinct	8
Distinct (%)	0.2%
Missing	0
Missing (%)	0.0%
Memory size	26.5 KiB






```
================================================================================
FILTRAGE DU PÉRIMÈTRE D'ÉTUDE
================================================================================
   Bâtiments initiaux :  3376
🚫 Bâtiments retirés  :  1708 (Type: Multifamily)
✅ Bâtiments restants :  1668 (Périmètre Non-Résidentiel uniquement)
================================================================================
```

2 Feature Engineering

P. Prétraitement
- P.1 Chargement du dataset. (shape avant et après)
- P.2 Filtrage du périmètre métier : exclusion du résidentiel
- **P.3 Choisir la cible du modèle**
- P.4 Normalisation initiale (cruciale pour la cohérence)

1. Nettoyage initial et élimination
2. Gestion des valeurs manquantes
3. Traitement de l'asymétrie et outliers
   - 3.2. Transformation logarithmique: appliquer aux variables d'énergie et surface.
   - 3.3. Winsorisation/écrêtage: capper les valeurs aux percentiles 1% et 99%.
4. Création de nouvelles features
5. Codification catégorielle
   - 5.1 One-hot encoding
   - 5.2 Target encoding
6. Réduction de la redondance
   - 6.1. Analyse de corrélation: calculer la matrice de pearson post-transformations
   - 6.2. Élimination des corrélées: supprimer si |rho| > 0.99 (garder la plus liée à y)
7. Standardisation. Mise à l'échelle finale

SiteEnergyUse(kBtu)

Consommation totale d'énergie du site.

SiteEnergyUse(kBtu)

Real number (ℝ)

High correlation | Skewed

Distinct	3354	Minimum	0
Distinct (%)	99.5%	Maximum	8.7392371×10^8
Missing	5	Zeros	18
Missing (%)	0.1%	Zeros (%)	0.5%
Infinite	0	Negative	0
Infinite (%)	0.0%	Negative (%)	0.0%
Mean	5403667.3	Memory size	26.5 KiB



TotalGHGEmissions

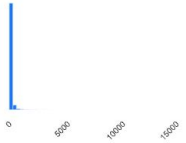
Émissions totales de gaz à effet de serre (GES)

TotalGHGEmissions

Real number (ℝ)

High correlation

Distinct	2818	Minimum	-0.8
Distinct (%)	83.7%	Maximum	16870.98
Missing	9	Zeros	9
Missing (%)	0.3%	Zeros (%)	0.3%
Infinite	0	Negative	1
Infinite (%)	0.0%	Negative (%)	< 0.1%
Mean	119.72397	Memory size	26.5 KiB




```
================================================================================
PARAMÈTRES DE CONFIGURATION INITIALISÉS
================================================================================
  Variable cible (Target)...: SiteEnergyUse(kBtu)
  Graine aléatoire (SEED)...: 42
  Status....................: ✅ Configuration prête
================================================================================
```

2 Feature Engineering

P. Prétraitement
- P.1 Chargement du dataset. (shape avant et après)
- P.2 Filtrage du périmètre métier : exclusion du résidentiel
- P.3 Choisir la cible du modèle
- **P.4 Normalisation initiale (cruciale pour la cohérence)**

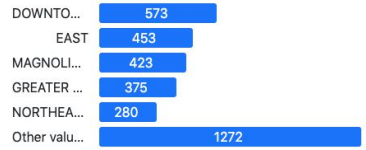
1. Nettoyage initial et élimination
2. Gestion des valeurs manquantes
3. Traitement de l'asymétrie et outliers
   - 3.2. Transformation logarithmique: appliquer aux variables d'énergie et surface.
   - 3.3. Winsorisation/écrêtage: capper les valeurs aux percentiles 1% et 99%.
4. Création de nouvelles features
5. Codification catégorielle
   - 5.1 One-hot encoding
   - 5.2 Target encoding
6. Réduction de la redondance
   - 6.1. Analyse de corrélation: calculer la matrice de pearson post-transformations
   - 6.2. Élimination des corrélées: supprimer si |rho| > 0.99 (garder la plus liée à y)
7. Standardisation. Mise à l'échelle finale

Neighborhood

Categorical

High correlation

Distinct	19
Distinct (%)	0.6%
Missing	0
Missing (%)	0.0%
Memory size	26.5 KiB



Neighborhood	Count	Percentage
DOWNTOWN	573	16.97
EAST	453	13.42
MAGNOLIA / QUEEN ANNE	423	12.53
GREATER DUWAMISH	375	11.11
NORTHEAST	280	8.29
LAKE UNION	251	7.43
NORTHWEST	210	6.22
SOUTHWEST	166	4.92
NORTH	145	4.3
BALLARD	126	3.73
CENTRAL	107	3.17
SOUTHEAST	95	2.81
DELRIDGE	80	2.37
North	42	1.24
Central	27	0.8
Northwest	11	0.33
Ballard	7	0.21
Delridge	4	0.12
DELRIDGE NEIGHBORHOODS	1	0.03

DELRIDGE NEIGHBORHOODS =?= DELRIDGE vs Delridge

```
# On identifie les colonnes textuelles
cols_texte = df.select_dtypes(include=['object']).columns

for col in cols_texte:
        # 1. Convertir en string (pour éviter les erreurs sur les types mixtes)
        # 2. Tout en majuscules
        # 3. Supprimer les espaces au début et à la fin (strip)
        df[col] = df[col].astype(str).str.upper().str.strip()

        # 4. (Optionnel) Reconvertir les chaînes 'NAN' ou 'NONE' en vrais NaN de Numpy
        df[col] = df[col].replace(['NAN', 'NONE', 'NULL', ''], np.nan)
```

2 Feature Engineering

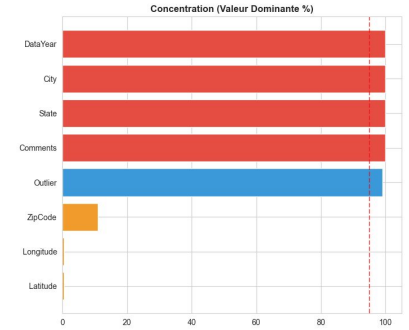
P. Prétraitement
- P.1 Chargement du dataset. (shape avant et après)
- P.2 Filtrage du périmètre métier : exclusion du résidentiel
- P.3 Choisir la cible du modèle
- P.4 Normalisation initiale (cruciale pour la cohérence)

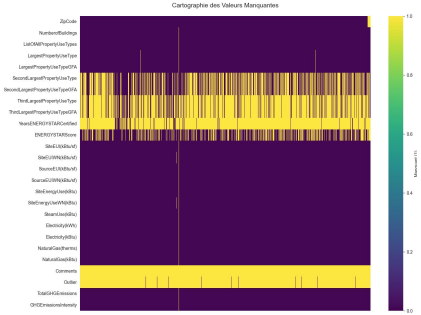
1. Nettoyage initial et élimination

2. Gestion des valeurs manquantes
3. Traitement de l'asymétrie et outliers
   - 3.2. Transformation logarithmique: appliquer aux variables d'énergie et surface.
   - 3.3. Winsorisation/écrêtage: capper les valeurs aux percentiles 1% et 99%.
4. Création de nouvelles features
5. Codification catégorielle
   - 5.1 One-hot encoding
   - 5.2 Target encoding
6. Réduction de la redondance
   - 6.1. Analyse de corrélation: calculer la matrice de pearson post-transformations
   - 6.2. Élimination des corrélées: supprimer si |rho| > 0.99 (garder la plus liée à y)
7. Standardisation. Mise à l'échelle finale

1. Nettoyage Initial et Élimination

- suppression_constantes
- suppression_manquants
- suppression_specifique





Suppression des Constantes:
élimine les variables n'apportant aucune information discriminante (Entropie nulle).

Élimination des Manquants Excessifs:
Supprimer les colonnes Comments et Outlier.

Suppression des Identifiants:
Supprimer l'identifiant unique OSEBuildingID.

Gestion de la Redondance:
Indentifies dans la phase prealable.

```
# ------------------------------------------------------------
# ⚠️ Électricité consommée (kWh) (Electricity(kWh))  <--->  Électricité consommée (kBtu) (Electricity(kBtu))
#    Indice de corrélation : 1.0000
# ------------------------------------------------------------
# ⚠️ Gaz naturel consommé (therms) (NaturalGas(therms))  <--->  Gaz naturel consommé (kBtu) (NaturalGas(kBtu))
#    Indice de corrélation : 1.0000
# ------------------------------------------------------------
```

```
================================================================================================
RAPPORT DE SYNTHÈSE : ÉLAGAGE DES DONNÉES
================================================================================================
      Column                        Raison_Principale     Dtype            Impact_Potentiel
4       City                  Constante (Unique)   object  Perte d'information nulle
1   Comments  Manquants > 95% & Constante (Unique)  float64  Perte d'information nulle
2   DataYear                  Constante (Unique)    int64  Perte d'information nulle
3    Outlier                     Manquants > 95%   object  Perte d'information nulle
0      State                  Constante (Unique)   object  Perte d'information nulle
```

2 Feature Engineering

P. Prétraitement
- P.1 Chargement du dataset. (shape avant et après)
- P.2 Filtrage du périmètre métier : exclusion du résidentiel
- P.3 Choisir la cible du modèle
- P.4 Normalisation initiale (cruciale pour la cohérence)

1. Nettoyage initial et élimination
2. **Gestion des valeurs manquantes**
3. Traitement de l'asymétrie et outliers
   - 3.2. Transformation logarithmique: appliquer aux variables d'énergie et surface.
   - 3.3. Winsorisation/écrêtage: capper les valeurs aux percentiles 1% et 99%.
4. Création de nouvelles features
5. Codification catégorielle
   - 5.1 One-hot encoding
   - 5.2 Target encoding
6. Réduction de la redondance
   - 6.1. Analyse de corrélation: calculer la matrice de pearson post-transformations
   - 6.2. Élimination des corrélées: supprimer si |rho| > 0.99 (garder la plus liée à y)
7. Standardisation. Mise à l'échelle finale

2. Gestion des Valeurs Manquantes

- creation_indicateurs_missing
- imputation_categoriques
- imputation_numeriques

```
# ÉTAPE 2.1 : CRÉATION DES INDICATEURS (MEMORY OF MISSINGNESS)
# Feature : Nom_Original + "_IS_NAN"
# ------------------------------------------------------------------------------
| Feature Source (Exemple)          | Feature Indicateur (Nouveau)           |
|-----------------------------------|----------------------------------------|
| ThirdLargestPropertyUseTypeGFA    | ThirdLargestPropertyUseTypeGFA_Manquant|
| SecondLargestPropertyUseType      | SecondLargestPropertyUseType_Manquant  |
| ENERGYSTARScore                   | ENERGYSTARScore_Manquant               |
```

Compléter les manquants des features catégorielles

"INCONNU"

```
# ÉTAPE 2.2 : IMPUTATION CATÉGORIELLE (SEMANTIC FILL)
# Valeur de remplacement : "INCONNU"
# ------------------------------------------------------------------------------
| SecondLargestPropertyUseType    | SecondLargestPropertyUseType_Manquant  |
|---------------------------------|----------------------------------------|
| "Office"                        | 0  ← Inchangé                          |
| "INCONNU"                       | 1  ← Valeur imputée                    |
| "Retail"                        | 0  ← Inchangé                          |
| "INCONNU"                       | 1  ← Valeur imputée                    |
```

Compléter les manquants des features numériques

Médiane

```
# ÉTAPE 2.3 : IMPUTATION NUMÉRIQUE (ROBUST FILL)
# Valeur de remplacement : Médiane du Train Set
# ------------------------------------------------------------------------------
| ThirdLargestPropertyUseTypeGFA  | ThirdLargestPropertyUseTypeGFA_Manquant|
|---------------------------------|----------------------------------------|
| 150.5                           | 0  ← Inchangé                          |
| 175.0 (Médiane)                 | 1  ← Valeur imputée                    |
| 200.0                           | 0  ← Inchangé                          |
| 175.0 (Médiane)                 | 1  ← Valeur imputée                    |
```

```
========================================================================
Top 20 du rapport détaillé :
| Column                    |   N_Unique |   Missing_Pct | Dtype    |      Var_Norm |   Dominant_Pct | Is_Constant   | Is_Quasi   |
|:--------------------------|-----------:|--------------:|:---------|--------------:|---------------:|:--------------|:-----------|
| DataYear                  |          1 |             0 | int64    |             0 |            100 | True          | False      |
| City                      |          1 |             0 | object   | nan           |            100 | True          | False      |
| State                     |          1 |             0 | object   | nan           |            100 | True          | False      |
| Comments                  |          1 |           100 | float64  | nan           |            100 | True          | False      |
| DefaultData               |          2 |             0 | bool     |   4.23855     |             94.7242 | False         | False      |
```

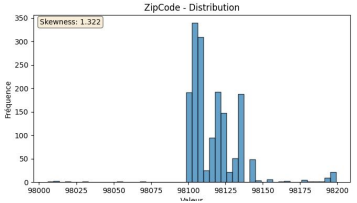
2 Feature Engineering

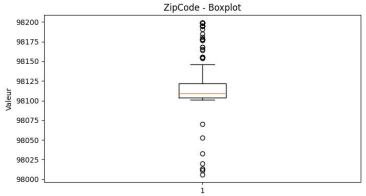
P. Prétraitement
- P.1 Chargement du dataset. (shape avant et après)
- P.2 Filtrage du périmètre métier : exclusion du résidentiel
- P.3 Choisir la cible du modèle
- P.4 Normalisation initiale (cruciale pour la cohérence)

1. Nettoyage initial et élimination
2. Gestion des valeurs manquantes
3. **Traitement de l'asymétrie et outliers**
   - **3.2. Transformation logarithmique: appliquer aux variables d'énergie et surface.**
   - 3.3. Winsorisation/écrêtage: capper les valeurs aux percentiles 1% et 99%.
4. Création de nouvelles features
5. Codification catégorielle
   - 5.1 One-hot encoding
   - 5.2 Target encoding
6. Réduction de la redondance
   - 6.1. Analyse de corrélation: calculer la matrice de pearson post-transformations
   - 6.2. Élimination des corrélées: supprimer si |rho| > 0.99 (garder la plus liée à y)
7. Standardisation. Mise à l'échelle finale

3. Traitement de l'Asymétrie et Outliers

- transformation_logarithmique
- winsorisation





Transformation logarithmique

Réduire l'asymétrie (skewness) des distributions pour rendre les données plus gaussiennes. Essentiel pour les variables avec forte asymétrie positive (longue queue à droite).

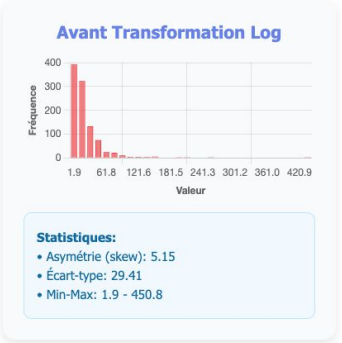
Formule

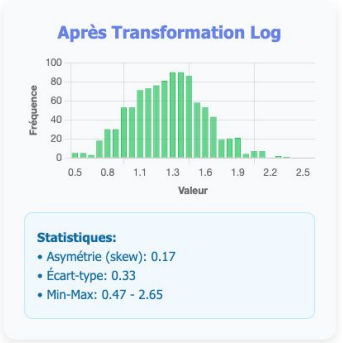
$$x' = \log_{10}(x + 1) \text{ ou } x' = \ln(x + 1)$$

On utilise log(x+1) pour gérer les valeurs nulles

✅ **Avantages**

Réduit l'asymétrie
Distribution plus symétrique et normale
Stabilise la variance
Homogénéise les variances entre groupes
Atténue les extrêmes
Réduit l'influence des valeurs très élevées
Linéarise les relations
Relations exponentielles → linéaires






```
================================================================================
• SteamUse(kBtu)                                    → SteamUse(kBtu)_log
    Skewness avant.......:   19.152
    Skewness après.......:    3.492
    Amélioration.........:   15.660
```

2 Feature Engineering

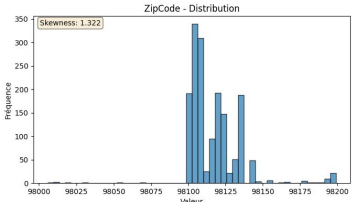
P. Prétraitement
- P.1 Chargement du dataset. (shape avant et après)
- P.2 Filtrage du périmètre métier : exclusion du résidentiel
- P.3 Choisir la cible du modèle
- P.4 Normalisation initiale (cruciale pour la cohérence)

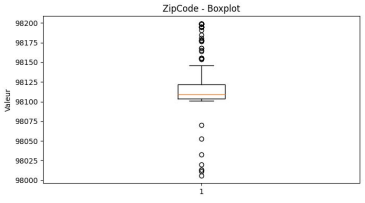
1. Nettoyage initial et élimination
2. Gestion des valeurs manquantes
3. Traitement de l'asymétrie et outliers
   - 3.2. Transformation logarithmique: appliquer aux variables d'énergie et surface.
   - **3.3. Winsorisation/écrêtage: capper les valeurs aux percentiles 1% et 99%.**
4. Création de nouvelles features
5. Codification catégorielle
   - 5.1 One-hot encoding
   - 5.2 Target encoding
6. Réduction de la redondance
   - 6.1. Analyse de corrélation: calculer la matrice de pearson post-transformations
   - 6.2. Élimination des corrélées: supprimer si |rho| > 0.99 (garder la plus liée à y)
7. Standardisation. Mise à l'échelle finale

3. Traitement de l'Asymétrie et Outliers

transformation_logarithmique

winsorisation





Feature Clipping

Winsorisation/Clipping (écrêtage par percentiles)

Limiter l'influence des valeurs extrêmes (outliers) sans les supprimer. On remplace les valeurs au-delà des percentiles par ces percentiles.

Formule

$x' = clip(x, P_1, P_{99})$

Si $x < P_1 \rightarrow x' = P_1$, Si $x > P_{99} \rightarrow x' = P_{99}$, Sinon $\rightarrow x' = x$

P_1 = 1er percentile, P_{99} = 99e percentile

✅ **Avantages**

Préserve les données
Pas de suppression, seulement limitation

Réduit l'influence
Outliers ne dominent plus le modèle

Robustesse accrue
Améliore la stabilité des modèles

Conserve la taille
Aucune perte de observations






```
================================================================================
  • GHGEmissionsIntensity → GHGEmissionsIntensity_wins
    Bornes.............: [0.03, 11.08]
    Valeurs cappées.....: 34 (2.04%)
      - Bas (< 0.03)...: 17
      - Haut (> 11.08).: 17
```

2 Feature Engineering

P. Prétraitement
- P.1 Chargement du dataset. (shape avant et après)
- P.2 Filtrage du périmètre métier : exclusion du résidentiel
- P.3 Choisir la cible du modèle
- P.4 Normalisation initiale (cruciale pour la cohérence)

1. Nettoyage initial et élimination
2. Gestion des valeurs manquantes
3. Traitement de l'asymétrie et outliers
   - 3.2. Transformation logarithmique: appliquer aux variables d'énergie et surface.
   - 3.3. Winsorisation/écrêtage: capper les valeurs aux percentiles 1% et 99%.
4. **Création de nouvelles features**
5. Codification catégorielle
   - 5.1 One-hot encoding
   - 5.2 Target encoding
6. Réduction de la redondance
   - 6.1. Analyse de corrélation: calculer la matrice de pearson post-transformations
   - 6.2. Élimination des corrélées: supprimer si |rho| > 0.99 (garder la plus liée à y)
7. Standardisation. Mise à l'échelle finale

Variable (Feature)	Description Métier	Logique de Calcul / Formule
F1_Distance_Centre	Proximité avec le centre névralgique	Distance géospatiale (m) / Hôtel de Ville
F2_Distance_Port	Impact de la zone industrielle/portuaire	Distance géospatiale (m) / Port de Seattle
F3_Densite_Voisinage	Contexte urbain et micro-climat	Nombre de bâtiments voisins (Rayons 500-2000m)
F4_Taille_Ordinale	Catégorie de grandeur du bâtiment	Binning : Petit (0), Moyen (1), Grand (2)
F5_Usage_Diversity	Mixité simple des activités	Somme des usages secondaires et tertiaires
F6_Parking_Ratio	Importance des zones non-chauffées	Surface Parking / Surface Totale
F7_Has_Parking	Présence d'une infrastructure de stationnement	Variable Binaire (0: Non, 1: Oui)
F8_EnergyStar_Cat	Niveau d'efficacité certifié	Classes : Faible, Moyen, Bon, Excellent
F10_Primary_Use_Ratio	Spécialisation du bâtiment	Surface Usage Principal / Surface Totale
F11_Building_Age	Obsolescence thermique	2016 - Année de construction
F12_Floors_Mean	Densité verticale par structure	Nombre d'Étages / Nombre de Bâtiments

```
cleaner_global.ajouter_feature(
    nom    = 'F1_Usage_Complexity_Score',
    calcul = lambda df: (
        df['SecondLargestPropertyUseType'].notna().astype(int) +
        df['ThirdLargestPropertyUseType'].notna().astype(int)
    ).replace(2, 3),
    description = "Score de complexité : 0 (mono), 1 (bi), 3 (multi-usage)",
    dtype  = int
)
```

2 Feature Engineering

- P. Prétraitement
  - P.1 Chargement du dataset. (shape avant et après)
  - P.2 Filtrage du périmètre métier : exclusion du résidentiel
  - P.3 Choisir la cible du modèle
  - P.4 Normalisation initiale (cruciale pour la cohérence)
- 1. Nettoyage initial et élimination
- 2. Gestion des valeurs manquantes
- 3. Traitement de l'asymétrie et outliers
  - 3.2. Transformation logarithmique: appliquer aux variables d'énergie et surface.
  - 3.3. Winsorisation/écrêtage: capper les valeurs aux percentiles 1% et 99%.
- 4. Création de nouvelles features
- **5. Codification catégorielle**
  - **5.1 One-hot encoding**
  - 5.2 Target encoding
- 6. Réduction de la redondance
  - 6.1. Analyse de corrélation: calculer la matrice de pearson post-transformations
  - 6.2. Élimination des corrélées: supprimer si |rho| > 0.99 (garder la plus liée à y)
- 7. Standardisation. Mise à l'échelle finale

5. Codification Catégorielle

- one_hot_encoding
- target_encoding

Formule

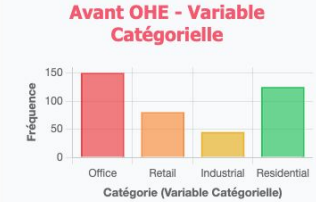
$X_original = [cat_1, cat_2, ..., catn] > X_encoded = [X_1, X_2, ..., Xn_{-1}]$

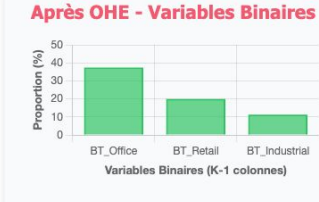
$X_i = \{ 1 \text{ si catégorie} = cat_i \ 0 \text{ sinon} \}$

On garde K-1 colonnes (drop_first=True) pour éviter la multicolinéarité

One-Hot Encoding (OHE)

Convertir les variables catégorielles en variables binaires (0/1). Chaque catégorie devient une colonne séparée. Idéal pour basse cardinalité (≤ 10 catégories).





✅ **Avantages**

Simple et intuitif
Facile à comprendre et interpréter

Sans ordre artificiel
Ne crée pas de relation ordinale

Compatible sklearn
Fonctionne avec tous les modèles

⚠️ **Inconvénients**

Curse of dimensionality
100 catégories = 99 colonnes !

Sparse matrices
Beaucoup de zéros (inefficace)

BuildingType (Original)	BT_Commercial	BT_Industrial	BT_Residential
Office	1	0	0
Industrial	0	1	0
Residential	0	0	1
Office	1	0	0

```
📊 Analyse de la feature : BuildingType
---
• Nombre de catégories uniques : 5
• Type de données : object
• Top 5 des catégories :
BuildingType
NonResidential        1460
SPS-District K-12       98
Nonresidential COS      85
Campus                  24
Nonresidential WA        1
```

2 Feature Engineering

P. Prétraitement
- P.1 Chargement du dataset. (shape avant et après)
- P.2 Filtrage du périmètre métier : exclusion du résidentiel
- P.3 Choisir la cible du modèle
- P.4 Normalisation initiale (cruciale pour la cohérence)

1. Nettoyage initial et élimination
2. Gestion des valeurs manquantes
3. Traitement de l'asymétrie et outliers
   - 3.2. Transformation logarithmique: appliquer aux variables d'énergie et surface.
   - 3.3. Winsorisation/écrêtage: capper les valeurs aux percentiles 1% et 99%.
4. Création de nouvelles features
5. Codification catégorielle
   - 5.1 One-hot encoding
   - **5.2 Target encoding**
6. Réduction de la redondance
   - 6.1. Analyse de corrélation: calculer la matrice de pearson post-transformations
   - 6.2. Élimination des corrélées: supprimer si |rho| > 0.99 (garder la plus liée à y)
7. Standardisation. Mise à l'échelle finale

5. Codification Catégorielle

one_hot_encoding

target_encoding

Target Encoding (TE)

Remplacer chaque catégorie par la moyenne de la cible pour cette catégorie. Idéal pour haute cardinalité (> 10 catégories). Encode l'information prédictive directement.

✅ **Avantages**

Haute cardinalité
1000 catégories → 1 seule colonne

Information prédictive
Encode directement la relation avec y

Performant
Souvent meilleur R^2 que OHE

⚠️ **Inconvénients**

Risque de leakage
Doit utiliser Cross-Validation

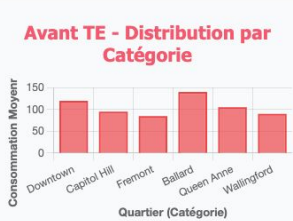
Plus complexe
Nécessite accès à y

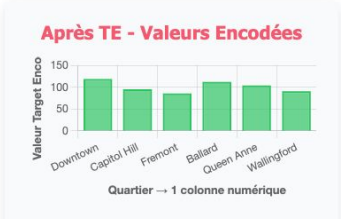
Catégories nouvelles
Fallback vers moyenne globale

Formule

$$TE(c) = (n_c \times mean_c + m \times mean_global) / (n_c + m)$$

où:
- **n_c** = nombre d'observations dans catégorie c
- **mean_c** = moyenne de y pour catégorie c
- **mean_global** = moyenne globale de y
- **m** = paramètre de smoothing (typ. 10-100)





Neighborhood	Énergie Moyenne (y)	Count	Target Encoded (m=10)
Downtown	120 kBtu	150	118.5
Capitol Hill	95 kBtu	80	96.7
Fremont	85 kBtu	200	85.5
Ballard	140 kBtu	5	126.7 ⚠️

⚠️ *Ballard (rare) est "lissé" vers la moyenne globale (100) grâce au smoothing*

```
================================================================================
Target                : SiteEnergyUsekBtu_wins
Catégories            : 14
Global Mean           : 7015540.5676
Smoothing             : 10.0
CV Folds              : 5
Nouvelle colonne      : Neighborhood_Encoded
  Mean                : 7073663.3544
  Std                 : 2762649.3178
  Range               : [3495675.8322, 11959922.3127]
  Missing             : 0
```

2 Feature Engineering

P. Prétraitement
- P.1 Chargement du dataset. (shape avant et après)
- P.2 Filtrage du périmètre métier : exclusion du résidentiel
- P.3 Choisir la cible du modèle
- P.4 Normalisation initiale (cruciale pour la cohérence)

1. Nettoyage initial et élimination
2. Gestion des valeurs manquantes
3. Traitement de l'asymétrie et outliers
   - 3.2. Transformation logarithmique: appliquer aux variables d'énergie et surface.
   - 3.3. Winsorisation/écrêtage: capper les valeurs aux percentiles 1% et 99%.
4. Création de nouvelles features
5. Codification catégorielle
   - 5.1 One-hot encoding
   - 5.2 Target encoding
6. **Réduction de la redondance**
   - **6.1. Analyse de corrélation: calculer la matrice de pearson post-transformations**
   - **6.2. Élimination des corrélées: supprimer si |rho| > 0.99 (garder la plus liée à y)**
7. Standardisation. Mise à l'échelle finale

6. Réduction de la Redondance

`eliminer_correlees`

Réduction de Redondance

Éliminer les variables qui sont quasi-identiques (fortement corrélées). Si deux variables mesurent presque la même chose, une seule suffit. Cela réduit la multicolinéarité et améliore l'efficacité du modèle.

✅ Avantages

Réduit la multicolinéarité
Évite que deux variables "se battent" pour expliquer la même variance

Améliore la stabilité
Coefficients du modèle plus stables et interprétables

Accélère l'entraînement
Moins de colonnes = calculs plus rapides

Évite l'overfitting
Moins de features redondantes = moins de bruit

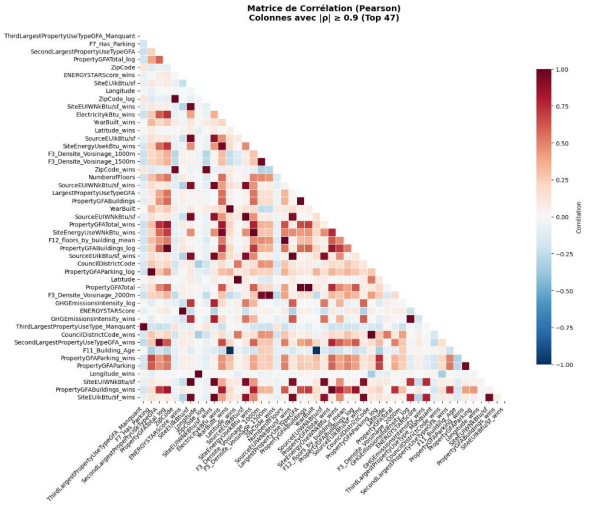
Coefficient de corrélation de Pearson

$$r(X, Y) = Cov(X, Y) / (\sigma_x \times \sigma_Y)$$

où:
- **Cov(X, Y)** = covariance entre X et Y
- σ_x, σ_Y = écarts-types de X et Y
- **Résultat :** r ∈ [-1, 1]

Matrice de corrélation

Valeurs absolues: On prend la valeur absolue car -0.95 est aussi redondant que +0.95
Triangle supérieur: Pour éviter de comparer chaque paire deux fois (X→Y et Y→X)




```
================================================================================
1. ρ = -1.0000
   YearBuilt
   F11_Building_Age
--------------------------------------------------------------------------------
CANDIDATS À LA SUPPRESSION (38)
--------------------------------------------------------------------------------
1. F11_Building_Age
   Corrélée avec : YearBuilt (ρ=-1.0000)
   Corr. target gardée   : 0.1898
   Corr. target supprimée: 0.1898
```

2 Feature Engineering

P. Prétraitement
- P.1 Chargement du dataset. (shape avant et après)
- P.2 Filtrage du périmètre métier : exclusion du résidentiel
- P.3 Choisir la cible du modèle
- P.4 Normalisation initiale (cruciale pour la cohérence)

1. Nettoyage initial et élimination
2. Gestion des valeurs manquantes
3. Traitement de l'asymétrie et outliers
   - 3.2. Transformation logarithmique: appliquer aux variables d'énergie et surface.
   - 3.3. Winsorisation/écrêtage: capper les valeurs aux percentiles 1% et 99%.
4. Création de nouvelles features
5. Codification catégorielle
   - 5.1 One-hot encoding
   - 5.2 Target encoding
6. Réduction de la redondance
   - 6.1. Analyse de corrélation: calculer la matrice de pearson post-transformations
   - 6.2. Élimination des corrélées: supprimer si |rho| > 0.99 (garder la plus liée à y)

7. Standardisation. Mise à l'échelle finale

7. Standardisation. Mise à l'Échelle Finale

suppression_haute_cardinalite

Standardisation (Feature Scaling)

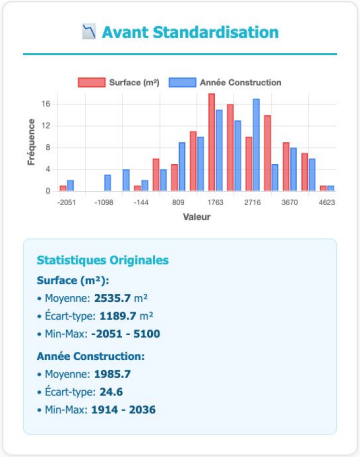
Transformer toutes les variables numériques pour qu'elles aient **moyenne = 0** et **écart-type = 1.**

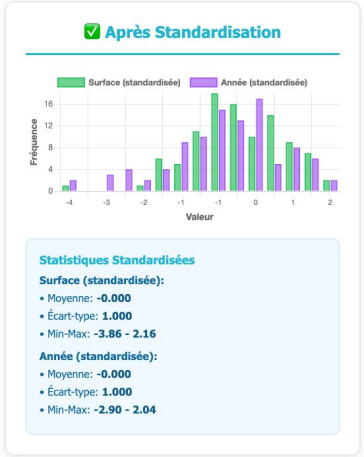
Cela permet aux algorithmes de traiter équitablement toutes les features, indépendamment de leur échelle d'origine.

StandardScaler (Z-score normalization)

$$z = (x - \mu) / \sigma$$

où:
- **x** = valeur originale
- **μ** = moyenne de la feature
- **σ** = écart-type de la feature
- **z** = valeur standardisée

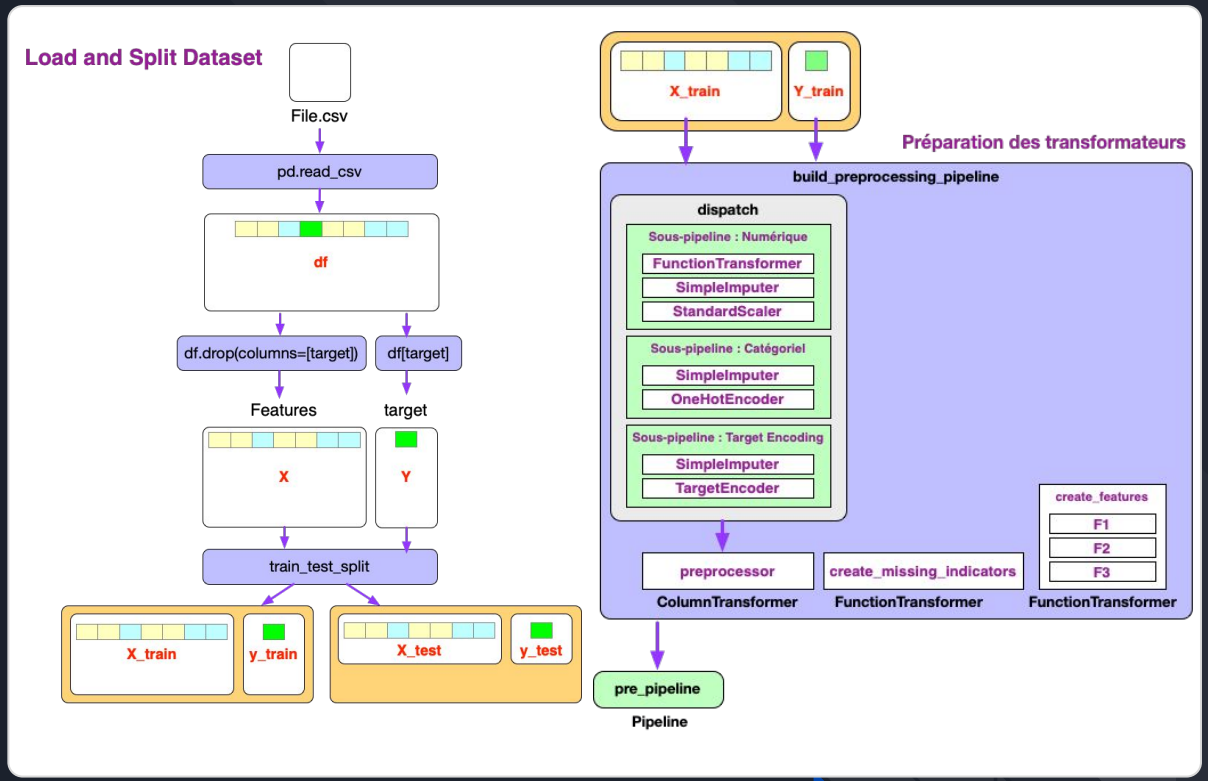





```
================================================================================
VÉRIFICATION PRÉ-SCALING
2. NumberofBuildings
   dtype=float64, unique=16, missing=0
   μ =1.17, σ=2.93, range=[0.00, 111.00]
================================================================================
STANDARDISATION (StandardScaler)
2. NumberofBuildings
   Avant : μ=1.17      , σ=2.93, range=[0.00, 111.00]
   Après : μ=-2.45e-17, σ=1.00, range=[-0.40, 37.50]
```

3 Modelisation

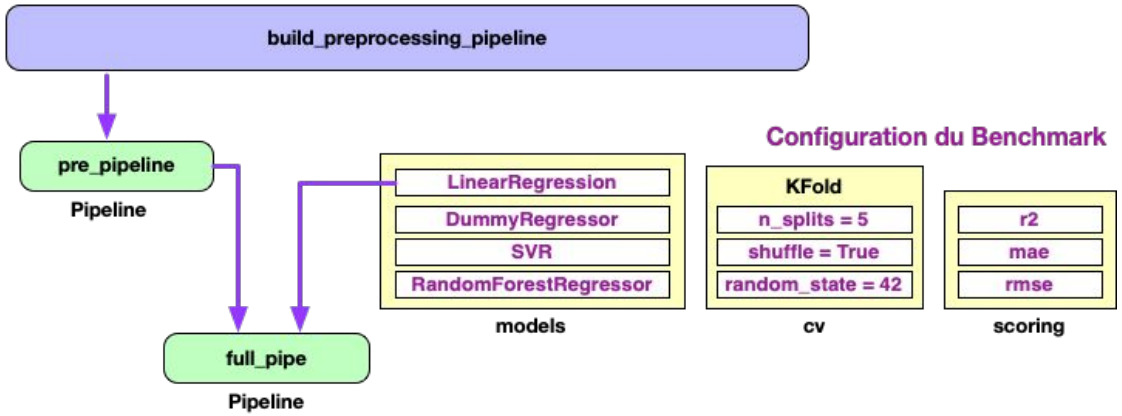
1. **Initialisation du pré-pipeline**
   Préparation des transformateurs (scaling, encodage, imputation).
2. Configuration du benchmark
   Définition des métriques (R^2, RMSE, MAE) et sélection des algorithmes candidats.
3. Benchmark des modèles : évaluation détaillée
   Entraînement initial et extraction des performances moyennes par validation croisée.
4. Entraînement Final et Test (Production Ready)
   FIT : Entraînement du modèle sélectionné sur la totalité du set d'entraînement (X_train). C'est ici que les poids du modèle sont fixés.
   PREDICT : Projection sur les données jamais vues (X_test) pour mesurer la capacité de généralisation réelle.
5. Analyse comparative et sélection du modèle optimal
   5.1 Analyse des courbes de validation (Étude du surapprentissage : biais vs variance).
   5.2 Inspection des résidus (Homoscédasticité et normalité des erreurs sur X_test
   5.3 Importance des Features (Quelles variables de Seattle influencent le plus la consommation ?).




```
================================================================================
ARCHITECTURE DU PRÉPROCESSEUR (SCIKIT-LEARN)
================================================================================
  Features numériques...: 43
  Features catégorielles: 8
  Stratégie Imputation..: Médiane (Num) / Constante (Cat)
  Normalisation.........: StandardScaler (μ=0, σ=1)
  Status................: ✅ Pipeline configuré avec succès
================================================================================
```

3 Modelisation

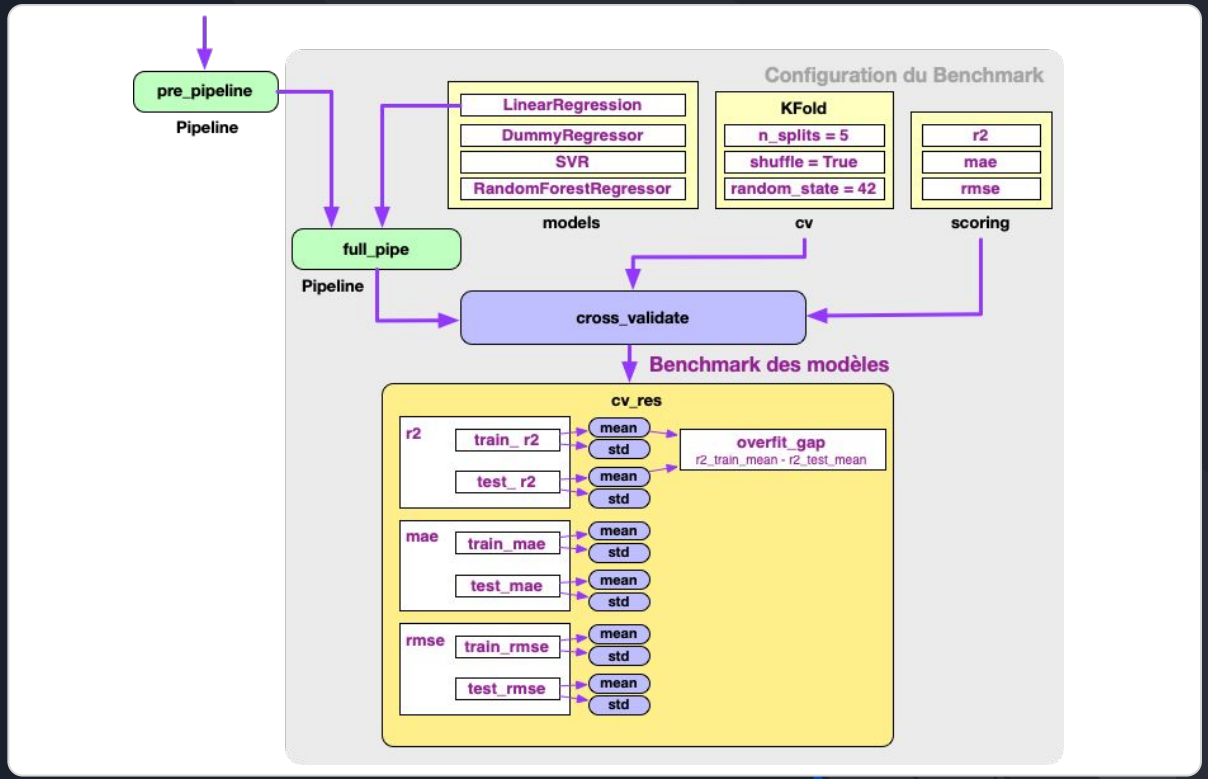
1. Initialisation du pré-pipeline
   Préparation des transformateurs (scaling, encodage, imputation).
2. **Configuration du benchmark**
   Définition des métriques (R^2, RMSE, MAE) et sélection des algorithmes candidats.
3. Benchmark des modèles : évaluation détaillée
   Entraînement initial et extraction des performances moyennes par validation croisée.
4. Entraînement Final et Test (Production Ready)
   FIT : Entraînement du modèle sélectionné sur la totalité du set d'entraînement (X_train). C'est ici que les poids du modèle sont fixés.
   PREDICT : Projection sur les données jamais vues (X_test) pour mesurer la capacité de généralisation réelle.
5. Analyse comparative et sélection du modèle optimal
   5.1 Analyse des courbes de validation (Étude du surapprentissage : biais vs variance).
   5.2 Inspection des résidus (Homoscédasticité et normalité des erreurs sur X_test
   5.3 Importance des Features (Quelles variables de Seattle influencent le plus la consommation ?).




```
================================================================================
CATALOGUE DE MODÉLISATION INITIALISÉ (SEED: 42)
================================================================================
  Modèle 01 : Baseline (Moyenne)............: En attente de validation
  Modèle 02 : Régression Linéaire...........: En attente de validation
  Modèle 03 : SVR (RBF).....................: En attente de validation
  Modèle 04 : Random Forest.................: En attente de validation
================================================================================
PARAMÈTRES DE VALIDATION CROISÉE
================================================================================
  Nombre de Folds.......: 5
  Mélange des données...: True
  Métriques suivies.....: ['r2', 'mae', 'rmse']
  Graine aléatoire (SEED): 42
  Status................: ✅ Prêt pour le benchmark
================================================================================
```

3 Modelisation

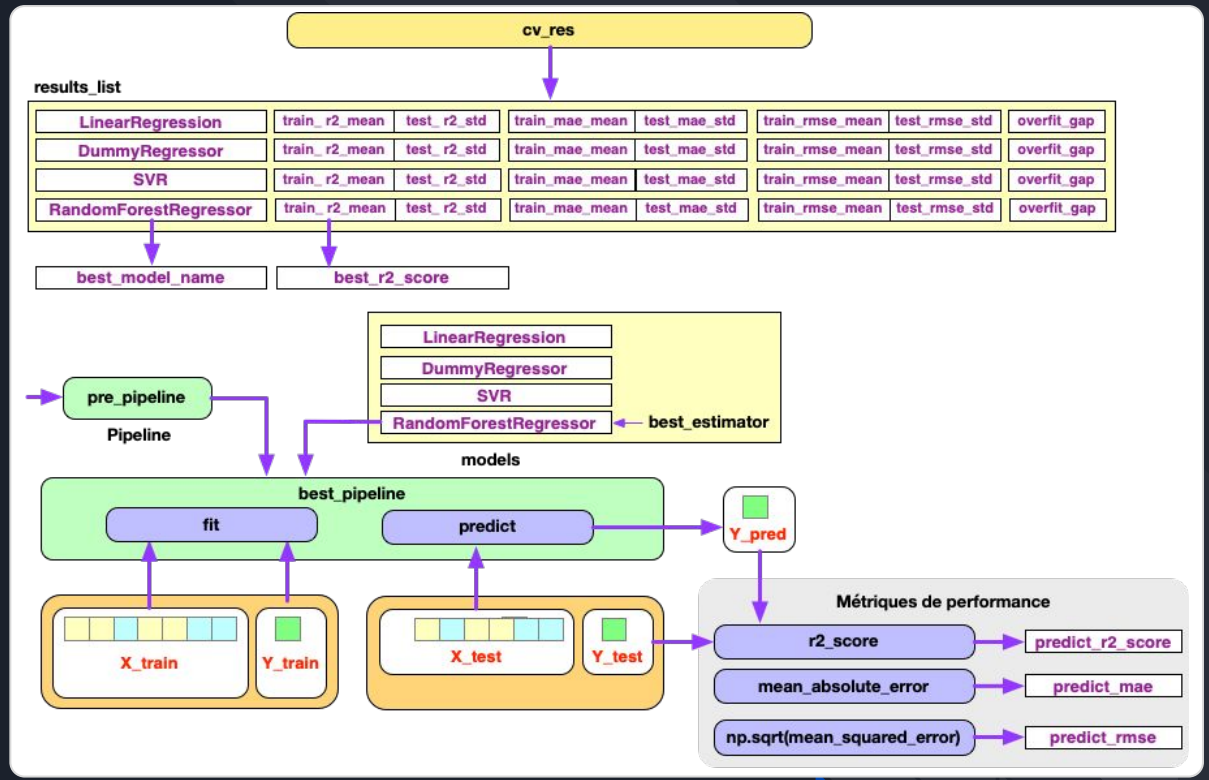
1. Initialisation du pré-pipeline
   Préparation des transformateurs (scaling, encodage, imputation).
2. Configuration du benchmark
   Définition des métriques (R^2, RMSE, MAE) et sélection des algorithmes candidats.
3. **Benchmark des modèles : évaluation détaillée**
   Entraînement initial et extraction des performances moyennes par validation croisée.
4. Entraînement Final et Test (Production Ready)
   FIT : Entraînement du modèle sélectionné sur la totalité du set d'entraînement (X_train). C'est ici que les poids du modèle sont fixés.
   PREDICT : Projection sur les données jamais vues (X_test) pour mesurer la capacité de généralisation réelle.
5. Analyse comparative et sélection du modèle optimal
   5.1 Analyse des courbes de validation (Étude du surapprentissage : biais vs variance).
   5.2 Inspection des résidus (Homoscédasticité et normalité des erreurs sur X_test
   5.3 Importance des Features (Quelles variables de Seattle influencent le plus la consommation ?).




```
🔄 Cross-validation pour Régression Linéaire...
✅ Régression Linéaire
   R²   train..: 0.4908 | CV: 0.4259 ± 0.1664
   MAE  train..: 3984754.81 | CV: 4490683.10 ± 189872.68
   RMSE train..: 10913064.24 | CV: 11215698.42 ± -4763989.50
   ✅ Bon équilibre train/CV
```

3 Modelisation

1. Initialisation du pré-pipeline
   Préparation des transformateurs (scaling, encodage, imputation).
2. Configuration du benchmark
   Définition des métriques (R^2, RMSE, MAE) et sélection des algorithmes candidats.
3. Benchmark des modèles : évaluation détaillée
   Entraînement initial et extraction des performances moyennes par validation croisée.
4. **Entraînement Final et Test (Production Ready)**
   FIT : Entraînement du modèle sélectionné sur la totalité du set d'entraînement (X_train). C'est ici que les poids du modèle sont fixés.
   PREDICT : Projection sur les données jamais vues (X_test) pour mesurer la capacité de généralisation réelle.
5. Analyse comparative et sélection du modèle optimal
   5.1 Analyse des courbes de validation (Étude du surapprentissage : biais vs variance).
   5.2 Inspection des résidus (Homoscédasticité et normalité des erreurs sur X_test
   5.3 Importance des Features (Quelles variables de Seattle influencent le plus la consommation ?).




```
================================================================================
📦 ENTRAÎNEMENT DU MODÈLE OPTIMAL : Random Forest
================================================================================
🚀 Entraînement final de Random Forest sur le jeu complet...
================================================================================
BILAN FINAL DU PIPELINE
================================================================================
  Modèle entraîné.....: Random Forest
  Performance R² Test.: 0.2923
================================================================================
✅ Pipeline sauvegardé : 'best_model_pipeline.pkl'
   Taille disque......: 4119.89 KB
```

3 Modelisation

1. Initialisation du pré-pipeline
   Préparation des transformateurs (scaling, encodage, imputation).
2. Configuration du benchmark
   Définition des métriques (R^2, RMSE, MAE) et sélection des algorithmes candidats.
3. Benchmark des modèles : évaluation détaillée
   Entraînement initial et extraction des performances moyennes par validation croisée.
4. Entraînement Final et Test (Production Ready)
   FIT : Entraînement du modèle sélectionné sur la totalité du set d'entraînement (X_train). C'est ici que les poids du modèle sont fixés.
   PREDICT : Projection sur les données jamais vues (X_test) pour mesurer la capacité de généralisation réelle.
5. **Analyse comparative et sélection du modèle optimal**
   5.1 Analyse des courbes de validation (Étude du surapprentissage : biais vs variance).
   5.2 Inspection des résidus (Homoscédasticité et normalité des erreurs sur X_test
   5.3 Importance des Features (Quelles variables de Seattle influencent le plus la consommation ?).



Si la barre orange (CV) est beaucoup plus basse que la bleue(Train), on visualises physiquement la Variance (Surapprentissage).
Si la moustache de la barre orange (CV) est très longue, signifie que les performances du modèle sont instables selon les données qu'il reçoit.

📊 Diagnostic 5.1 : Biais-Variance

Surapprentissage généralisé :
Tous les modèles dépassent le seuil critique de 0.10 (Zone Rouge).

Meilleur candidat :
Le Random Forest est le plus performant, malgré un écart (gap) de 0.115.

Instabilité linéaire :
La Régression Linéaire échoue avec le plus fort surapprentissage (0.197).

🎯 Diagnostic 5.3 : Importance des Features

Ultra-concentration :
Deux variables seulement (Noms à identifier) dictent 93% du modèle.

Stabilité des poids :
Les faibles barres d'erreur confirment que ces deux piliers sont fiables.

Loi de Pareto :
Le reste des 46 variables n'apporte quasiment aucun signal utile au modèle.

```
================================================================================
📊 Interprétation Biais-Variance:
❌ Random Forest              → Surapprentissage (gap = 0.115)
❌ Régression Linéaire        → Surapprentissage (gap = 0.197)
❌ SVR (RBF)                  → Surapprentissage (gap = 0.176)
✅ Baseline (Moyenne)         → Bon équilibre (gap = 0.004)
```

3 Modelisation

1. Initialisation du pré-pipeline
   Préparation des transformateurs (scaling, encodage, imputation).
2. Configuration du benchmark
   Définition des métriques (R^2, RMSE, MAE) et sélection des algorithmes candidats.
3. Benchmark des modèles : évaluation détaillée
   Entraînement initial et extraction des performances moyennes par validation croisée.
4. Entraînement Final et Test (Production Ready)
   FIT : Entraînement du modèle sélectionné sur la totalité du set d'entraînement (X_train). C'est ici que les poids du modèle sont fixés.
   PREDICT : Projection sur les données jamais vues (X_test) pour mesurer la capacité de généralisation réelle.
5. Analyse comparative et sélection du modèle optimal
   5.1 Analyse des courbes de validation (Étude du surapprentissage : biais vs variance).
   5.2 Inspection des résidus (Homoscédasticité et normalité des erreurs sur X_test
   5.3 Importance des Features (Quelles variables de Seattle influencent le plus la consommation ?).

Homoscédasticité indique si **"Les erreurs de prédiction sont-elles régulières partout ?"**

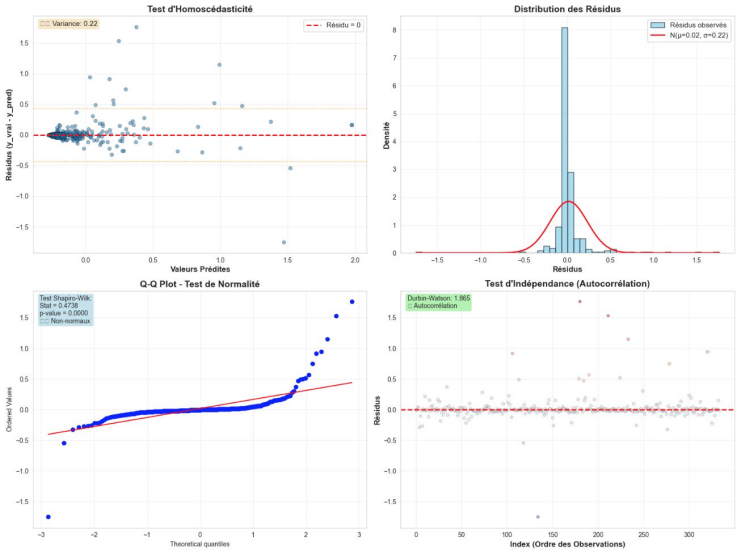
4 graphiques :

Résidus vs Prédictions
→ Test homoscédasticité
→ Vérifie si les erreurs sont **constantes** partout (pas d'entonnoir)

Histogramme
→ Distribution des erreurs
→ Vérifie si les erreurs sont **symétriques** autour de zéro (forme de cloche)

Q-Q Plot
→ Test normalité (Shapiro-Wilk)
→ Vérifie si les erreurs **suivent une loi normale** (points sur la diagonale)

Résidus vs Ordre
→ Test autocorrélation (Durbin-Watson)
→ Vérifie si les erreurs **sont indépendantes** (pas de pattern/vague)




```
==========================================================================
🔬 Diagnostic des Résidus:
  • Homoscédasticité...: ⚠️
  • Normalité..........: ⚠️ Non-normaux
  • Autocorrélation....: ✅
```

3 Modelisation

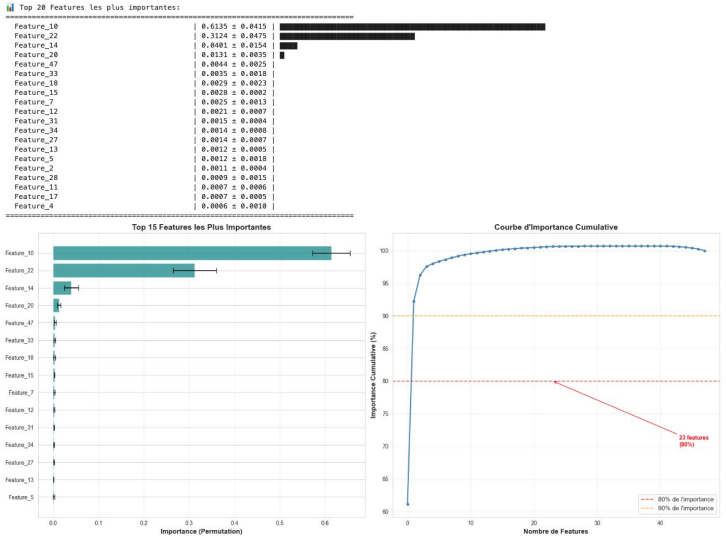
1. Initialisation du pré-pipeline
   Préparation des transformateurs (scaling, encodage, imputation).
2. Configuration du benchmark
   Définition des métriques (R^2, RMSE, MAE) et sélection des algorithmes candidats.
3. Benchmark des modèles : évaluation détaillée
   Entraînement initial et extraction des performances moyennes par validation croisée.
4. Entraînement Final et Test (Production Ready)
   FIT : Entraînement du modèle sélectionné sur la totalité du set d'entraînement (X_train). C'est ici que les poids du modèle sont fixés.
   PREDICT : Projection sur les données jamais vues (X_test) pour mesurer la capacité de généralisation réelle.
5. Analyse comparative et sélection du modèle optimal
   5.1 Analyse des courbes de validation (Étude du surapprentissage : biais vs variance).
   5.2 Inspection des résidus (Homoscédasticité et normalité des erreurs sur X_test
   5.3 Importance des Features (Quelles variables de Seattle influencent le plus la consommation ?).

Importance des Features

Permutation Importance (model-agnostic)
Top 20 Features (Texte) :
Domination absolue de deux variables (Noms à identifier) qui concentrent à elles seules près de 93% du pouvoir prédictif du modèle.

Top 15 features visualisées
Stabilité statistique satisfaisante (barres d'erreur courtes), confirmant que l'importance de ces variables est structurelle et non due au hasard des permutations.

Courbe cumulative (combien de features pour 80%?)
Pente extrêmement verticale ; le modèle est "paresseux" car il dépend d'un très petit nombre de variables pour expliquer la quasi-totalité du phénomène.




```
==========================================================================================
🎯 Insights sur les Features:
   • 23 features capturent 80% de l'importance
   • 23 features capturent 90% de l'importance
   • Total de features: 48
```

Q & A

Rafael CEREZO MARTIN

Décembre 2025