TECHNOVA
PARTNERS

Analyse des causes d'attrition TechNova Partners

Rafael CEREZO MARTIN

Janvier 2026

Objectifs du projet

Département demandeur : Ressources Humaines (RH)

Problématique : Taux de démission (turnover) anormalement élevé

Objectif principal : Identifier les causes racines des démissions et proposer des leviers actionnables

Interlocuteurs clés

- **Augustin Moser** - Responsable SIRH (fournit les données)
- **Amandine Rousset** - Manager Data Scientist (cadrage méthodologique)

Approche méthodologique

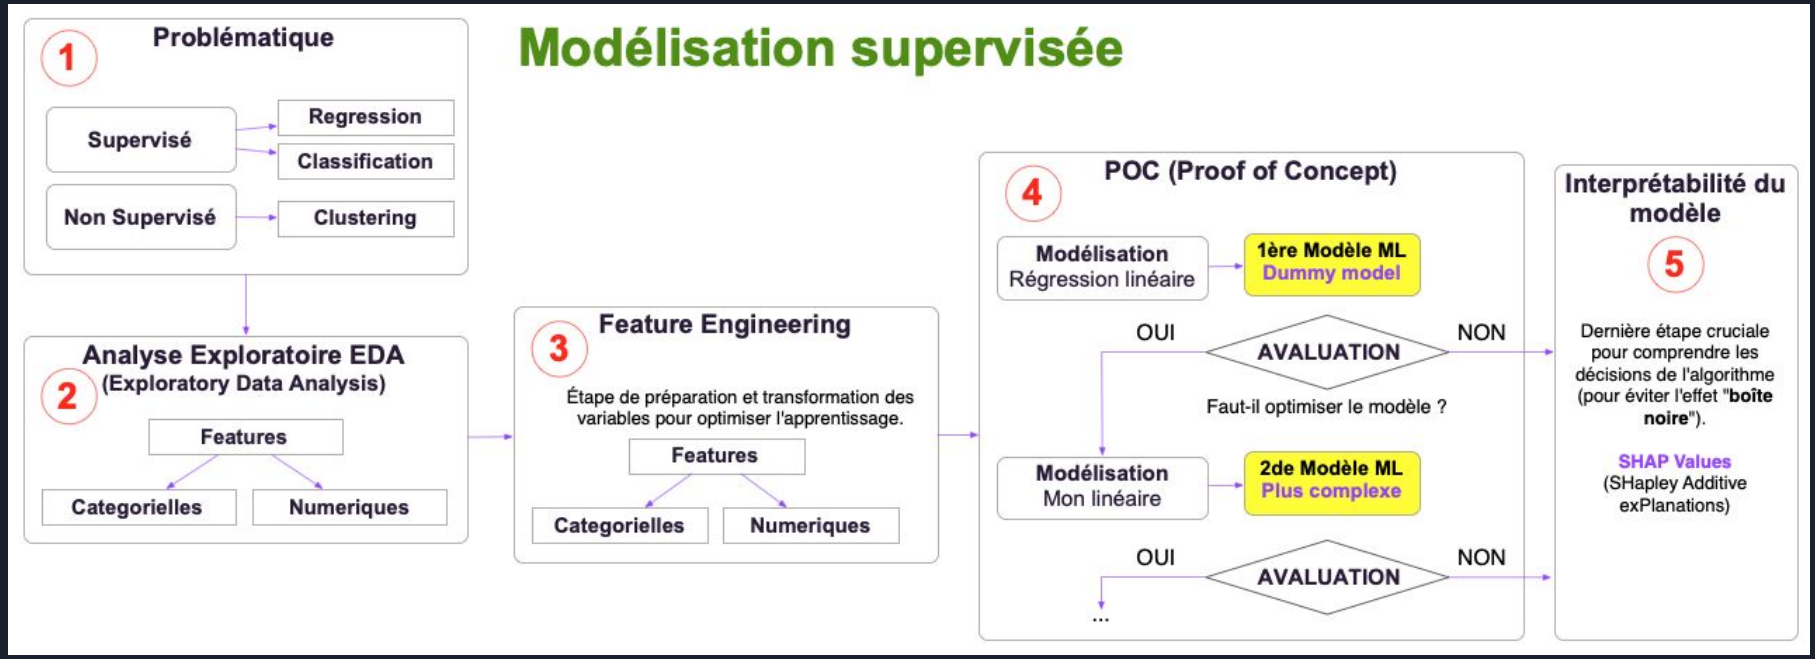
- **Analyse exploratoire** : Identifier différences entre employés partis vs restés
- **Modélisation prédictive** : Classification pour scorer probabilité de démission
- **Interprétabilité** : Extraction des causes via package SHAP

Données disponibles

3 fichiers CSV provenant de sources différentes :

1. **SIRH** : Fonction, âge, salaire, ancienneté, données sociodémographiques
2. **Évaluations de performance** : Notes d'évaluation, satisfaction
3. **Sondage bien-être** : Réponses annuelles + indicateur de départ (target)

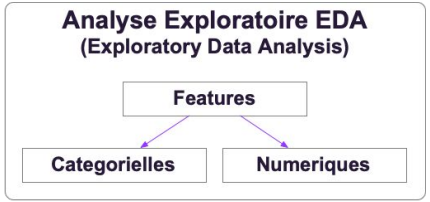
Etapes du Projet

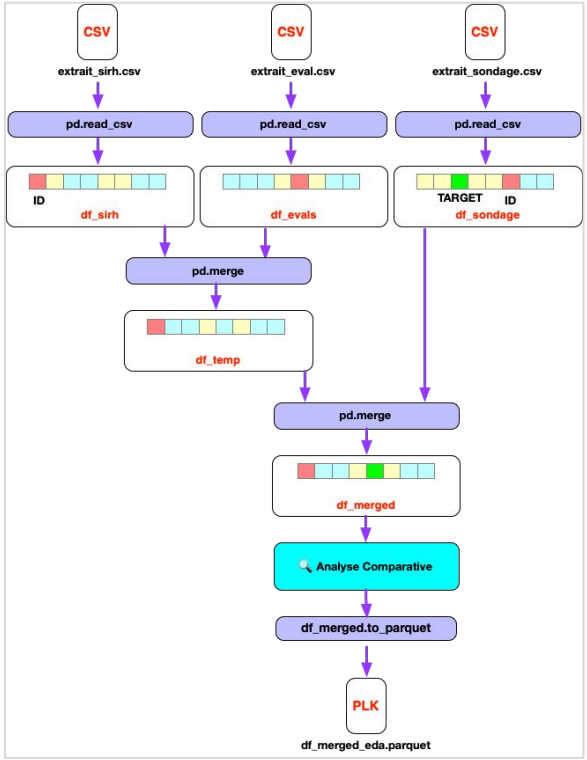


1 Analyse Exploratoire

ÉTAPE 1 : Nettoyage et exploration des données

1. **Compréhension des données (Verification & Audit)**
2. Générer des rapports (ydata profiling)
3. Fusion des fichiers (Consolidation avec Merge)
2. Générer rapport de la Consolidation (ydata profiling)
4. Analyse exploratoire





==========

Préparation de la cible (Target Cleaning)

```
# Conversion en binaire pour les calculs (1 = Parti, 0 = Resté)
df_merged['attrition_binary'] = df_merged['a_quitte_l_entreprise'].map({'Oui': 1, 'Non': 0})
print(df_merged['attrition_binary'].describe())
```

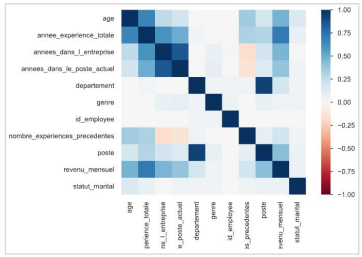
1 Analyse Exploratoire

ÉTAPE 1 : Nettoyage et exploration des données

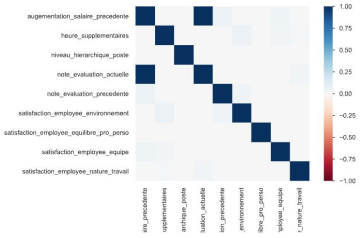
1. Compréhension des données (Verification & Audit)
2. **Générer des rapports (ydata profiling)**
3. Fusion des fichiers (Consolidation avec Merge)
2. Générer rapport de la Consolidation (ydata profiling)
4. Analyse exploratoire

Générer des rapports (ydata profiling)

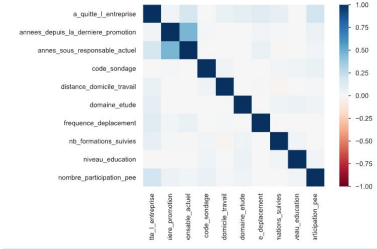
Profiling - extrait_sirh.csv



Profiling - extrait_eval.csv



Profiling - extrait_sondage.csv




```
================================================================================
print(f"🚀 Génération du rapport : {title}...")
profile = ProfileReport(df, title=title, explorative=True, html={"style": {"full_width": True}})
profile.to_file(report_path)
print(f"✨ Sauvegardé : {report_path}")
```

1 Analyse Exploratoire

ÉTAPE 1 : Nettoyage et exploration des données

1. Compréhension des données (Verification & Audit)
2. Générer des rapports (ydata profiling)
3. **Fusion des fichiers (Consolidation avec Merge)**
2. Générer rapport de la Consolidation (ydata profiling)
4. Analyse exploratoire

extrait_sirh.csv

id_employee	age	genre	revenu_mensuel	statut_marital	departement	poste
1	41	F	5993	Célibataire	Commercial	Cadre Commercial
2	49	M	5130	Marié(e)	Consulting	Assistant de Direction
4	37	M	2090	Célibataire	Consulting	Consultant

extrait_eval.csv

e_evaluation_precedente	veau_hierarchique_poste	employee_nature_travail	faction_employee_equipe	oyee_equilibre_pro_perso	eval_number	note_evaluation_actuelle
3	2	4	1	1	E_1	3
2	2	2	4	3	E_2	4
2	1	3	2	3	E_4	3

extrait_sondage.csv

a_quitte_l_entreprise	nombre_participation_pee	nb_formations_suivies	oyee_sous_responsabilite	code_sondage	distance_domicile_travail	niveau_education
Oui	0	0	1	000001	1	2
Non	1	3	1	000002	8	1
Oui	0	3	1	000004	2	2

```
================================================================================
Données perdues lors de la fusion en df_temp : 0
Données perdues lors de la fusion en df_merged : 0
✅ Fusion terminée. Dimensions finales : (1470, 35)
```

```
count    1470.000000
mean     1024.865306
std       602.024335
min         1.000000
25%       491.250000
50%      1020.500000
75%      1555.750000
max      2068.000000
Name: id_employee
```

```
count    1470.000000
mean     1024.865306
std       602.024335
min         1.000000
25%       491.250000
50%      1020.500000
75%      1555.750000
max      2068.000000
Name: code_sondage
```

```
count  1470.000000
mean   1024.865306
std     602.024335
min       1.000000
25%     491.250000
50%    1020.500000
75%    1555.750000
max    2068.000000
Name: eval_numeric
```

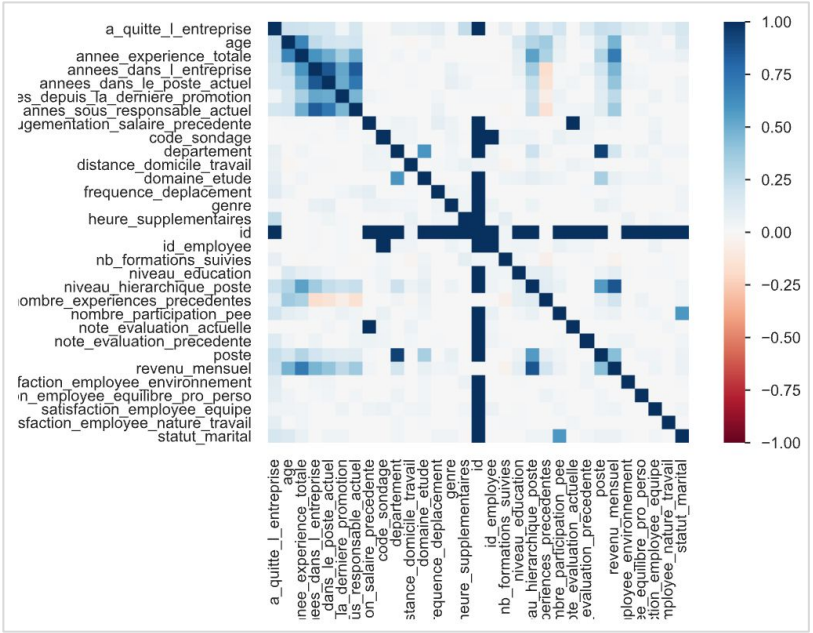
1 Analyse Exploratoire

ÉTAPE 1 : Nettoyage et exploration des données

1. Compréhension des données (Verification & Audit)
2. Générer des rapports (ydata profiling)
3. Fusion des fichiers (Consolidation avec Merge)
2. **Générer rapport de la Consolidation (ydata profiling)**
4. Analyse exploratoire

Générer rapport de la Consolidation (ydata profiling)

Profiling - Analyse Globale TechNova - Dataset Fusionné

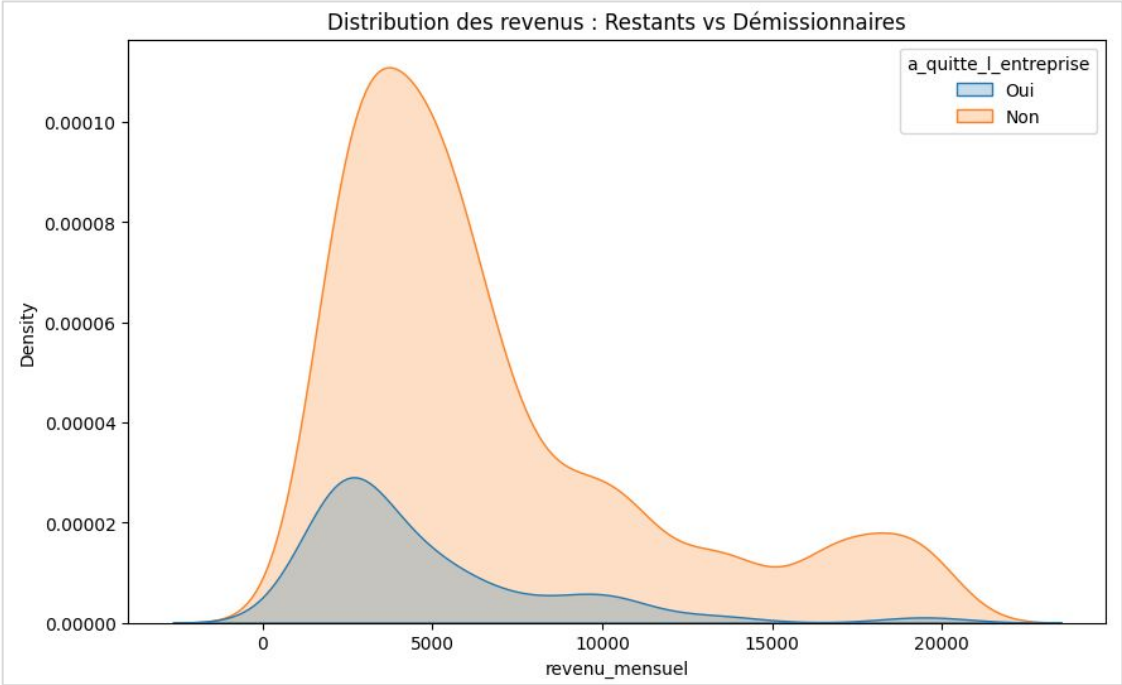



```
================================================================================
print(f"🚀 Génération du rapport : {title}...")
profile = ProfileReport(df, title=title, explorative=True, html={"style": {"full_width": True}})
profile.to_file(report_path)
print(f"✨ Sauvegardé : {report_path}")
```

1 Analyse Exploratoire

ÉTAPE 1 : Nettoyage et exploration des données

1. Compréhension des données (Verification & Audit)
2. Générer des rapports (ydata profiling)
3. Fusion des fichiers (Consolidation avec Merge)
2. Générer rapport de la Consolidation (ydata profiling)
4. **Analyse exploratoire**




```
================================================================================
# Exemple : Distribution du revenu mensuel par statut d'attrition
plt.figure(figsize=(10, 6))
sns.kdeplot(data=df_merged, x='revenu_mensuel', hue='a_quitte_l_entreprise', fill=True)
plt.title('Distribution des revenus : Restants vs Démissionnaires')
plt.show()
```

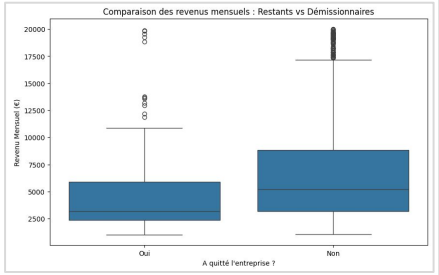
1 Analyse Exploratoire

ÉTAPE 1 : Nettoyage et exploration des données

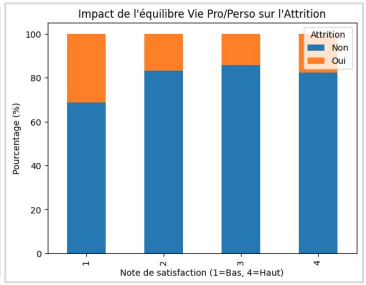
1. Compréhension des données (Verification & Audit)
2. Générer des rapports (ydata profiling)
3. Fusion des fichiers (Consolidation avec Merge)
2. Générer rapport de la Consolidation (ydata profiling)
4. **Analyse exploratoire**

Visualisations Comparatives

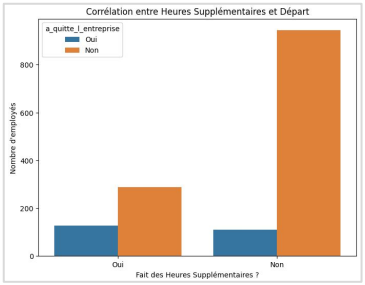
Le facteur financier (Revenu mensuel)



L'équilibre Vie Pro / Vie Perso (Satisfaction)



L'impact des longues journées (Heures Supplémentaires)



Le salaire est-il le facteur principal ?

La culture d'entreprise est-elle en cause ?

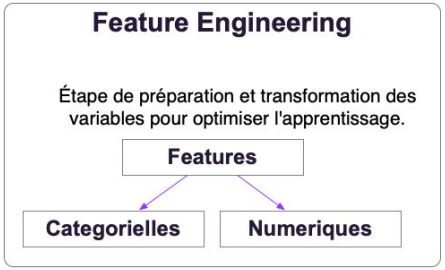
Les heures supplémentaires afecten le départ ?

```
================================================================================
plt.figure(figsize=(10, 6))
sns.boxplot(data=df_merged, x='a_quitte_l_entreprise', y='revenu_mensuel')
plt.title('Comparaison des revenus mensuels : Restants vs Démissionnaires')
plt.xlabel('A quitté l\'entreprise ?')
plt.ylabel('Revenu Mensuel (€)')
plt.show()
```

2 Feature Engineering

ÉTAPE 2 : Préparation des features pour la modélisation

1. Nettoyage Initial et Élimination
2. Codification Catégorielle
3. Codification Numérique
4. SPLIT X Y
5. PIPELINE pour Feature Engineering Initial
6. Enregistrer Union de Features et Target



- **Conversion de Percents**
- **Identification des Identifiants**
- **Identification des Constants**
- **Identification des Manquants Excessifs**

🗑️ **Suppression du Target Original**

```
cleaner.df = cleaner.df.drop(columns=["a_quitte_l_entreprise"])
```

```
--- 🗑️ COLUMNAS A SUPRIMIR (8) ---
  COLONNE                                  | ACTION/ENC          | NOTE / CONTENU
  ------------------------------------------------------------------------------------------
• a_quitte_l_entreprise                    | ❌ Suppresion        | VARIABLE CIBLE - Deja codifiqué dans la phase EDA
• id                                       | ❌ Suppresion        | Identifiant utilisé dans le merge
• id_employee                              | ❌ Suppresion        | Identifiant technique sans valeur prédictive (df_sirh)
• code_sondage                             | ❌ Suppresion        | Identifiant de sondage sans valeur prédictive (df_sondage)
• eval_number                              | ❌ Suppresion        | Identifiant de sondage sans valeur prédictive (evals)
• nombre_employee_sous_responsabilite      | ❌ Suppresion        | Constant
• nombre_heures_travailless                | ❌ Suppresion        | Constant
• ayant_enfants                            | ❌ Suppresion        | Constant
```

==========

✅ AUCUNE DONNÉE MANQUANTE DÉTECTÉE
Le dataset est complet. Le heatmap n'est pas nécessaire.

2 Feature Engineering

ÉTAPE 2 : Préparation des features pour la modélisation

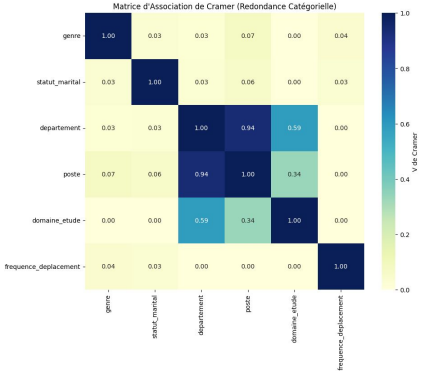
1. Nettoyage Initial et Élimination
2. **Codification Catégorielle**
3. Codification Numérique
4. SPLIT X Y
5. PIPELINE pour Feature Engineering Initial
6. Enregistrer Union de Features et Target

1. Identification des Catégorielles Redondants

1. **Table de contingence**
2. **Test du Khi-Deux > p-value < 0.05**
3. **Test de Cramér:** Force d'association > Threshold = 0.75 = Redondants

🧪 ANALYSE DE DÉPENDANCE (Test du Khi-Deux)
Cible : a_quitte_l_entreprise

COLONNE	P-VALUE	DÉPENDANCE	ÉTAT
• genre	2.9057e-01	NON	⚪ Faible/Nulle
• statut_marital	9.4555e-11	OUI	🟢 Forte
• departement	4.5256e-03	OUI	🟡 Significative
• poste	2.7525e-15	OUI	🟢 Forte
• domaine_etude	6.7740e-03	OUI	🟡 Significative
• frequence_deplacement	5.6086e-06	OUI	🟢 Forte



[('departement', 'poste', np.float64(0.9371276978654515))] Force d'association (Cramér's V)

🗑️ **Suppression des Colonnes Redondants**
COLS_REDONDANTS.append('departement')
Corrélée avec: "poste" Une **p-valeur** significativement **plus faible** implique une **capacité discriminante** bien **plus robuste**.

2. Identifier Transformations Catégorielles

--- 📦 CATEGORÍA TÉCNICA: CATEGORIQUES (6) ---

COLONNE	ACTIONENC	NOTE / CONTENU
• genre	✅ OneHotEncoding	F, M
• statut_marital	✅ OneHotEncoding	Célibataire, Divorcé(e), Marié(e)
• domaine_etude	✅ OneHotEncoding	Autre, Entrepreunariat, Infra & ...
• departement	❌ Suppression	(Categorical Correlation V de Cramer=0.94 avec 'poste') Département de travail
• poste	✅ OneHotEncoding	Assistant de Direction, Cadre Co...
• frequence_deplacement	✅ OneHotEncoding	Aucun, Frequent, Occasionnel

- OneHotEncoding
- BinaryEncoding"
- Target Encoding

```
================================================================================

cleaner.df, meta_dict_enrichi = cleaner.supprier_colonnes_REDONDANTS(df = cleaner.df,
   meta_dict     = meta_dict_enrichi,
   cols_to_remove = cleaner.COLS_REDONDANTS,
   reason="Categorical Correlation V de Cramer=0.94 avec 'poste'"
)
```

2 Feature Engineering

ÉTAPE 2 : Préparation des features pour la modélisation

1. Nettoyage Initial et Élimination
2. Codification Catégorielle
3. **Codification Numérique**
4. SPLIT X Y
5. PIPELINE pour Feature Engineering Initial
6. Enregistrer Union de Features et Target

1. Identification des Numériques Redondants

1. Choix de la métrique : Pearson vs Spearman

Type de Feature	Méthode conseillée	Pourquoi ?
Numérique Continue (Salaire, Âge)	**Pearson**	Pour les relations linéaires simples.
Numérique Ordinale (Satisfaction, Éducation)	**Spearman**	Pour respecter l'ordre sans supposer une linéarité.

2. Matrice de Corrélation
3. Analyse des Seuils et Arbitrage

🗑️ **Suppression des Colonnes Redondants**
`COLS_REDONDANTS.append('niveau_hierarchique_poste')`
Corrélée avec: “revenu_mensuel”



2. Identifier Transformations Numériques

```
🔍 ANALYSE ET SYNCHRONISATION DU BLUEPRINT NUMÉRIQUE
Colonne                                | Stratégie              | Métriques (Skew/CV)
-------------------------------------------------------------------------------------
satisfaction_employee_environnement    | 🔔 Standardize (RAS)    | Normal/Binaire/Orphan
annes_sous_responsable_actuel          | 🔔 Standardize (RAS)    | Normal/Binaire/Orphan
augementation_salaire_precedente       | 🔔 Standardize (RAS)    | Normal/Binaire/Orphan
niveau_education                       | 🔔 Standardize (RAS)    | Normal/Binaire/Orphan
age                                    | 🔔 Standardize (RAS)    | Normal/Binaire/Orphan
nombre_experiences_precedentes         | 🔔 Standardize (RAS)    | Normal/Binaire/Orphan
satisfaction_employee_equilibre_pro_perso | 🔔 Standardize (RAS)  | Normal/Binaire/Orphan
revenu_mensuel                         | 🚀 Log Transform        | Skew: 1.37
note_evaluation_precedente             | 🔔 Standardize (RAS)    | Normal/Binaire/Orphan
satisfaction_employee_equipe           | 🔔 Standardize (RAS)    | Normal/Binaire/Orphan
attrition_binary                       | 🔔 Standardize (RAS)    | Normal/Binaire/Orphan
annees_depuis_la_derniere_promotion    | 🚀 Log Transform        | Skew: 1.98
heure_supplementaires                  | 🔔 Standardize (RAS)    | Normal/Binaire/Orphan
annees_dans_le_poste_actuel            | 🔔 Standardize (RAS)    | Normal/Binaire/Orphan
note_evaluation_actuelle               | 🔔 Standardize (RAS)    | Normal/Binaire/Orphan
satisfaction_employee_nature_travail   | 🔔 Standardize (RAS)    | Normal/Binaire/Orphan
nombre_participation_pee               | 🔔 Standardize (RAS)    | Normal/Binaire/Orphan
nb_formations_suivies                  | 🔔 Standardize (RAS)    | Normal/Binaire/Orphan
annees_dans_l_entreprise               | 🚀 Log Transform        | Skew: 1.76
distance_domicile_travail              | 🔔 Standardize (RAS)    | Normal/Binaire/Orphan
annee_experience_totale                | 🚀 Log Transform        | Skew: 1.12
```

- Log Transform (Transformation Logarithmique)
- Scaling (Mise à l'échelle / Min-Max Scaling)
- RAS / Standardize (Standardisation)

```
================================================================================

cleaner.df, meta_dict_enrichi = cleaner.supprier_colonnes_REDONDANTS(df = cleaner.df,
   meta_dict     = meta_dict_enrichi,
   cols_to_remove = cleaner.COLS_REDONDANTS,
   reason=f"Numerical Correlation Pearson (Lineal) > {THRESHOLD_NUMERICAL_REDONDANCE} avec
{FEATURE_TARGET}"
)
```

2 Feature Engineering

ÉTAPE 2 : Préparation des features pour la modélisation

1. Nettoyage Initial et Élimination

2. Codification Catégorielle

3. Codification Numérique

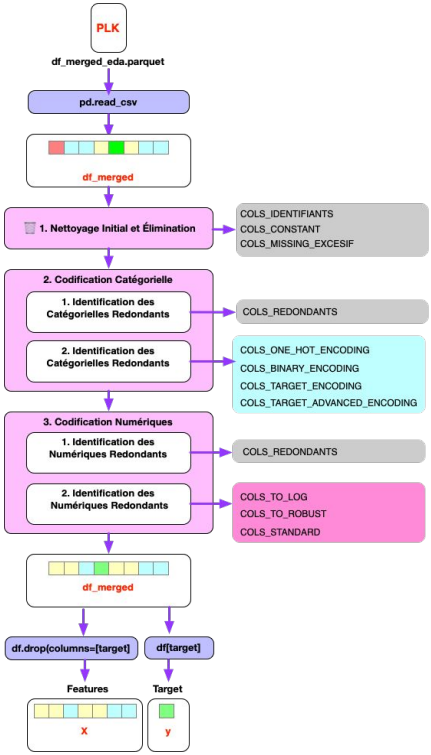
4. SPLIT X Y

5. PIPELINE pour Feature Engineering Initial

6. Enregistrer Union de Features et Target

WORKAROUND

Préparer un Pipeline pour réaliser le Feature Engineering




```
================================================================================

# Appel de la fonction
X, y = cleaner.pipeline_preparation_initiale(
    df           = cleaner.df,
    target       = FEATURE_TARGET,
    cols_to_drop = FEATURES_TO_REMOVE
)
```

2 Feature Engineering

ÉTAPE 2 : Préparation des features pour la modélisation

1. Nettoyage Initial et Élimination

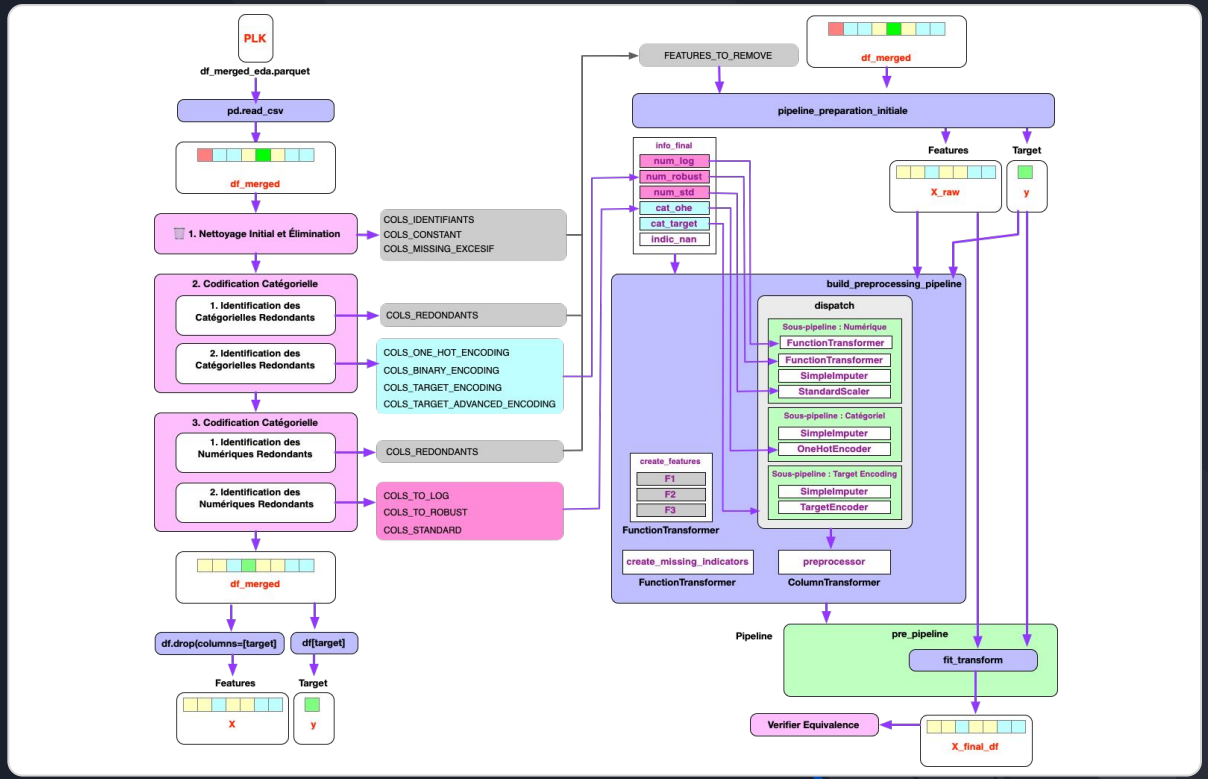
2. Codification Catégorielle

3. Codification Numérique

4. SPLIT X Y

5. PIPELINE pour Feature Engineering Initial

6. Enregistrer Union de Features et Target



Résultats attendus

- *Un DataFrame contenant vos features prêtes pour la modélisation (autrement dit : un DataFrame qui **peut être injecté dans une méthode fit()** de sklearn sans erreur)*
- *Un Pandas Series contenant votre colonne cible (traditionnellement appelée y).*
- *Idéalement, des fonctions Python permettant de réaliser les transformations …*

Le Pipeline applique ces calculs pour convertir les données brutes en chiffres optimisés

	n_log__revenu_mensuel	n_log__annee_experience_totale	n_log__annees_dans_l_entreprise	n_log__annees_depuis_la_derniere_promotion	n_std__age	n_std__nombre_experiences_precedentes
0	0.218262	-0.148970	0.178857	-0.974295	0.446350	2.125136
1	-0.017266	0.144921	0.777704	-0.116765	1.322365	-0.678049
2	-1.377263	-0.321469	-2.399329	-0.974295	0.008343	1.324226
3	-0.876523	-0.148970	0.511830	0.740765	-0.429664	-0.678049
4	-0.610308	-0.517031	-0.943749	0.384858	-1.086676	2.525591

2 Feature Engineering

ÉTAPE 2 : Préparation des features pour la modélisation

1. Nettoyage Initial et Élimination

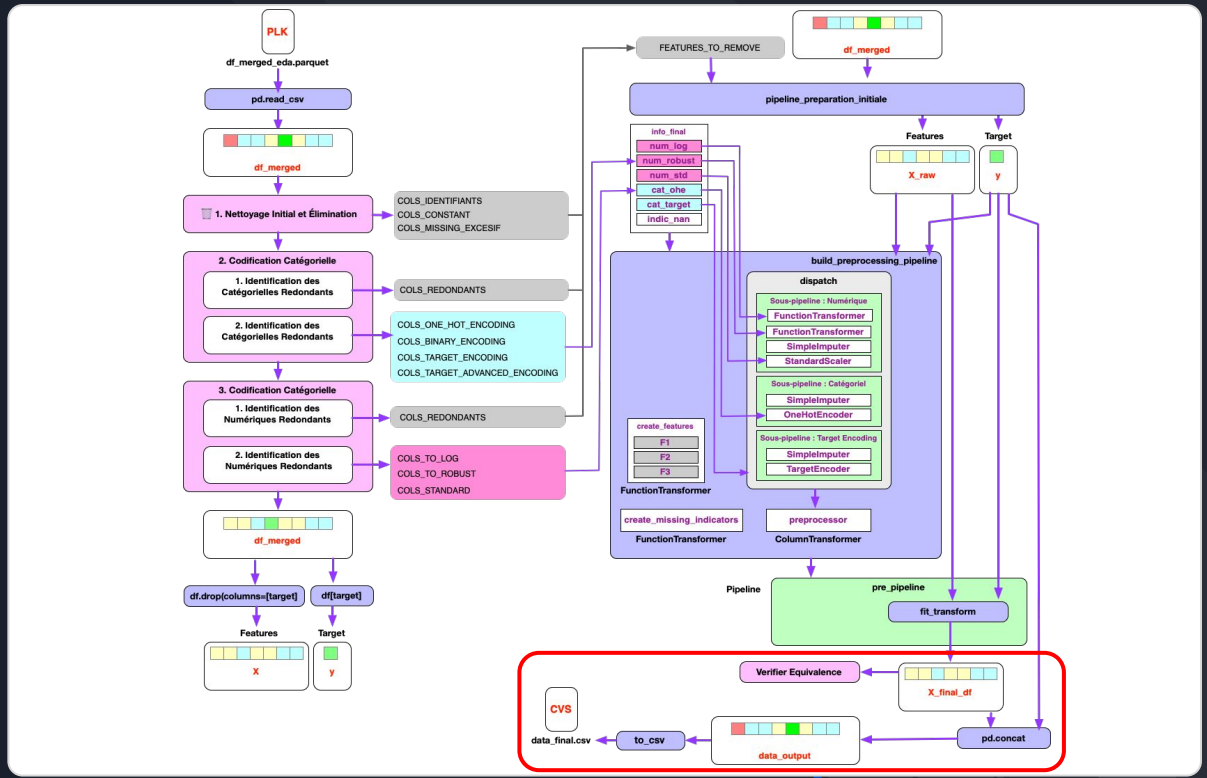
2. Codification Catégorielle

3. Codification Numérique

4. SPLIT X Y

5. PIPELINE pour Feature Engineering Initial

6. Enregistrer Union de Features et Target




```
================================================================================

data_output = pd.concat([X_final_df, y], axis=1)

✅ Matrice finale consolidée : 1470 lignes x 44 colonnes

output_path = PREPROCESED_DIR / "data_final.csv"
data_output.to_csv(output_path, index=False)
```

3 Modélisation V1

ÉTAPE 3 : Modélisation initiale (baseline)

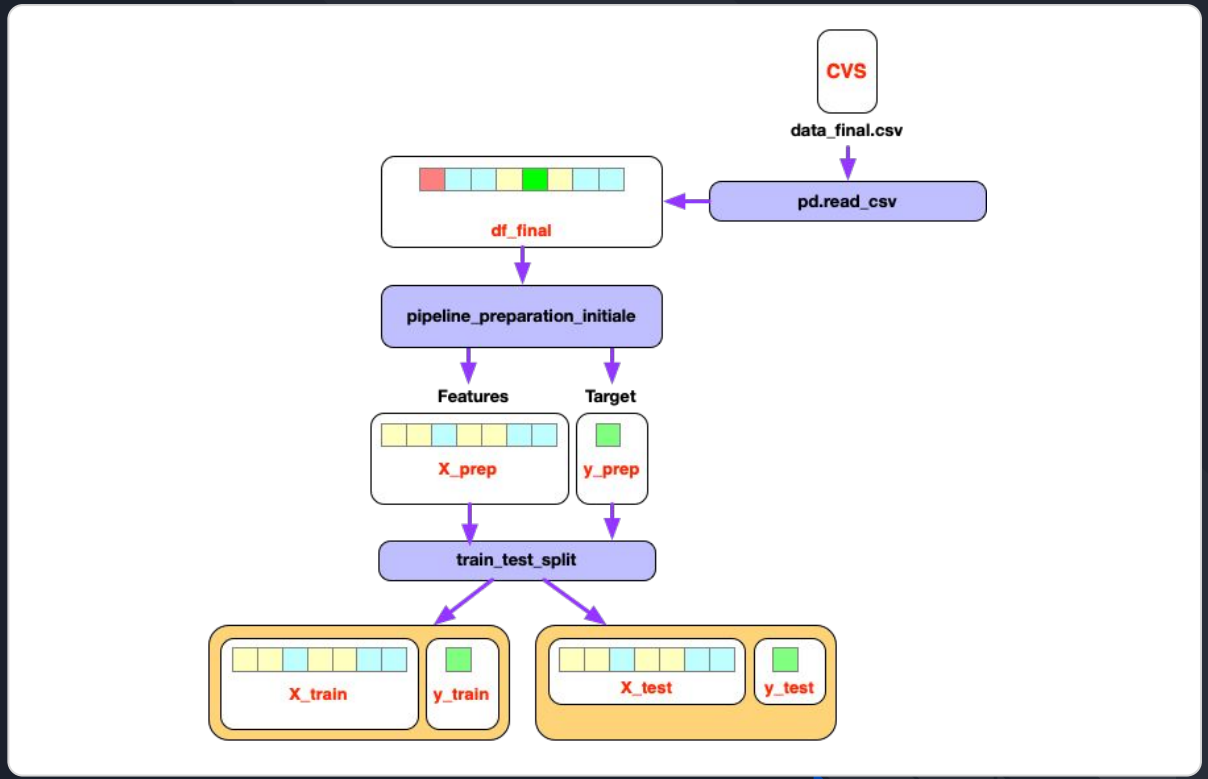
1. Split stratifié (prepare_train_test_split)

2. Initialisation du ClassificationModeler

3. Entraînements Individuels

4. Evaluation Individuels

5. Etude Comparatif




```
==========================================================================
BILAN DU PARTITIONNEMENT (TRAIN/TEST SPLIT)
==========================================================================
  Taille totale dataset.: 1470  lignes
  Ensemble Train........: 1176 lignes (80.0%)
  Ensemble Test.........: 294  lignes (20.0%)
  Variables prédictives.: 43
  Status................: ✅ Segmentation effectuée avec succès
==========================================================================
```

3 Modélisation V1

ÉTAPE 3 : Modélisation initiale (baseline)

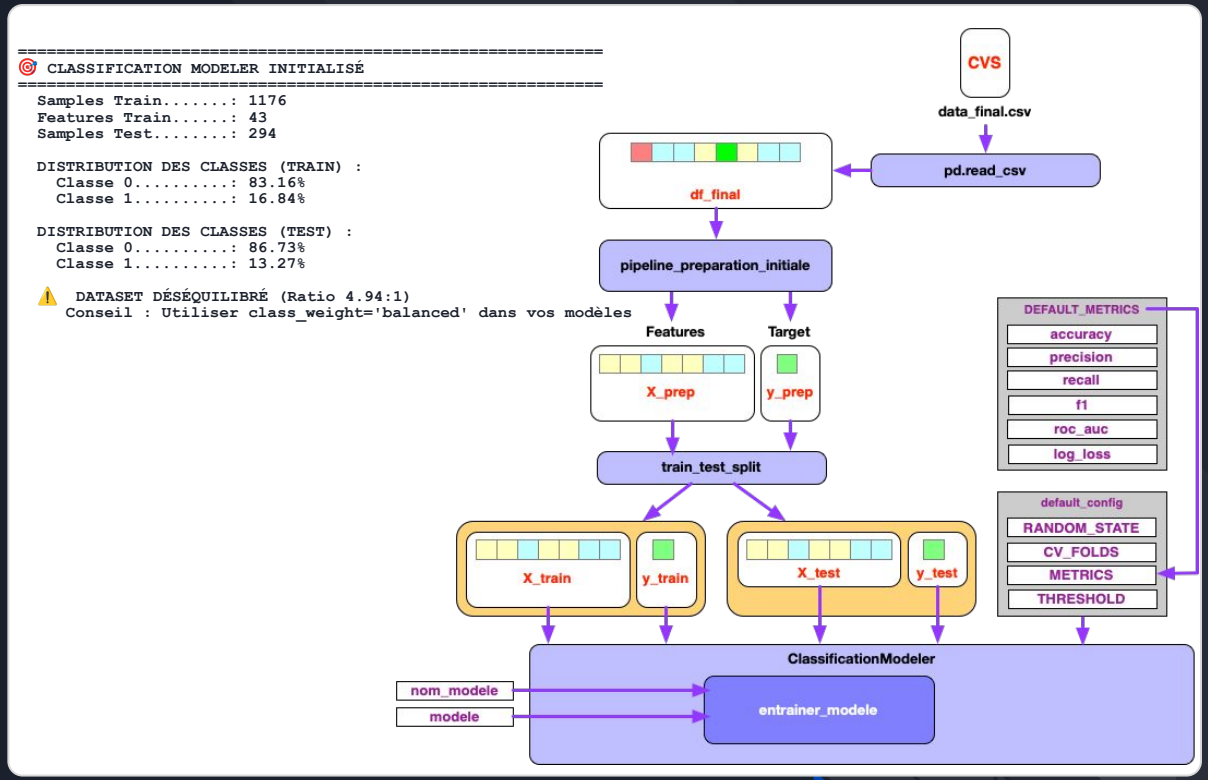
1. Split stratifié (prepare_train_test_split)
2. **Initialisation du ClassificationModeler**
3. Entraînements Individuels
4. Evaluation Individuels
5. Etude Comparatif

```
============================================================
🎯 CLASSIFICATION MODELER INITIALISÉ
============================================================
  Samples Train.......: 1176
  Features Train......: 43
  Samples Test........: 294

  DISTRIBUTION DES CLASSES (TRAIN) :
    Classe 0..........: 83.16%
    Classe 1..........: 16.84%

  DISTRIBUTION DES CLASSES (TEST) :
    Classe 0..........: 86.73%
    Classe 1..........: 13.27%

  ⚠️  DATASET DÉSÉQUILIBRÉ (Ratio 4.94:1)
     Conseil : Utiliser class_weight='balanced' dans vos modèles
```




```
================================================================================
  Random State........: 42
  CV Folds (Stratified): 5
  Seuil de Décision...: 0.5
  Métriques actives...: ['accuracy', 'precision', 'recall', 'f1', 'roc_auc', 'log_loss']
```

3 Modélisation V1

ÉTAPE 3 : Modélisation initiale (baseline)

1. Split stratifié (prepare_train_test_split)
2. Initialisation du ClassificationModeler
3. **Entraînements Individuels**
4. Evaluation Individuels
5. Etude Comparatif

Entraînements Individuels
(Modèles avec Hyperparamètres basiques)

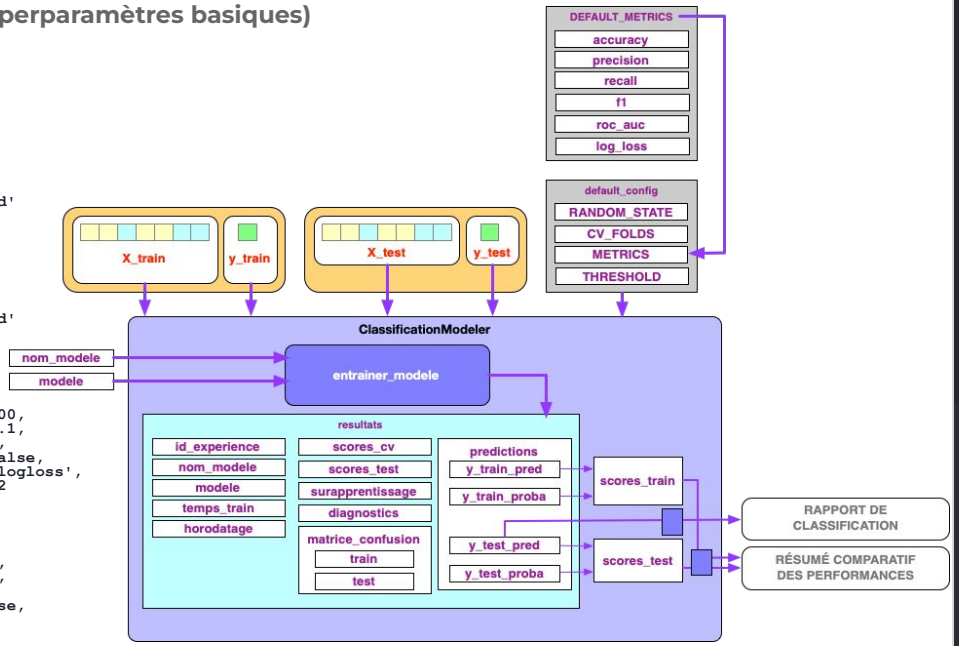
```
DummyClassifier(
  strategy='stratified'
)

LogisticRegression(
  max_iter=1000,
  class_weight='balanced'
)

RandomForestClassifier(
  n_estimators=100,
  class_weight='balanced'
)

XGBClassifier(
  n_estimators      = 100,
  learning_rate     = 0.1,
  max_depth         = 6,
  use_label_encoder = False,
  eval_metric       = 'logloss',
  random_state      = 42
)

CatBoostCompatible(
    iterations    = 100,
    learning_rate = 0.1,
    depth         = 6,
    verbose       = False,
    random_state  = 42
)
```



sklearn.metrics.classification_report(y_reel, y_predit, zero_division=0)

📊 RAPPORT DE CLASSIFICATION (Baseline_Aleatoire)

	precision	recall	f1-score	support
0	0.86	0.81	0.84	255
1	0.11	0.15	0.13	39
accuracy			0.72	294
macro avg	0.49	0.48	0.48	294
weighted avg	0.76	0.72	0.74	294

_afficher_resume(scores_train, scores_test) diff = v_train - v_test

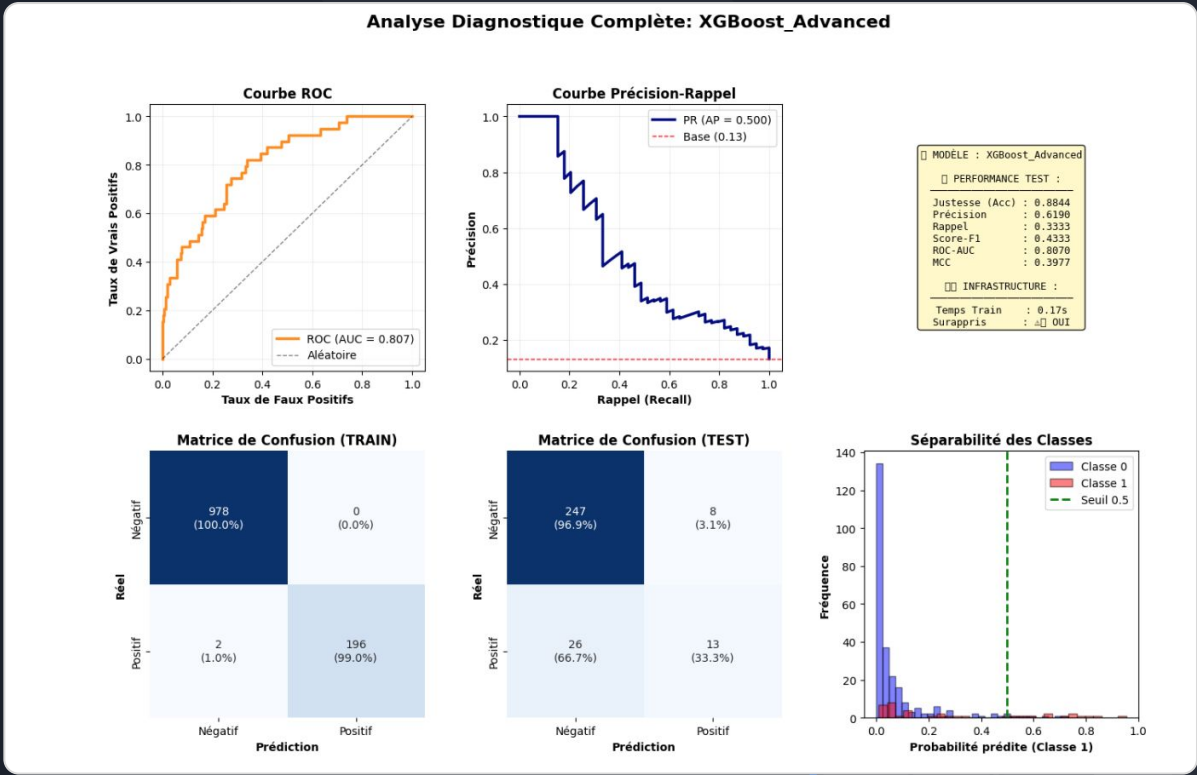
📊 RÉSUMÉ COMPARATIF DES PERFORMANCES

Métrique	Train	Test	Δ
ACCURACY	0.7092	0.7245	-0.0153
PRECISION	0.1505	0.1111	+0.0394
RECALL	0.1566	0.1538	+0.0027
F1	0.1535	0.1290	+0.0244
SPECIFICITE	0.8211	0.8118	+0.0093
ROC_AUC	0.5193	0.4296	+0.0897
MCC	-0.0220	-0.0301	+0.0081

3 Modélisation V1

ÉTAPE 3 : Modélisation initiale (baseline)

1. Split stratifié (prepare_train_test_split)
2. Initialisation du ClassificationModeler
3. Entraînements Individuels
4. **Evaluation Individuels**
5. Etude Comparatif

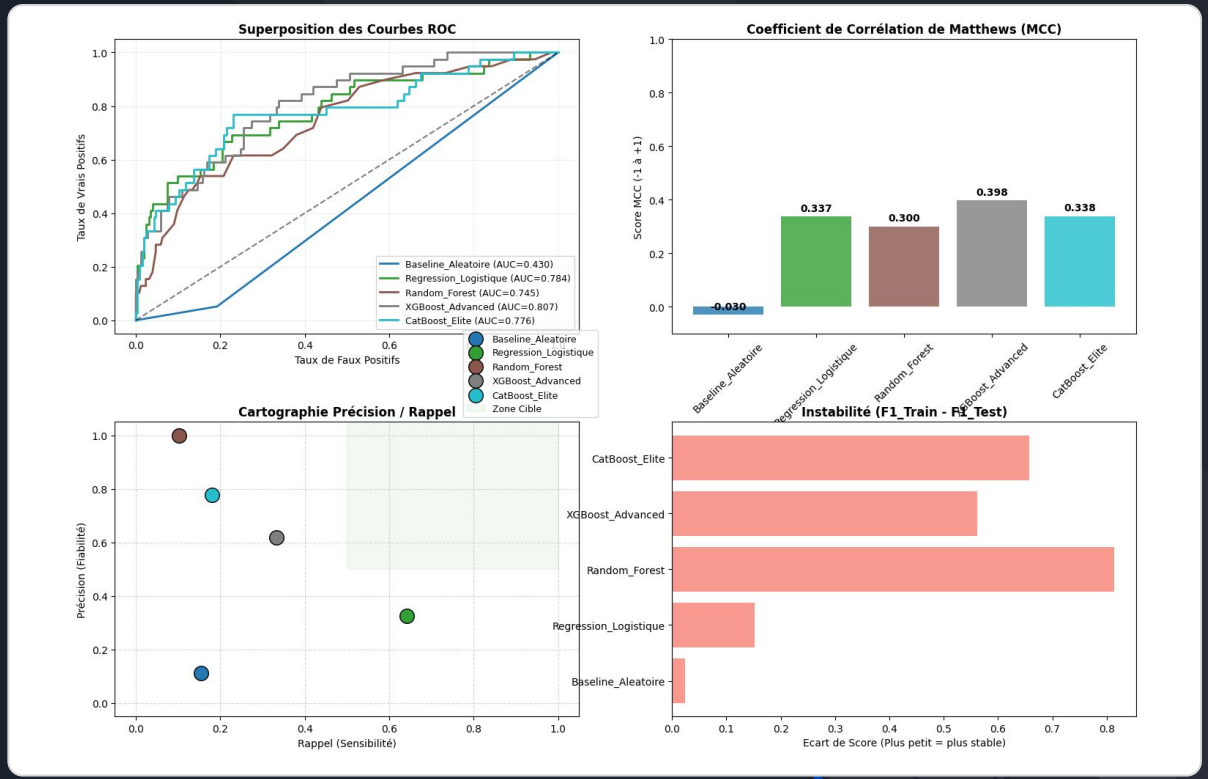



```
================================================================================
Analyse de la Capacité Prédictive (ROC & PR)
Diagnostic de l'Overfitting
Matrice de Confusion (Train / Test)
Séparabilité des Classes
```

3 Modélisation V1

ÉTAPE 3 : Modélisation initiale (baseline)

1. Split stratifié (prepare_train_test_split)
2. Initialisation du ClassificationModeler
3. Entraînements Individuels
4. Evaluation Individuels
5. **Etude Comparatif**



Rang	Modèle	Score-F1	Rappel	Précision	ROC-AUC	État
1 🏆	**XGBoost_Advanced**	**0,433**	33,3 %	0,619	**0,807**	⚠️ Overfit
2	**Regression_Logistique**	0,431	**64,1 %**	0,325	0,784	⚠️ Overfit
3	**CatBoost_Elite**	0,292	17,9 %	0,778	0,776	⚠️ Overfit
4	**Random_Forest**	0,186	10,3 %	**1,000**	0,745	⚠️ Overfit
5	**Baseline_Aleatoire**	0,129	15,4 %	0,111	0,430	✅ Stable

Superposition des Courbes ROC (En haut à gauche)
Mesurer la capacité de discrimination du modèle.

Coefficient de Corrélation de Matthews - MCC (En haut à droite)
Évaluer la qualité globale de la classification, surtout si les classes sont déséquilibrées.

Cartographie Précision / Rappel (En bas à gauche)
Visualiser l'arbitrage (Trade-off) entre la fiabilité et la quantité de détection.

Instabilité - F1_Train vs F1_Test (En bas à droite)
Détecter le Surapprentissage (Overfitting).

4 Modélisation avancée

ÉTAPE 4 : Modélisation avancée (gestion déséquilibre + optimisation)

1. Définir stratégie de modélisation

2. Validation croisée stratifiée

2.1 Feature Engineering

3. Entraînements Individuels

3.1 Utilisation du Score F-bêta

4. Etude Comparatif

5. Optimisation

5.1 Courbe Précision-Rappel et choix du seuil

5.2 Analyser feature importance (permutation)

5.3 Analyse des probabilités par type d'erreur

1. Les Probabilités de Prédiction

🎯 ANALYSE DU CONTEXTE MÉTIER

Type de problème : Prédiction d'attrition (démission)

- **Classe positive (1)** : Employé a quitté l'entreprise
- **Classe négative (0)** : Employé reste dans l'entreprise

Enjeux métier critiques :

Type d'erreur	Impact business	Coût
Faux Positif (FP)	Identifier à tort un employé comme "à risque" → Actions RH inutiles, stress inutile	**MODÉRÉ** (50-200€)
Faux Négatif (FN)	Ne pas détecter un employé qui va partir → Perte de talent, coût de recrutement/formation	**ÉLEVÉ** (5000-15000€)

⚠️ **CONCLUSION : Les FN coûtent 25-75× plus cher que les FP**

📐 1. Identification des Métriques d'évaluation prioritaires

Métrique	Priorité	Pourquoi ?
Recall 🔥	**HAUTE**	Capturer tous les employés à risque (minimiser FN)
Précision-Recall AUC 🔥	**HAUTE**	Meilleure que ROC-AUC pour classes déséquilibrées
F1-Score	MOYENNE	Équilibre, mais pas optimal si coût FN >> FP
F-beta (β=2) 🎯	**RECOMMANDÉ**	Pénalise 2× plus les FN que les FP
Courbe PR	HAUTE	Pour optimiser le seuil selon le contexte
MCC	MOYENNE	Robustesse globale
ROC-AUC	⚠️ BASSE	Trompeuse avec déséquilibre

Paramétrage du coefficient β

β	Effet	Usage
0.5	Plus de poids sur **Précision**	Minimiser FP prioritaire
1.0	Équilibre Précision-Rappel	F1 Score standard
2.0	Plus de poids sur **Rappel**	Minimiser FN prioritaire

```
f2_scorer = make_scorer(fbeta_score, beta=2)
```

⚖️ 2. Analyse du déséquilibre

📊 Stratégie de modélisation recommandé
• SMOTE (Library imblearn.over_sampling)

Critères de choix

Situation	Variante recommandée	Raison
Classes déséquilibrées (classification)	**StratifiedKFold**	Garantir représentativité
Données temporelles séquentielles	**TimeSeriesSplit**	Respecter chronologie
Question : 1 ou N modèles ?	**LeaveOneGroupOut**	Test exploratoire
Features déséquilibrées	**StratifiedKFold** sur feature	Éviter biais apprentissage
Données indépendantes, équilibrées	**KFold standard**	Cas simple

```
cv_stratifie = StratifiedKFold(n_splits=5, shuffle=True, random_state=42)
```

```
============================================================
🔍 Distribution de la cible (attrition_binary):
attrition_binary
0    1233
1     237
Name: count, dtype: int64
📊 Distribution relative:
attrition_binary
0    0.838776
1    0.161224
Name: proportion, dtype: float64
⚠️ Ratio de déséquilibre: 5.20:1
   SMOTE Counter y_train_smote: Counter({0: 1233, 1: 237})
```

```
==========================================
Employés qui restent à leur poste (Classe 0)
Employés qui restent à leur poste (Classe 1) Minoritaire


# Avant SMOTE, le Counter affichait un déséquilibre
(ex: {0: 1233, 1: 237}).

# Après l'exécution, on a une distribution parfaitement équilibrée
(ex: {0:  924, 1: 924}).
```

4 Modélisation avancée

ÉTAPE 4 : Modélisation avancée (gestion déséquilibre + optimisation)

1. Définir stratégie de modélisation

2. Validation croisée stratifiée

2.1 Feature Engineering

3. Entraînements Individuels

3.1 Utilisation du Score F-bêta

4. Etude Comparatif

5. Optimisation

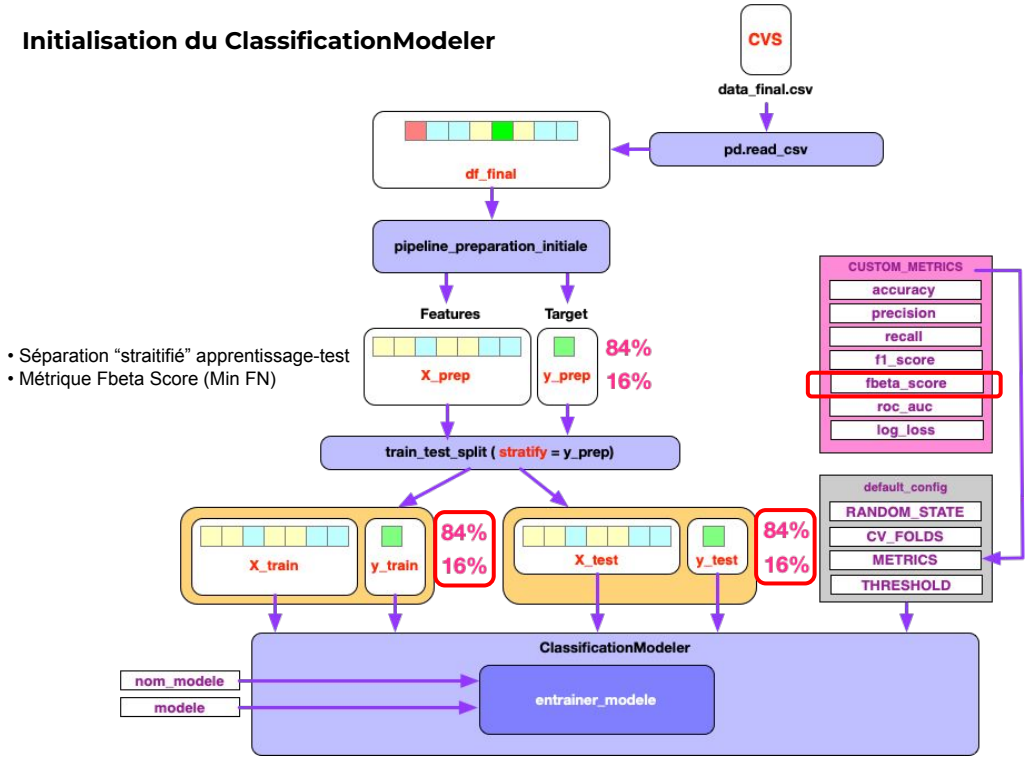
5.1 Courbe Précision-Rappel et choix du seuil

5.2 Analyser feature importance (permutation)

5.3 Analyse des probabilités par type d'erreur

1. Les Probabilités de Prédiction

Initialisation du ClassificationModeler




```
================================================================================
# ✅ UTILISATION DE train_test_split AVEC STRATIFICATION
X_train, X_test, y_train, y_test = train_test_split(
    X_prep, y_prep,
    test_size=0.25,           # 25% pour le test (règle standard)
    stratify=y_prep,          # ⚠️ CRUCIAL : préserve la distribution des classes
    random_state=42,          # Reproductibilité
    shuffle=True              # Mélange avant split
)
📊 Vérification de la stratification :
   Dataset complet.....: {0: 0.8387755102040816, 1: 0.16122448979591836}
   Train set...........: {0: 0.838475499092559,  1: 0.16152450090744103}
   Test set............: {0: 0.8396739130434783, 1: 0.16032608695652173}
```

4 Modélisation avancée

ÉTAPE 4 : Modélisation avancée (gestion déséquilibre + optimisation)

1. Définir stratégie de modélisation
2. Validation croisée stratifiée
   - **2.1 Feature Engineering**
3. Entraînements Individuels
   - 3.1 Utilisation du Score F-bêta
4. Etude Comparatif
5. Optimisation
   - 5.1 Courbe Précision-Rappel et choix du seuil
   - 5.2 Analyser feature importance (permutation)
   - 5.3 Analyse des probabilités par type d'erreur
     - 1. Les Probabilités de Prédiction

⭐ FEATURE ENGINEERING

Nom de la Feature	Formule Mathématique	Définition & Logique Métier
`fe1_ratio_stagnation`	$\frac{\text{Promotions}}{\text{Ancienneté}+1}$	**Score de Stagnation** : Mesure la proportion de la carrière dans l'entreprise passée sans promotion. Un score élevé indique un blocage de carrière.
`fe2_stabilite_manager`	$\frac{\text{Années sous Responsable}}{\text{Années Poste Actuel}+1}$	**Lassitude Managériale** : Si proche de 1, l'employé n'a pas changé de manager malgré son ancienneté dans le poste, ce qui peut freiner le renouvellement des idées.
`fe3_indice_job_hopping`	$\frac{\text{Expérience Totale}}{\text{Nb Entreprises Précédentes}+1}$	**Indice "Zappeur"** : Un score bas indique un profil qui change très souvent d'entreprise (instabilité chronique).
`fe4_anciennete_relative`	$\frac{\text{Ancienneté Entreprise}}{\text{Âge}-18}$	**Fidélité Relative** : Proportion de la vie active passée au sein de l'organisation. Mesure l'attachement historique de l'employé à l'entreprise.
`fe5_satisfaction_globale`	$mean(\text{Satisfaction_cols})$	**Vision Holistique** : Moyenne agrégée des scores de satisfaction (environnement, travail, équipe, équilibre). Donne l'état moral général du salarié.
`fe6_risque_overwork`	$\text{Heures Sup} \times \frac{1}{\text{Équilibre Pro}+2}$	**Risque de Burn-out** : Combine une forte charge de travail avec un mauvais équilibre vie pro/vie perso. C'est un indicateur de tension extrême.
`fe7_penibilite_trajet`	$\text{Heures Sup} \times \text{Distance Domicile}$	**Pénibilité Logistique** : Cumul de la fatigue liée aux heures supplémentaires et de la distance géographique. Facteur de lassitude physique.
`fe8_valeur_experience`	$\frac{\text{Revenu Mensuel}}{\text{Expérience Totale}+1}$	**Équité Perçue** : Analyse si le salaire est à la hauteur de l'expérience globale du salarié. Un ratio bas peut générer un sentiment d'injustice salariale.

```
================================================================================
✅ Features avant (X_train)......: 43 colonnes
✅ Features avant (X_train)......: 43 colonnes
✅ Features après (X_train)......: 51 colonnes
✅ Nouvelles Features (8)......: ['fe1_ratio_stagnation', 'fe2_stabilite_manager',
'fe3_indice_job_hopping', 'fe4_anciennete_relative', 'fe5_satisfaction_globale',
'fe6_risque_overwork', 'fe7_penibilite_trajet', 'fe8_valeur_experience']
```

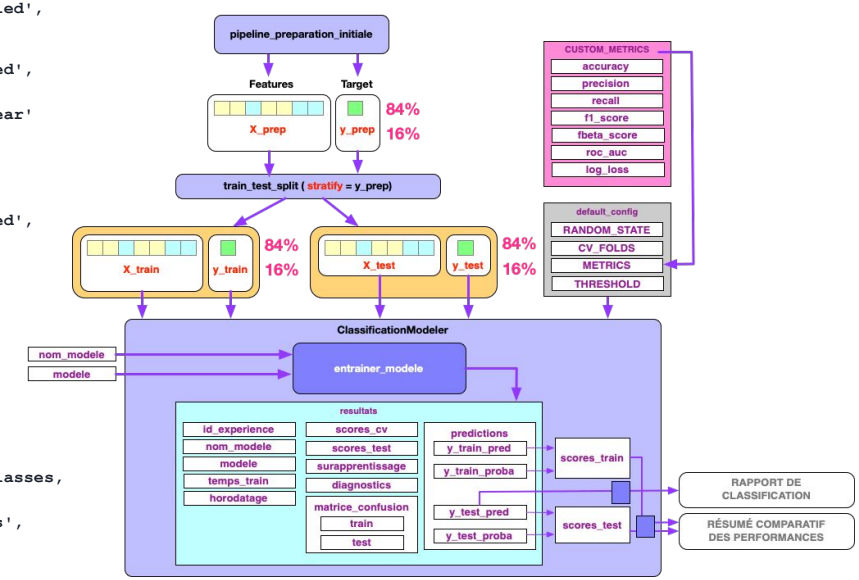
4 Modélisation avancée

ÉTAPE 4 : Modélisation avancée (gestion déséquilibre + optimisation)

1. Définir stratégie de modélisation
2. Validation croisée stratifiée
   - 2.1 Feature Engineering
3. **Entraînements Individuels**
   - **3.1 Utilisation du Score F-bêta**
4. Etude Comparatif
5. Optimisation
   - 5.1 Courbe Précision-Rappel et choix du seuil
   - 5.2 Analyser feature importance (permutation)
   - 5.3 Analyse des probabilités par type d'erreur
     - 1. Les Probabilités de Prédiction

Entraînements Individuels
(Modèles avec HyperParamètres modifiés)

```
DummyClassifier(
  strategy          = 'stratified',
  random_state      = 42
)
LogisticRegression(
  class_weight      = 'balanced',
  max_iter          = 1000,
  random_state      = 42,
  solver            = 'liblinear'
)
RandomForestClassifier(
  n_estimators      = 200,
  max_depth         = 10,
  min_samples_split = 20,
  min_samples_leaf  = 10,
  class_weight      = 'balanced',
  random_state      = 42,
  n_jobs            = -1
)
GradientBoostingClassifier(
  n_estimators      = 150,
  learning_rate     = 0.1,
  max_depth         = 5,
  min_samples_split = 20,
  min_samples_leaf  = 10,
  random_state      = 42
)
XGBClassifier(
  n_estimators      = 200,
  max_depth         = 6,
  learning_rate     = 0.05,
  min_child_weight  = 3,
  scale_pos_weight  = ratio_classes,
  random_state      = 42,
  use_label_encoder = False,
  eval_metric       = 'logloss',
  n_jobs            = -1
)
RandomForestClassifier(
  n_estimators      = 200,
  max_depth         = 10,
  random_state      = 42,
  n_jobs            = -1
)
```



📊 RAPPORT DE CLASSIFICATION (LogisticReg_Balanced)

	precision	recall	f1-score	support
0	0.92	0.83	0.87	309
1	0.40	0.61	0.48	59
accuracy			0.79	368
macro avg	0.66	0.72	0.68	368
weighted avg	0.83	0.79	0.81	368

📊 RÉSUMÉ COMPARATIF DES PERFORMANCES

Métrique	Train	Test	Δ
ACCURACY	0.8022	0.7908	+0.0114
PRECISION	0.4408	0.4000	+0.0408
RECALL	0.8371	0.6102	+0.2269
F1	0.5775	0.4832	+0.0943
F2	0.7095	0.5521	+0.1574
SPECIFICITE	0.7955	0.8252	-0.0298
ROC_AUC	0.8846	0.8028	+0.0818
MCC	0.5048	0.3717	+0.1331

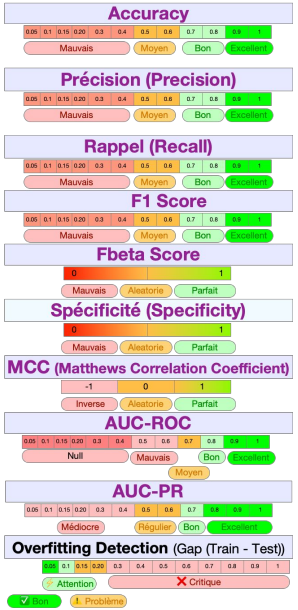
4 Modélisation avancée

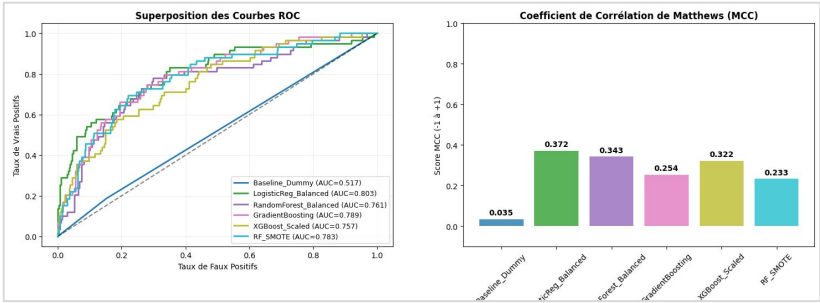
ÉTAPE 4 : Modélisation avancée (gestion déséquilibre + optimisation)

1. Définir stratégie de modélisation
2. Validation croisée stratifiée
   - 2.1 Feature Engineering
3. Entraînements Individuels
   - 3.1 Utilisation du Score F-bêta
4. **Etude Comparatif**
5. Optimisation
   - 5.1 Courbe Précision-Rappel et choix du seuil
   - 5.2 Analyser feature importance (permutation)
   - 5.3 Analyse des probabilités par type d'erreur
     - 1. Les Probabilités de Prédiction

Meilleur Modèle

LogisticRegression (Trié par Rappel)






```
================================================================================================================
📊 COMPARAISON DES MODÈLES (trié par Score-F2)
================================================================================================================

                     Modèle  Temps (s) Surappris  Expérience  Justesse  Précision   Rappel  Score-F1  F1 (CV)  Score-F2  ROC-AUC  Log-Loss Rang
LogisticReg_Balanced          0.015078          ✅           3  0.790761   0.400000 0.610169  0.483221 0.519661  0.552147 0.802754  0.453579    🏆
RandomForest_Balanced         0.532869          ❗           4  0.820652   0.442623 0.457627  0.450000 0.522219  0.454545 0.761286  0.455847
       XGBoost_Scaled         0.385099          ❗           6  0.842391   0.513514 0.322034  0.395833 0.512540  0.347985 0.757336  0.422159
            RF_SMOTE          1.045026          ❗           7  0.858696   0.684211 0.220339  0.333333 0.942475  0.254902 0.785750  0.374472
    GradientBoosting          2.457537          ❗           5  0.842391   0.521739 0.203390  0.292683 0.454802  0.231660 0.788547  0.467336
       Baseline_Dummy         0.001512          ✅           2  0.741848   0.189655 0.186441  0.188034 0.139898  0.187075 0.517169  9.304747

🏆 Meilleur modèle : LogisticReg_Balanced (Score-F2 = 0.5521)
================================================================================================================
```

```
================================================================================================================
📊 COMPARAISON DES MODÈLES (trié par F1)
================================================================================================================

                     Modèle  F1 (CV)  Justesse  Précision   Rappel  Score-F1  Spécificité  ROC-AUC       MCC  Temps (s) Surappris  Expérience Rang
       XGBoost_Advanced      0.422315  0.884354   0.619048 0.333333  0.433333     0.968627 0.807039  0.397706  0.324992          ❗           4    🏆
Regression_Logistique        0.553371  0.775510   0.324675 0.641026  0.431034     0.796078 0.783811  0.337219  0.036997          ❗           2
       CatBoost_Elite        0.432404  0.884354   0.777778 0.179487  0.291667     0.992157 0.775767  0.337977  0.747775          ❗           5
        Random_Forest        0.264986  0.880952   1.000000 0.102564  0.186047     1.000000 0.744646  0.300309  0.442003          ❗           3
    Baseline_Aleatoire       0.191326  0.724490   0.111111 0.153846  0.129032     0.811765 0.429563 -0.030125  0.000996          ✅           1

================================================================================================================
🏆 Meilleur modèle : XGBoost_Advanced (F1 = 0.4333)
================================================================================================================
```

```
# ____________________________________________________
# CUSTOM_METRICS = {
#     'accuracy' : 'accuracy',
#     'precision': make_scorer(precision_score , average='binary', zero_division=0),
#     'recall'   : make_scorer(recall_score    , average='binary', zero_division=0),
#     'f1'       : make_scorer(f1_score        , average='binary', zero_division=0),
#     'f2'       : make_scorer(fbeta_score     , average='binary', zero_division=0, beta=2  ),
#     'roc_auc'  : 'roc_auc',
#     'log_loss' : 'neg_log_loss'
# }

df_resultados = modeler.comparer_modeles_with_custom_metrics(trier_par='f2', custom_metrics=CUSTOM_METRICS)
```

4 Modélisation avancée

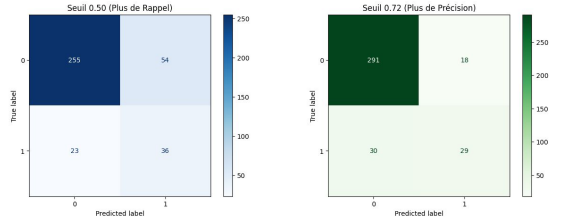
ÉTAPE 4 : Modélisation avancée (gestion déséquilibre + optimisation)

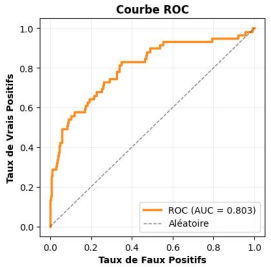
1. Définir stratégie de modélisation
2. Validation croisée stratifiée
   - 2.1 Feature Engineering
3. Entraînements Individuels
   - 3.1 Utilisation du Score F-bêta
4. Etude Comparatif
5. **Optimisation**
   - **5.1 Courbe Précision-Rappel et choix du seuil**
   - 5.2 Analyser feature importance (permutation)
   - 5.3 Analyse des probabilités par type d'erreur
     - 1. Les Probabilités de Prédiction

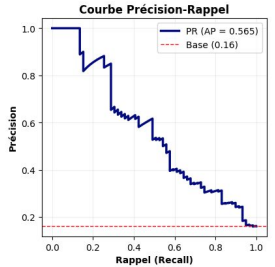
1. Matrices de Confusion (Bas) (Seuils 0.50 / 0.72)
Comparaison des Stratégies Opérationnelles

2. Courbe ROC (Haut - Gauche)
Performance Globale du Modèle (AUC : 0.80)

3. Courbe Précision-Rappel (Haut - Droite)
Fiabilité des Alertes vs Courbure des Risques







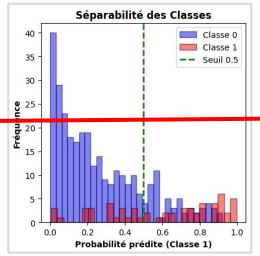
Choix du seuil a travers de une fonction:

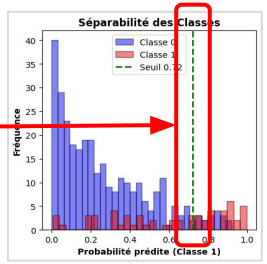
```
def trouver_seuil_optimal(y_true, y_probs):
    meilleur_seuil = 0.5
    meilleur_f1    = 0

    # On teste 100 seuils différents entre 0.1 et 0.9
    for seuil in np.linspace(0.1, 0.9, 100):
        y_pred = (y_probs >= seuil).astype(int)
        score  = f1_score(y_true, y_pred)

        if score > meilleur_f1:
            meilleur_f1    = score
            meilleur_seuil = seuil

    return meilleur_seuil
```





💡 **Seuil optimal trouvé : 0.72**

Seuil 0.50 (Approche Préventive) : On détecte 36 départs, mais on mobilise RH pour 54 personnes qui ne seraient finalement pas parties.

Seuil 0.72 (**Approche Ciblée**) : On réduit les erreurs de diagnostic de 66% (de 54 à 18), rendant l'action RH beaucoup plus efficace et crédible.

📊 RAPPORT DE CLASSIFICATION (LogisticReg_Balanced)

	precision	recall	f1-score	support
0	0.92	0.83	0.87	309
1	0.40	0.61	0.48	59
accuracy			0.79	368
macro avg	0.66	0.72	0.68	368
weighted avg	0.83	0.79	0.81	368

✨ Nouveau bilan pour LogisticReg_Balanced (Seuil 0.72)

	precision	recall	f1-score	support
0	0.91	0.94	0.92	309
1	0.62	0.49	0.55	59
accuracy			0.87	368
macro avg	0.76	0.72	0.74	368
weighted avg	0.86	0.87	0.86	368

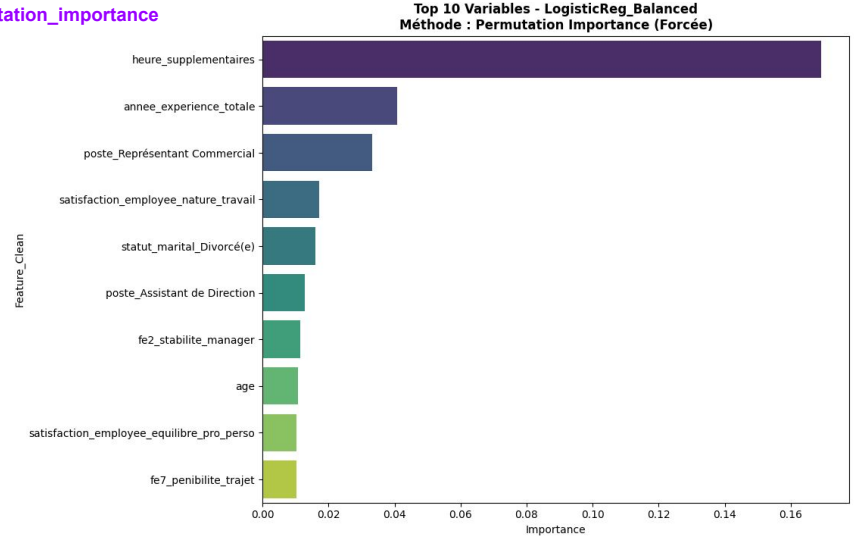
4 Modélisation avancée

ÉTAPE 4 : Modélisation avancée (gestion déséquilibre + optimisation)

1. Définir stratégie de modélisation
2. Validation croisée stratifiée
   - 2.1 Feature Engineering
3. Entraînements Individuels
   - 3.1 Utilisation du Score F-bêta
4. Etude Comparatif
5. Optimisation
   - 5.1 Courbe Précision-Rappel et choix du seuil
   - **5.2 Analyser feature importance (permutation)**
   - 5.3 Analyse des probabilités par type d'erreur
     - 1. Les Probabilités de Prédiction

Analyser feature importance (permutation)

Feature importance "Globale"
Méthode Model Agnostic: permutation_importance



CUSTOM FUNCTION POUR ANALYSER FEATURE IMPORTANCE:

- method == 'permutation' r = permutation_importance importances = r.importances_mean
- hasattr(instance, 'feature_importances_') importances = instance.feature_importances_
- hasattr(instance, 'coef_') importances = np.abs(instance.coef_[0])

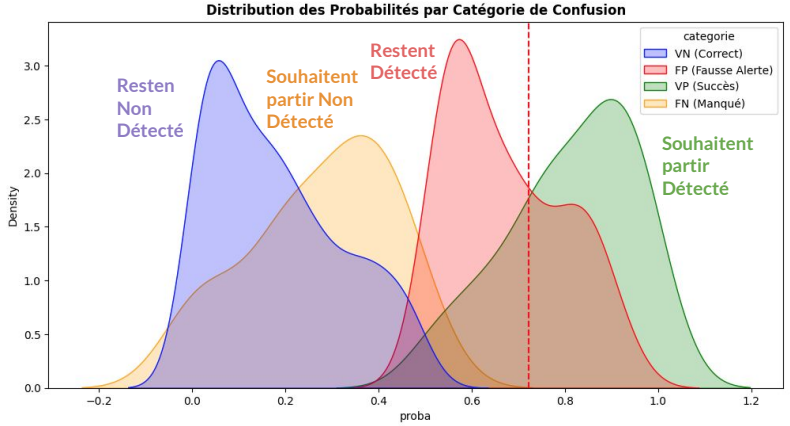
```
================================================================================
top_N_features = analyser_importance_features_by_method(
    X       = X_test,
    y       = y_test,
    top_n   = 10,
    scoring = 'f2',
    method  = 'permutation'
)
```

4 Modélisation avancée

ÉTAPE 4 : Modélisation avancée (gestion déséquilibre + optimisation)

1. Définir stratégie de modélisation
2. Validation croisée stratifiée
   - 2.1 Feature Engineering
3. Entraînements Individuels
   - 3.1 Utilisation du Score F-bêta
4. Etude Comparatif
5. Optimisation
   - 5.1 Courbe Précision-Rappel et choix du seuil
   - 5.2 Analyser feature importance (permutation)
   - **5.3 Analyse des probabilités par type d'erreur**
     - 1. Les Probabilités de Prédiction

Analyse de la distribution des probabilités (VP, FP, FN, VN)



ID's des 22 employés identifiés

Top Feature Importance

Liste d'intervention pour le département RH

LISTE D'INTERVENTION RH (Noms nettoyés)

	Probabilité (%)	heure_supplementaires	annee_experience_totale	poste_Représentant Commercial	satisfaction_employee_nature_travail	statut_marital_Divorcé(e)	poste_Assistant de Direction	fe2_stabilite_manager
911	99.0	1.591746	-2.351758	1.0	-1.567907	0.0	0.0	0.395151
1375	99.0	-0.628241	-2.351758	0.0	-0.660853	0.0	0.0	6.893396
357	98.9	1.591746	-1.336613	1.0	-0.660853	0.0	0.0	-1.548021
688	98.5	1.591746	-2.351758	1.0	-0.660853	0.0	0.0	6.893396
689	96.5	-0.628241	-2.351758	0.0	-1.567907	0.0	0.0	6.893396
514	95.2	1.591746	0.144921	0.0	-1.567907	0.0	1.0	0.395151
762	94.3	1.591746	-0.517031	0.0	-1.567907	0.0	1.0	-1.548021
946	92.7	1.591746	0.005335	0.0	-0.660853	0.0	0.0	-1.234045
1436	92.1	1.591746	-1.757936	1.0	-1.567907	0.0	0.0	-1.548021
1021	92.0	-0.628241	-0.517031	1.0	-1.567907	0.0	0.0	-1.548021

```
🎣 RÉSUMÉ POUR LA DIRECTION RH (ZONE CRITIQUE)
Seuil de confiance appliqué : 85.0%
--------------------------------------------------------------------------------
✅ Départs réels identifiés en test          : 59
🔥 Alertes de haute priorité générées        : 22
🎯 Départs réels capturés (Haut Risque)      : 17
📈 Taux de couverture de la zone             : 28.81%
✅ Fiabilité / Précision de l'alerte         : 77.27%
👉 Interprétation : Sur 10 alertes émises    : 8 départs effectifs
🚀 Action : 22 entretiens prioritaires à mener immédiatement.
```

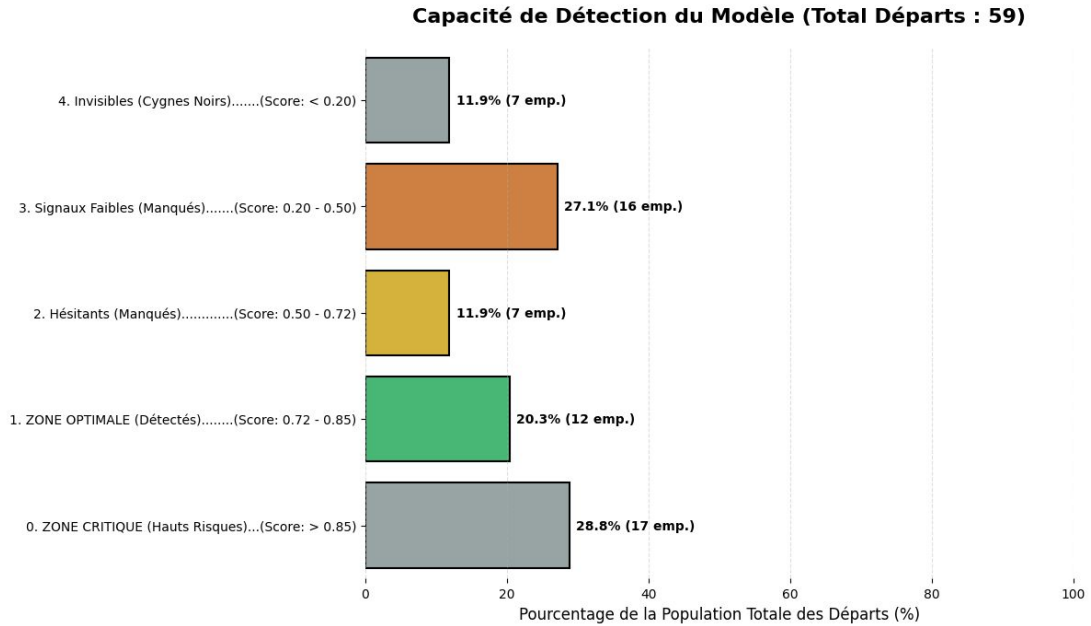
4 Modélisation avancée

ÉTAPE 4 : Modélisation avancée (gestion déséquilibre + optimisation)

1. Définir stratégie de modélisation
2. Validation croisée stratifiée
   - 2.1 Feature Engineering
3. Entraînements Individuels
   - 3.1 Utilisation du Score F-bêta
4. Etude Comparatif
5. Optimisation
   - 5.1 Courbe Précision-Rappel et choix du seuil
   - 5.2 Analyser feature importance (permutation)
   - 5.3 Analyse des probabilités par type d'erreur

1. Les Probabilités de Prédiction

Analyse de la distribution des probabilités (VP, FP, FN, VN)




```
================================================================================
📊 BILAN GLOBAL COHÉRENT (Seuil: 0.85)
--------------------------------------------------------------------------------
0. ZONE CRITIQUE (Hauts Risques)...(Score: > 0.85)      |  17 emp. ( 28.8%)
1. ZONE OPTIMALE (Détectés).....(Score: 0.72 - 0.85) |  12 emp. ( 20.3%)
2. Hésitants (Manqués).....(Score: 0.50 - 0.72) |   7 emp. ( 11.9%)
3. Signaux Faibles (Manqués).....(Score: 0.20 - 0.50) |  16 emp. ( 27.1%)
4. Invisibles (Cygnes Noirs).....(Score: < 0.20)      |   7 emp. ( 11.9%)
--------------------------------------------------------------------------------
```

5 Interprétation

Étape 5 : Interprétez le comportement du modèle

1. Évaluation de la Performance Décisionnelle

Analyse des courbes ROC et Précision-Rappel.

2. Interprétabilité Globale (Causes du Départ)

Hiérarchie des variables (SHAP Beeswarm Plot).

Analyse de convergence (Comparaison Permutation vs SHAP).

3. Analyse des Dépendances et Corrélations

Sens d'influence des caractéristiques clés (Scatter Plots).

Identification de comportements non-linéaires.

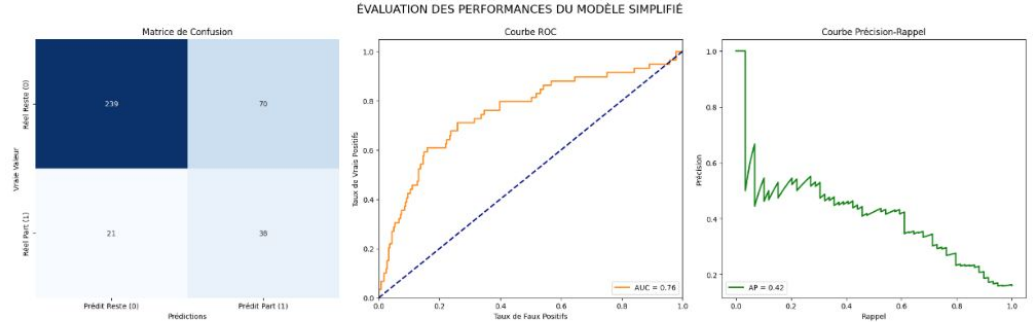
4. Interprétabilité Locale : Diagnostic Individuel

Analyse de cas spécifiques (Waterfall Plots).

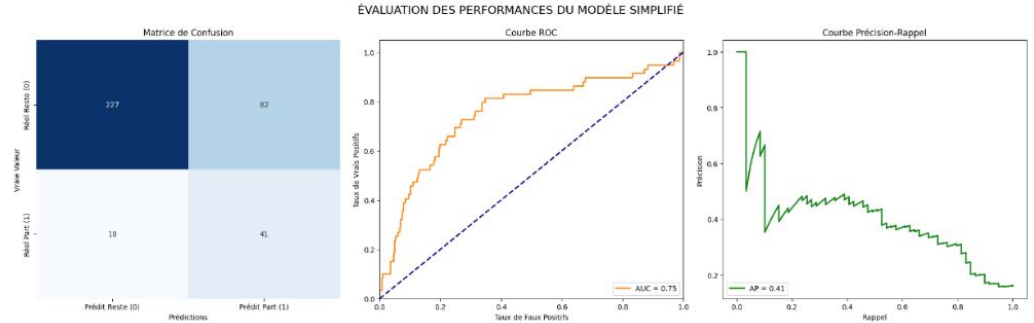
Décomposition du risque pour des profils types (Classes 0 et 1).

Métrique	Modèle avec Fine-Tuning (F2)	Modèle Original (Non optimisé)	Gagnant selon le contexte
Rappel (Recall)	**69.5%** ()	64.4% ()	**F2 (Fine-Tuned)**
Faux Négatifs	**18** (Départs non détectés)	21	**F2 (Fine-Tuned)**
Faux Positifs	82 (Fausses alertes)	**70**	**Original**
AUC (ROC)	0.75	**0.76**	**Original (de peu)**
AP (PR Curve)	0.41	**0.42**	**Original (de peu)**

Lancer une recherche d'hyper paramètres pour fine-tuner le modèle



Comparative AVEC FINE-TUNING (F2)




```
param_distributions = {
    'C'            : loguniform(1e-3, 100),  # Large plage pour trouver la régularisation optimale
    'penalty'      : ['l1', 'l2'],           # L1 aide à réduire l'impact des variables bruitées
    'solver'       : ['liblinear'],          # 'liblinear' est recommandé pour les datasets de taille moyenne avec L1
    'class_weight': ['balanced', None]       # Validation de l'utilité du poids équilibré des classes
}

✅ Meilleurs paramètres trouvés......:
{'C': np.float64(0.009962513222055111), 'class_weight': 'balanced', 'penalty': 'l2', 'solver': 'liblinear'}
```

5 Interprétation

Étape 5 : Interprétez le comportement du modèle

1. Évaluation de la Performance Décisionnelle

   Analyse des courbes ROC et Précision-Rappel.

2. Interprétabilité Globale (Causes du Départ)

   Hiérarchie des variables (SHAP Beeswarm Plot).

   Analyse de convergence (Comparaison Permutation vs SHAP).

3. Analyse des Dépendances et Corrélations

   Sens d'influence des caractéristiques clés (Scatter Plots).

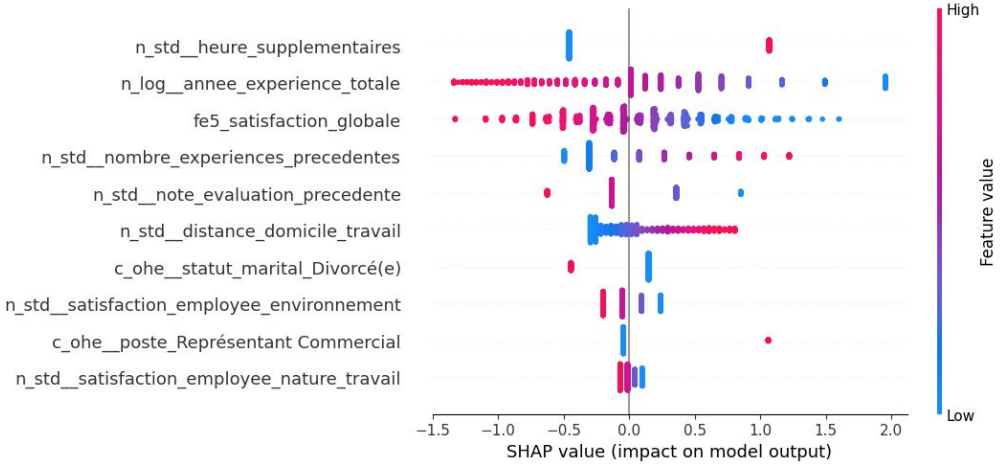
   Identification de comportements non-linéaires.

4. Interprétabilité Locale : Diagnostic Individuel

   Analyse de cas spécifiques (Waterfall Plots).

   Décomposition du risque pour des profils types (Classes 0 et 1).

Interprétabilité Globale
Beeswarm Plot




```
================================================================================
🏆 TOP 5 SHAP - IMPORTANCE GLOBALE MOYENNE
------------------------------------------------
n_std__heure_supplementaires              | 0.6367
n_log__annee_experience_totale            | 0.5932
fe5_satisfaction_globale                  | 0.4134
n_std__nombre_experiences_precedentes     | 0.3904
n_std__note_evaluation_precedente         | 0.2768
```

5 Interprétation

Étape 5 : Interprétez le comportement du modèle

1. Évaluation de la Performance Décisionnelle

   Analyse des courbes ROC et Précision-Rappel.

2. Interprétabilité Globale (Causes du Départ)

   Hiérarchie des variables (SHAP Beeswarm Plot).

   Analyse de convergence (Comparaison Permutation vs SHAP).

3. Analyse des Dépendances et Corrélations

   Sens d'influence des caractéristiques clés (Scatter Plots).

   Identification de comportements non-linéaires.

4. Interprétabilité Locale : Diagnostic Individuel

   Analyse de cas spécifiques (Waterfall Plots).

   Décomposition du risque pour des profils types (Classes 0 et 1).

Analyse de Convergence : Permutation vs SHAP

1. Les Piliers du Modèle (Top 1 & 2)

Heures Supplémentaires : Convergence totale en 1ère position. Plus l'employé en fait (points rouges), plus le risque de départ explose (SHAP > 0).

Années d'Expérience : 2ème facteur clé. L'impact est inverse : la séniorité agit comme un "bouclier" de rétention (points rouges à gauche).

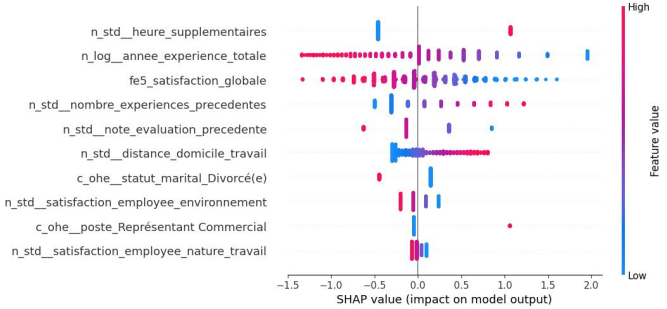
2. Facteurs de Risque Métier et Profil

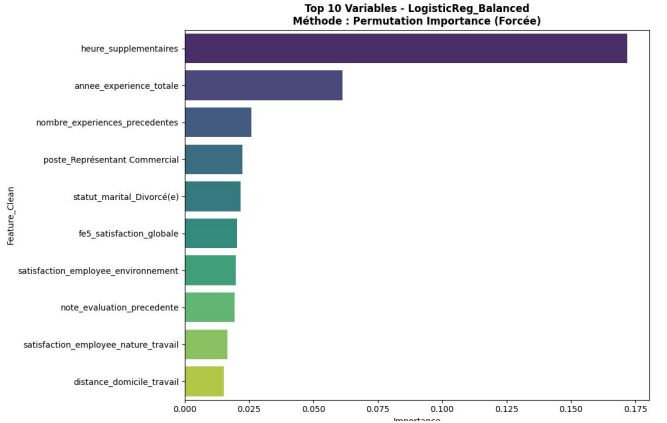
Poste (Commercial) & Statut (Divorcé) : Présents dans le Top 5 des deux méthodes. Ces catégories augmentent mécaniquement la probabilité de départ.

Distance Domicile-Travail : Confirmée comme un facteur de tension ; l'éloignement pousse les points SHAP vers la zone de risque.

3. Le Levier de la Satisfaction

Environnement & Nature du Travail : Bien que d'importance modérée (bas du Top 10), leur influence est claire : une faible satisfaction (bleu) est un moteur constant de démission.





🏆 TOP 5 SHAP - IMPORTANCE GLOBALE MOYENNE

n_std__heure_supplementaires	0.6367
n_log__annee_experience_totale	0.5932
fe5_satisfaction_globale	0.4134
n_std__nombre_experiences_precedentes	0.3904
n_std__note_evaluation_precedente	0.2768

🏆 TOP 5 DES VARIABLES DÉTERMINANTES

1. heure_supplementaires (0.1718)
2. annee_experience_totale (0.0614)
3. nombre_experiences_precedentes (0.0258)
4. poste_Représentant Commercial (0.0224)
5. statut_marital_Divorcé(e) (0.0218)

5 Interprétation

Étape 5 : Interprétez le comportement du modèle

1. Évaluation de la Performance Décisionnelle

   Analyse des courbes ROC et Précision-Rappel.

2. Interprétabilité Globale (Causes du Départ)

   Hiérarchie des variables (SHAP Beeswarm Plot).

   Analyse de convergence (Comparaison Permutation vs SHAP).

3. Analyse des Dépendances et Corrélations

   Sens d'influence des caractéristiques clés (Scatter Plots).

   Identification de comportements non-linéaires.

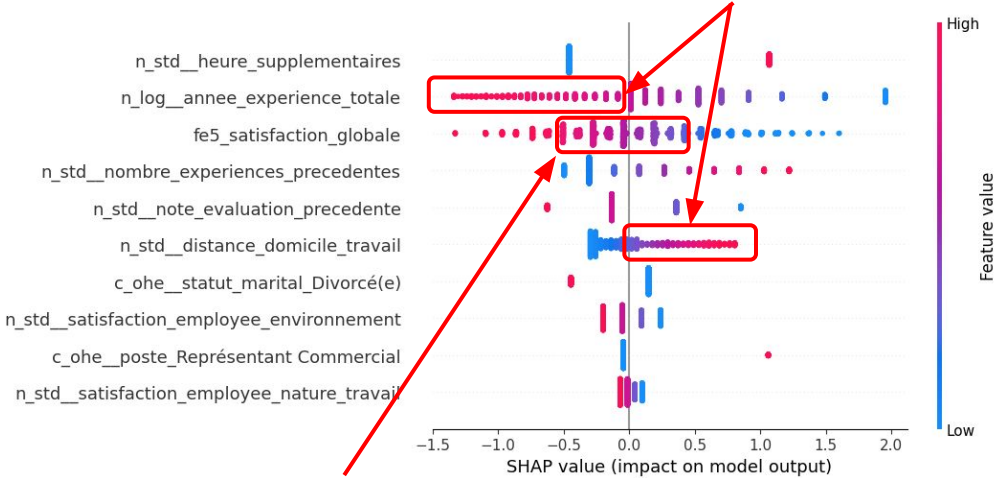
4. Interprétabilité Locale : Diagnostic Individuel

   Analyse de cas spécifiques (Waterfall Plots).

   Décomposition du risque pour des profils types (Classes 0 et 1).

Interprétabilité Globale
Beeswarm Plot

Sens de l'influence
Plus la distance domicile-travail augmente, plus la valeur SHAP devient positive (risque accru)



Constance du Comportement (Fiabilité)
Couleurs séparées ou mélangées?

```
================================================================================
# Beeswarm plot : Importance GLOBALE et distribution des impacts
# C'est le graphique le plus puissant : il montre l'impact des variables sur
l'ensemble du dataset
print("Importance Globale et Distribution (Beeswarm) :")
shap.plots.beeswarm(shap_values_train)
```

5 Interprétation

Étape 5 : Interprétez le comportement du modèle

1. Évaluation de la Performance Décisionnelle

   Analyse des courbes ROC et Précision-Rappel.

2. Interprétabilité Globale (Causes du Départ)

   Hiérarchie des variables (SHAP Beeswarm Plot).

   Analyse de convergence (Comparaison Permutation vs SHAP).

3. Analyse des Dépendances et Corrélations

   Sens d'influence des caractéristiques clés (Scatter Plots).

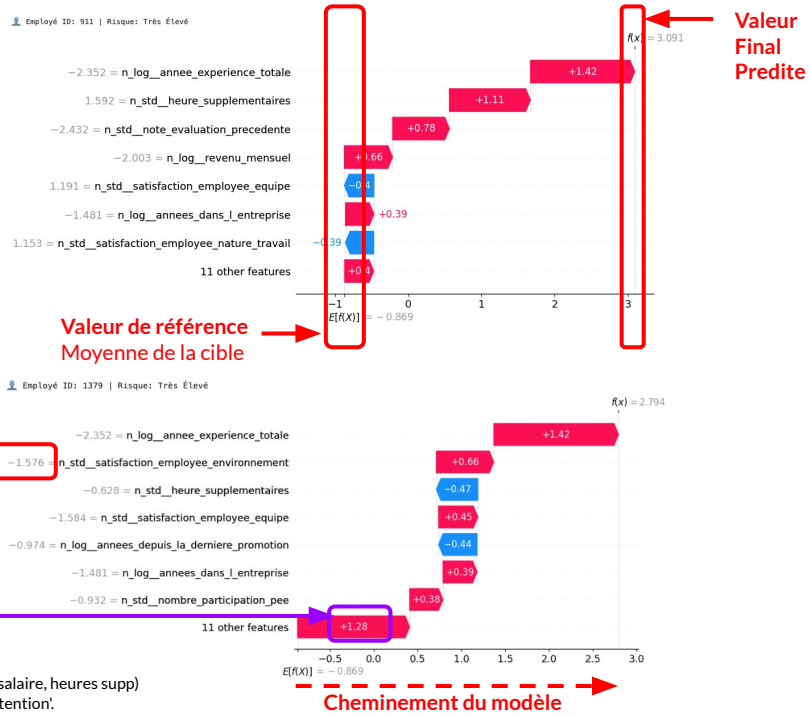
   Identification de comportements non-linéaires.

4. **Interprétabilité Locale : Diagnostic Individuel**

   Analyse de cas spécifiques (Waterfall Plots).

   Décomposition du risque pour des profils types (Classes 0 et 1).

Interprétabilité Locale
Waterfall plot
Explication pour UN employé spécifique



Longitude
Impact sur le modele

Direction (le "Combien")
- Vers le bas flèche rose (augmentation du risque)
- Vers le haut flèche bleue (réduction du risque).

Valeur réelle
(ou standardisée)
de la caractéristique
pour cet employé précis.
(le "Pourquoi")

Valeur de Shapley
Impact mathématique de cette donnée sur la prédiction finale.
Force avec laquelle chaque information (âge, salaire, heures supp) pousse l'aiguille vers le 'Départ' ou vers la 'Rétention'.

```
================================================================================
# Waterfall plot : Explication pour UN employé spécifique (ex: le premier du jeu d'entraînement)
# Ce graphique montre quels facteurs ont poussé CET employé vers le départ (1) ou la rétention (0)
print("Analyse individuelle - Employé 0 (Train) :")
shap.plots.waterfall(shap_values_train[0])
```

Bilan du projet réalisé

💡 RECOMMANDATIONS Administratives

Prévention de l'Épuisement (Priorité Haute)
Action : Mettre en place une alerte RH automatique dès qu'un employé dépasse un certain seuil d'heures supplémentaires sur deux mois consécutifs.

Parcours de Carrière et Promotion
Action : Créer des "points de carrière" obligatoires pour tous les employés n'ayant pas eu de promotion depuis plus de 2 ans.

Protection des Talents Juniors
Action : Lancer un programme de mentorat spécifique pour les employés ayant moins de 5 ans d'expérience totale.

🚧Les défis techniques rencontrés

- Trouver le moyen d'entraîner un modèle CatBoost
- Assurer que le features importance soient équivalents dans les notebooks de Modélisation et Interprétation
- Améliorations notables sur les classes auxiliaires DataCleaner et ClassificationModeler mais découvert nouveaux points d'optimisation

Q & A

Rafael CEREZO MARTIN

Janvier 2026

Mission facultative

Partie 2 - Identifiez les causes d'attrition au sein d'une ESN

Préparation de l'environnement (PostgreSQL)

Création des tables (Le Schéma)

Lecture des fichiers bruts

Ingestion des données vers PostgreSQL

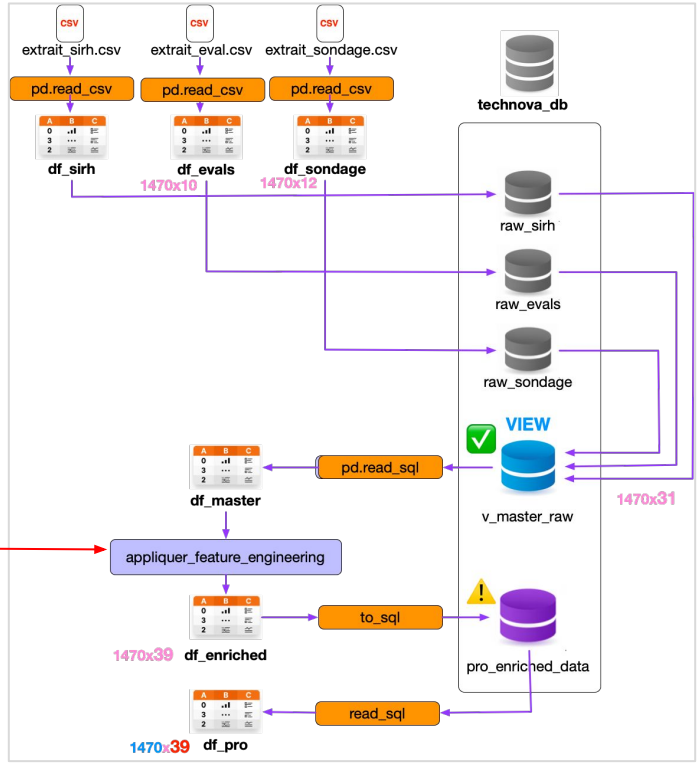
Méthode 1.

- **Création de la Vue "v_master_raw"**
- **Appliquer Feature engineering (Avec Python)**
- **Consulter causes de attrition**

Méthode 2.

- **Création de la Vue "v_master_clean"**
- **Appliquer Feature engineering (Avec SQL)**
- **Consulter causes de attrition**
- **Top 10 des profils à risque**

Méthode 1.



	target_attrition	effectif	age_moyen	salaire_moyen	taux_heures_supp_pct	distance_moyenne
0	0	1233	37.6	6833.0	23.4	8.9
1	1	237	33.6	4787.0	53.6	10.6

Mission facultative

Partie 2 - Identifiez les causes d'attrition au sein d'une ESN

Préparation de l'environnement (PostgreSQL)

Création des tables (Le Schéma)

Lecture des fichiers bruts

Ingestion des données vers PostgreSQL

Méthode 1.

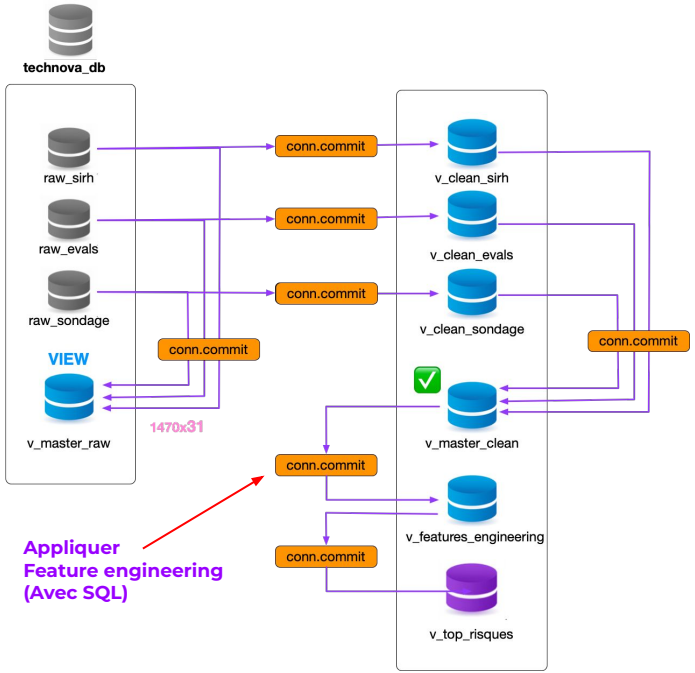
- Création de la Vue "v_master_raw"
- Appliquer Feature engineering (Avec Python)
- Consulter causes de attrition

Méthode 2.

- **Création de la Vue "v_master_clean"**
- **Appliquer Feature engineering (Avec SQL)**
- **Consulter causes de attrition**
- **Top 10 des profils à risque**

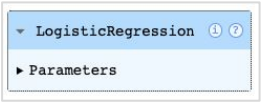
	emp_id	age	departement	poste	heures_supp	annees_dans_l_entreprise	annee_experience_totale	fe2_stabilite_manager	score_risque
0	374	55	Consulting	Senior Manager	Oui	36	37	1.1818	127.58
1	1973	55	Ressources Humaines	Senior Manager	Oui	10	35	0.4000	126.56
2	1824	58	Commercial	Senior Manager	Non	16	37	1.4000	126.34
3	131	58	Commercial	Cadre Commercial	Non	37	38	0.7273	126.20
4	532	56	Commercial	Cadre Commercial	Non	7	36	0.8750	123.76
5	1373	56	Consulting	Tech Lead	Oui	19	33	0.5294	122.82

Méthode 2.



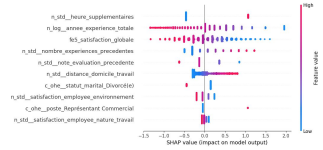
Le "Cerveau" (Le Modèle)

Il a appris à reconnaître les signaux faibles (heures sup, stagnation, distance) qui précèdent une démission.



La "Logique" (SHAP)

Nous a permis de comprendre l'importance de chaque variable (les coefficients comme 0.58, 0.39, etc.).
On obtient la Formule (SQL)



L'Anticipation (La Vue SQL)

En filtrant v_top_risques sur WHERE target_attrition = 0, on demande à la base de prédire l'avenir pour des employés qui sont encore dans l'entreprise.




```
============================================================
PS C:\Users\Public\IAE_DELL\pra_dell\m4_ocr> make predict
process_begin: CreateProcess(NULL, which conda, ...) failed.
Makefile:17: pipe: No error
uv run src/features/build_features.py
✅ Ingeniería de características completada en la DB.
uv run src/models/predict_model.py
🚀 Generando predicciones de riesgo en la base de datos...
✅ Vista 'v_top_risques' (Top 10) actualizada con éxito.
```

```
--- COPY INTO QUERY SQL ---
(
  (heure_supplementaires * 3.0) +
  (annee_experience_totale * 2.01) +
  ((4 - satisfaction_employee_nature_travail) * 1.51) +
  ("poste_Assistant de Direction" * 1.15) +
  (fe2_stabilite_manager * 0.95) +
  ((4 - satisfaction_employee_equilibre_pro_perso) * 0.9) +
  (age * 0.79) +
  ("statut_marital_Divorcé(e)" * 0.74) +
  ("poste_Représentant Commercial" * 0.26) +
  (fe7_penibilite_trajet * 0.21)
) AS score_risque_composite
```

Q & A

Rafael CEREZO MARTIN

Janvier 2026