Prêt à dépenser
Smart | Fast | Secure

Prêt à dépenser
Architecture de Scoring Binaire pour les Prêt à la Consommation

PARTIE 2 / 2
MLOps. Déploiement & Monitoring du Modèle de Scoring Crédit

Rafael CEREZO MARTIN

April 2026

Prêt à dépenser
Smart | Fast | Secure

Introducción

PARTIE 1/2 (Révision)
1.1 Architecture
1.2 Analyse Exploratoire
1.3 Feature Engineering
1.4 Expérimentations
1.5 Optimisation

Partie 2/2
2.1 Architecture
2.2 Best Model
2.3 Use Case
2.4 Drift Analyse
2.5 Performance

Bilan

Objectifs Partie 1/2

Département demandeur : Direction des Risques Financiers

Problématique : Inclusion financière des clients sans historique de crédit tout en minimisant le risque de défaut.

Objectif principal : Développer un modèle de classification automatisé pour prédire la probabilité de faillite et industrialiser son cycle de vie via une approche MLOps de bout en bout.

Standard Industriel (MLOps)

- **Tracking avec MLflow :** Suivi rigoureux des expérimentations, des hyperparamètres et des métriques métiers pour garantir la reproductibilité totale.
- **Model Registry & Serving** : Stockage centralisé et versionnage des modèles pour faciliter le passage de l'expérimentation au test de serving.
- **Optimisation Avancée :** Utilisation d'Optuna ou GridSearchCV pour maximiser les performances techniques et métiers.

Prêt à dépenser
Smart | Fast | Secure

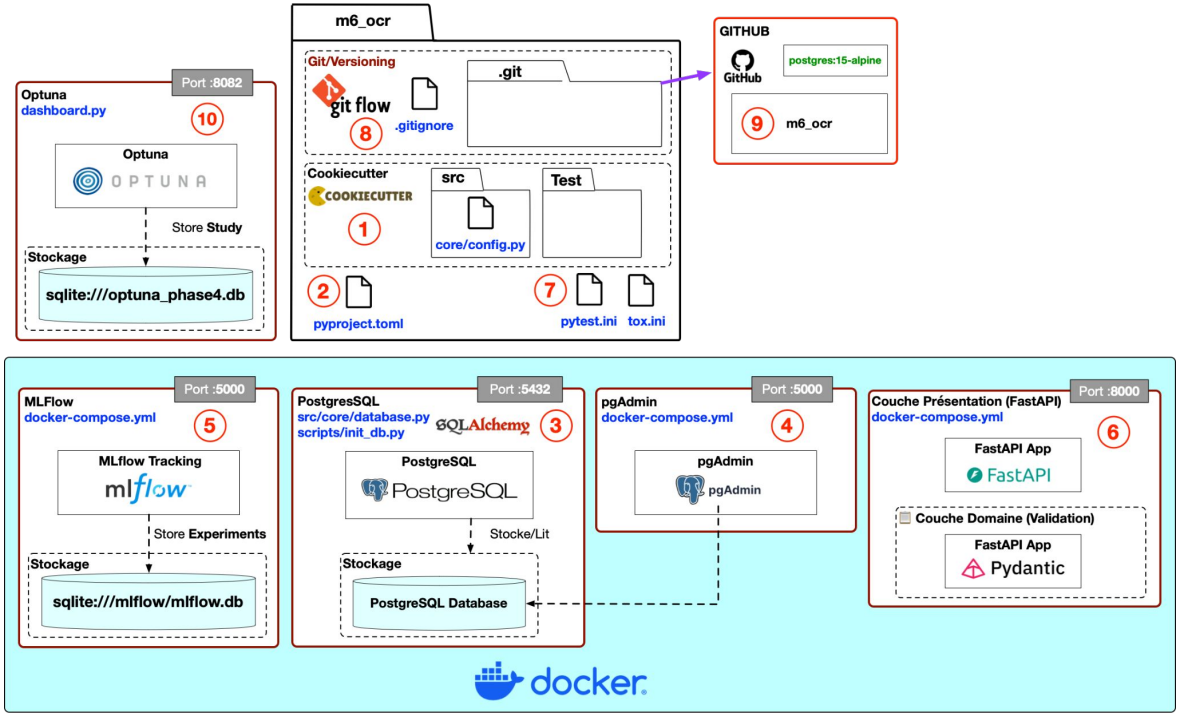
1

PARTIE 1/2 (Révision)
1.1 Architecture
1.2 Analyse Exploratoire
1.3 Feature Engineering
1.4 Expérimentations
1.5 Optimisation

Partie 2/2
2.1 Architecture
2.2 Best Model
2.3 Use Case
2.4 Drift Analyse
2.5 Performance

Bilan

Architecture de Scoring Binaire pour les Prêt à la Consommation
Part 1/2



Prêt à dépenser
Smart | Fast | Secure

1

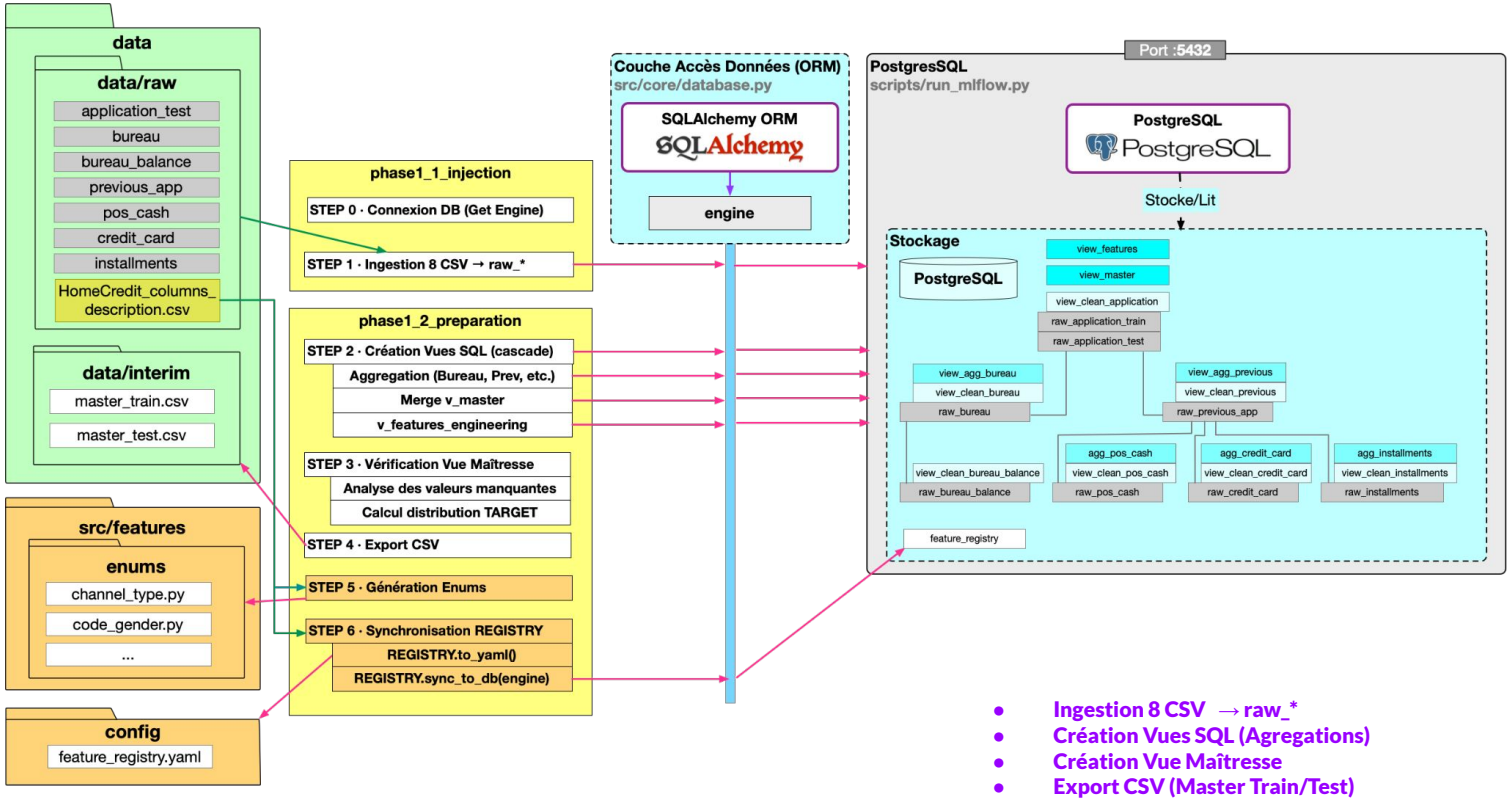
PARTIE 1/2 (Révision)
1.1 Architecture
1.2 Analyse Exploratoire
1.3 Feature Engineering
1.4 Expérimentations
1.5 Optimisation

Partie 2/2
2.1 Architecture
2.2 Best Model
2.3 Use Case
2.4 Drift Analyse
2.5 Performance

Bilan

Analyse Exploratoire (Nettoyage et Préparation)

STEP 1. Pipeline



- Ingestion 8 CSV → raw_*
- Création Vues SQL (Agregations)
- Création Vue Maîtresse
- Export CSV (Master Train/Test)

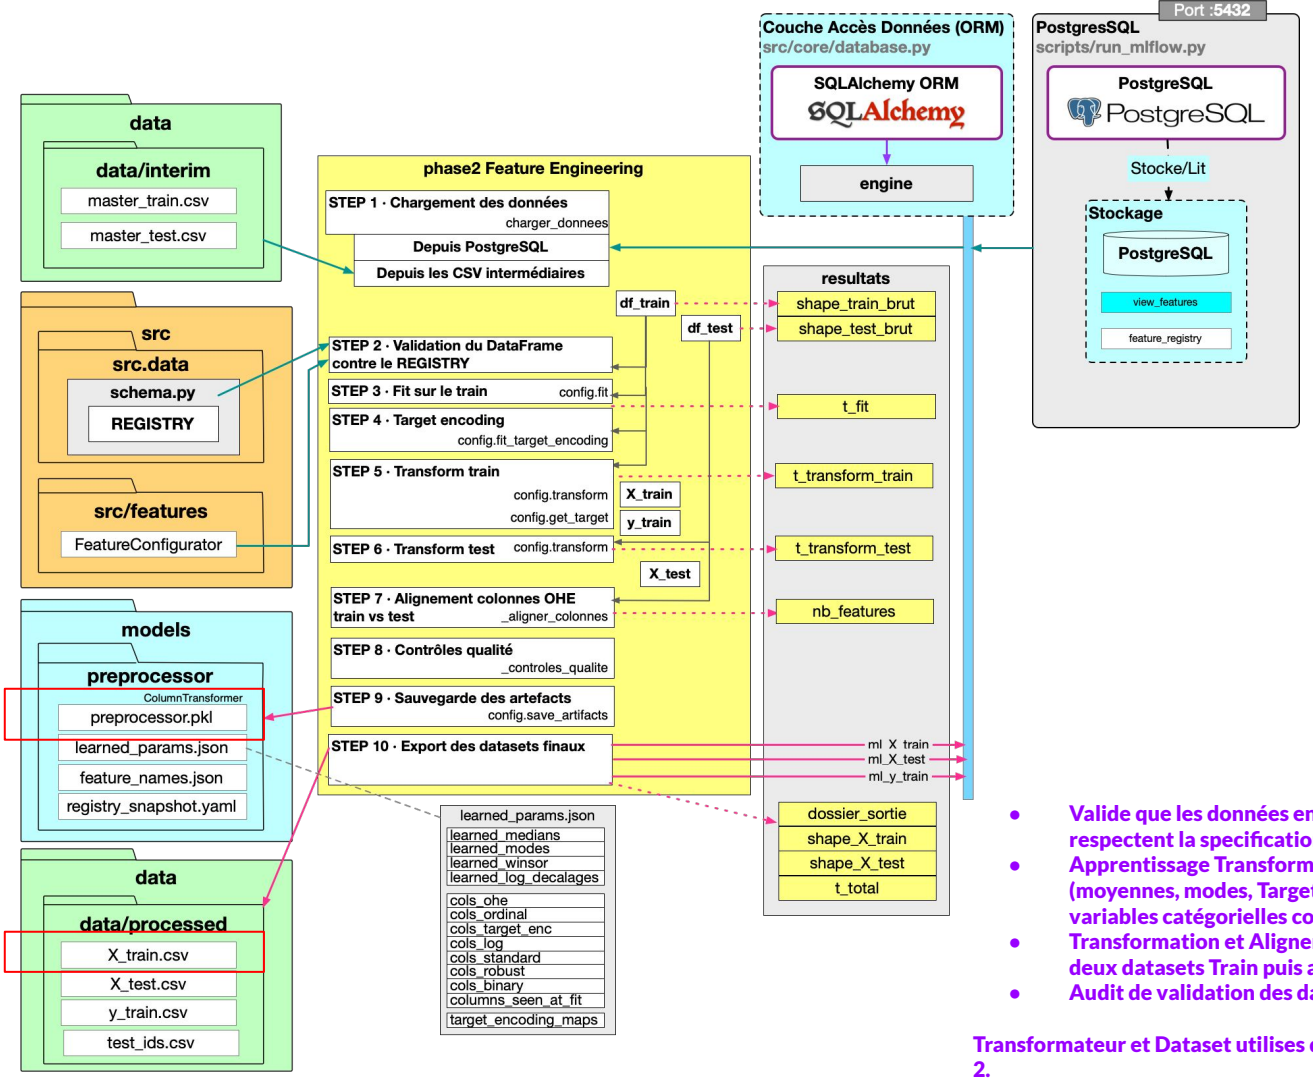
Prêt à dépenser
Smart | Fast | Secure

1

PARTIE 1/2 (Révision)
1.1 Architecture
1.2 Analyse Exploratoire
1.3 Feature Engineering
1.4 Expérimentations
1.5 Optimisation

Partie 2/2
2.1 Architecture
2.2 Best Model
2.3 Use Case
2.4 Drift Analyse
2.5 Performance

Bilan



- Valide que les données entrantes respectent la specification (REGISTRY)
- Apprentissage Transformateur (moyennes, modes, Target Encoding des variables catégorielles complexes)
- Transformation et Alignement sur les deux datasets Train puis au Test
- Audit de validation des datasets

Transformateur et Dataset utilises dans l'etape 2.

Prêt à dépenser
Smart | Fast | Secure

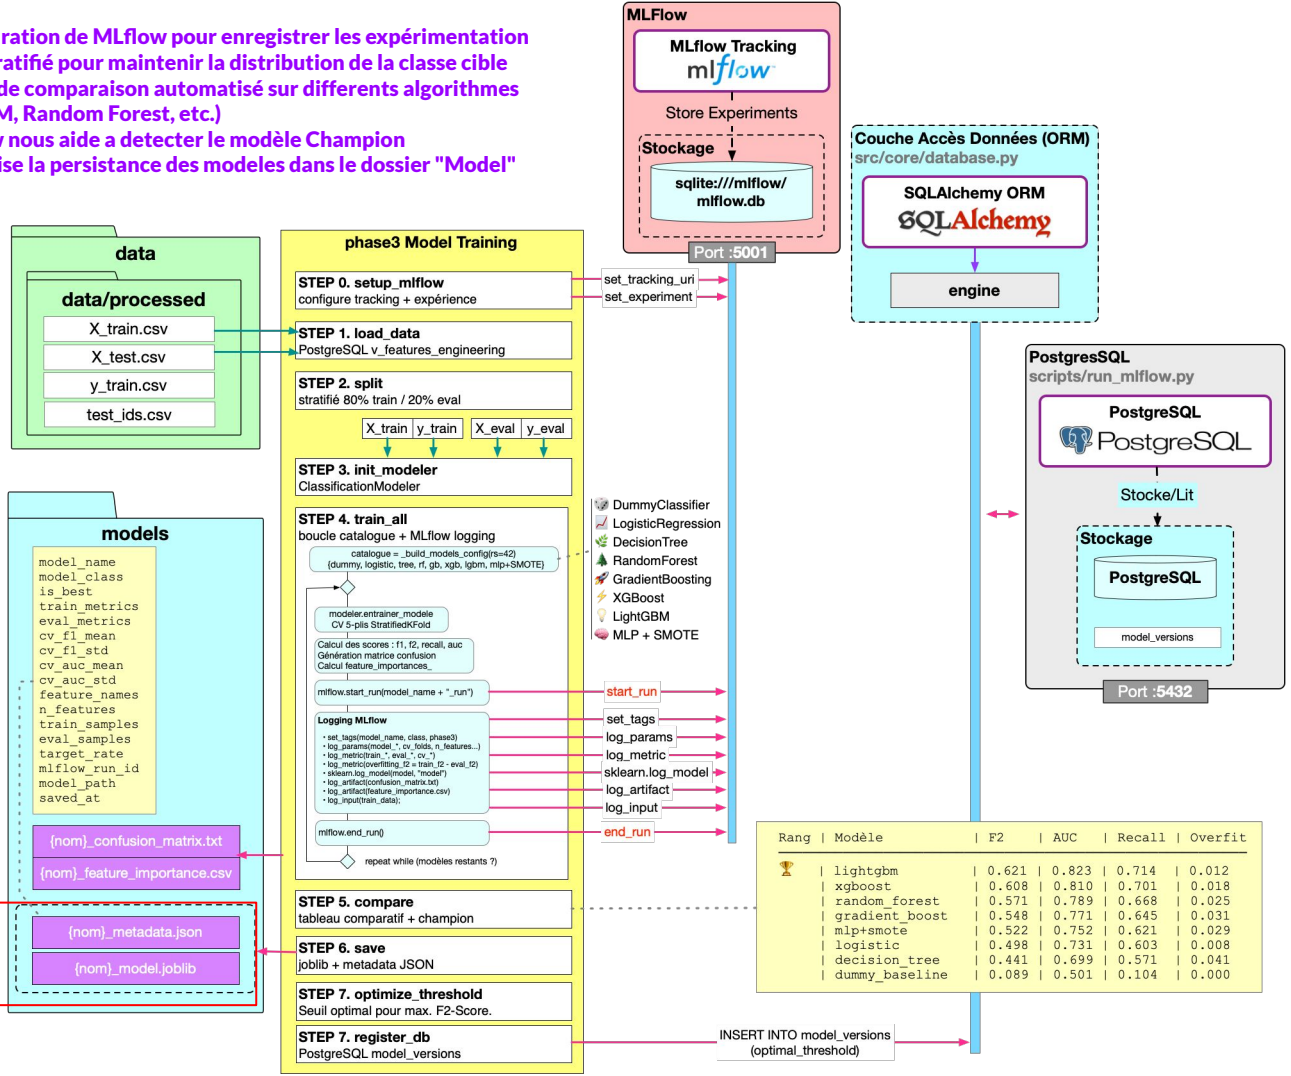
1

PARTIE 1/2 (Révision)
1.1 Architecture
1.2 Analyse Exploratoire
1.3 Feature Engineering
1.4 Expérimentations
1.5 Optimisation

Partie 2/2
2.1 Architecture
2.2 Best Model
2.3 Use Case
2.4 Drift Analyse
2.5 Performance

Bilan

- Configuration de MLflow pour enregistrer les expérimentation
- Split Stratifié pour maintenir la distribution de la classe cible
- Boucle de comparaison automatisé sur differents algorithmes (LightGBM, Random Forest, etc.)
- MLFlow nous aide a detecter le modèle Champion
- On realise la persistance des modeles dans le dossier "Model"



Prêt à dépenser
Smart | Fast | Secure

1

PARTIE 1/2 (Révision)
1.1 Architecture
1.2 Analyse Exploratoire
1.3 Feature Engineering
1.4 Expérimentations
1.5 Optimisation

Partie 2/2
2.1 Architecture
2.2 Best Model
2.3 Use Case
2.4 Drift Analyse
2.5 Performance

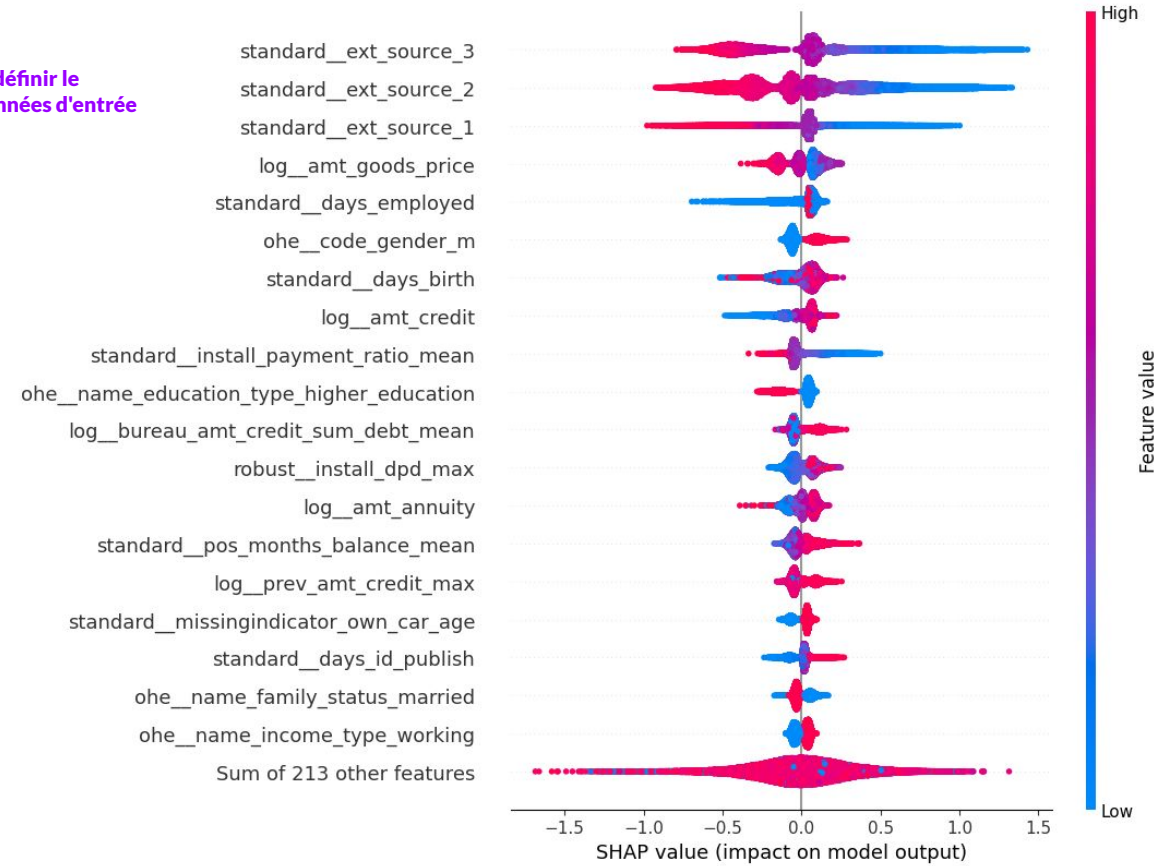
Bilan

Etape finale apres optimisation: Interprétabilité Globale du modèle (Causes de la decision)

Comprendre les décisions de l'algorithme (éviter l'effet "boîte noire")

📊 **Beeswarm Plot — Top 20 variables (impact sur la probabilité de défaut)**

Utilisées pour définir le schéma des données d'entrée de l'API.



Prêt à dépenser
Smart | Fast | Secure

Partie 2/2
Nous partons du modèle versionné dans MLflow pour le déployer, monitorer et optimiser en production

2

PARTIE 1/2 (Révision)
1.1 Architecture
1.2 Analyse Exploratoire
1.3 Feature Engineering
1.4 Expérimentations
1.5 Optimisation

Partie 2/2
2.1 Architecture
2.2 Best Model
2.3 Use Case
2.4 Drift Analyse
2.5 Performance

Bilan

Objectifs Partie 2/2 Déploiement & Monitoring Proactif

Industrialisation de l'API : Développement d'une interface robuste (FastAPI/Gradio) pour une consommation des scores en temps quasi-réel par le département "Crédit Express".

Optimisation de la Performance : Profilage du code et utilisation de formats comme **ONNX** pour minimiser le temps d'inférence et optimiser l'utilisation des ressources.

- **WebApp 1. Interface utilisateur pour l'API (user-friendly) interactive** permettant de saisir et d'envoyer les données client à l'API pour obtenir un score de crédit et ses explications SHAP.
- **WebApp 2. Monitoring & Observabilité** : Mise en place d'un **dashboard** (Streamlit/Evidently AI) pour le suivi de la **latence**, de la distribution des scores et la détection précoce du **Data Drift**.

Conteneurisation & Agilité : Standardisation de l'environnement via **Docker** pour garantir la portabilité et la cohérence entre le développement et la production.

Pipeline CI/CD Automatisé : Automatisation du cycle de déploiement (GitHub Actions) incluant des tests unitaires rigoureux (Pytest) pour valider l'intégrité du modèle à chaque mise à jour.

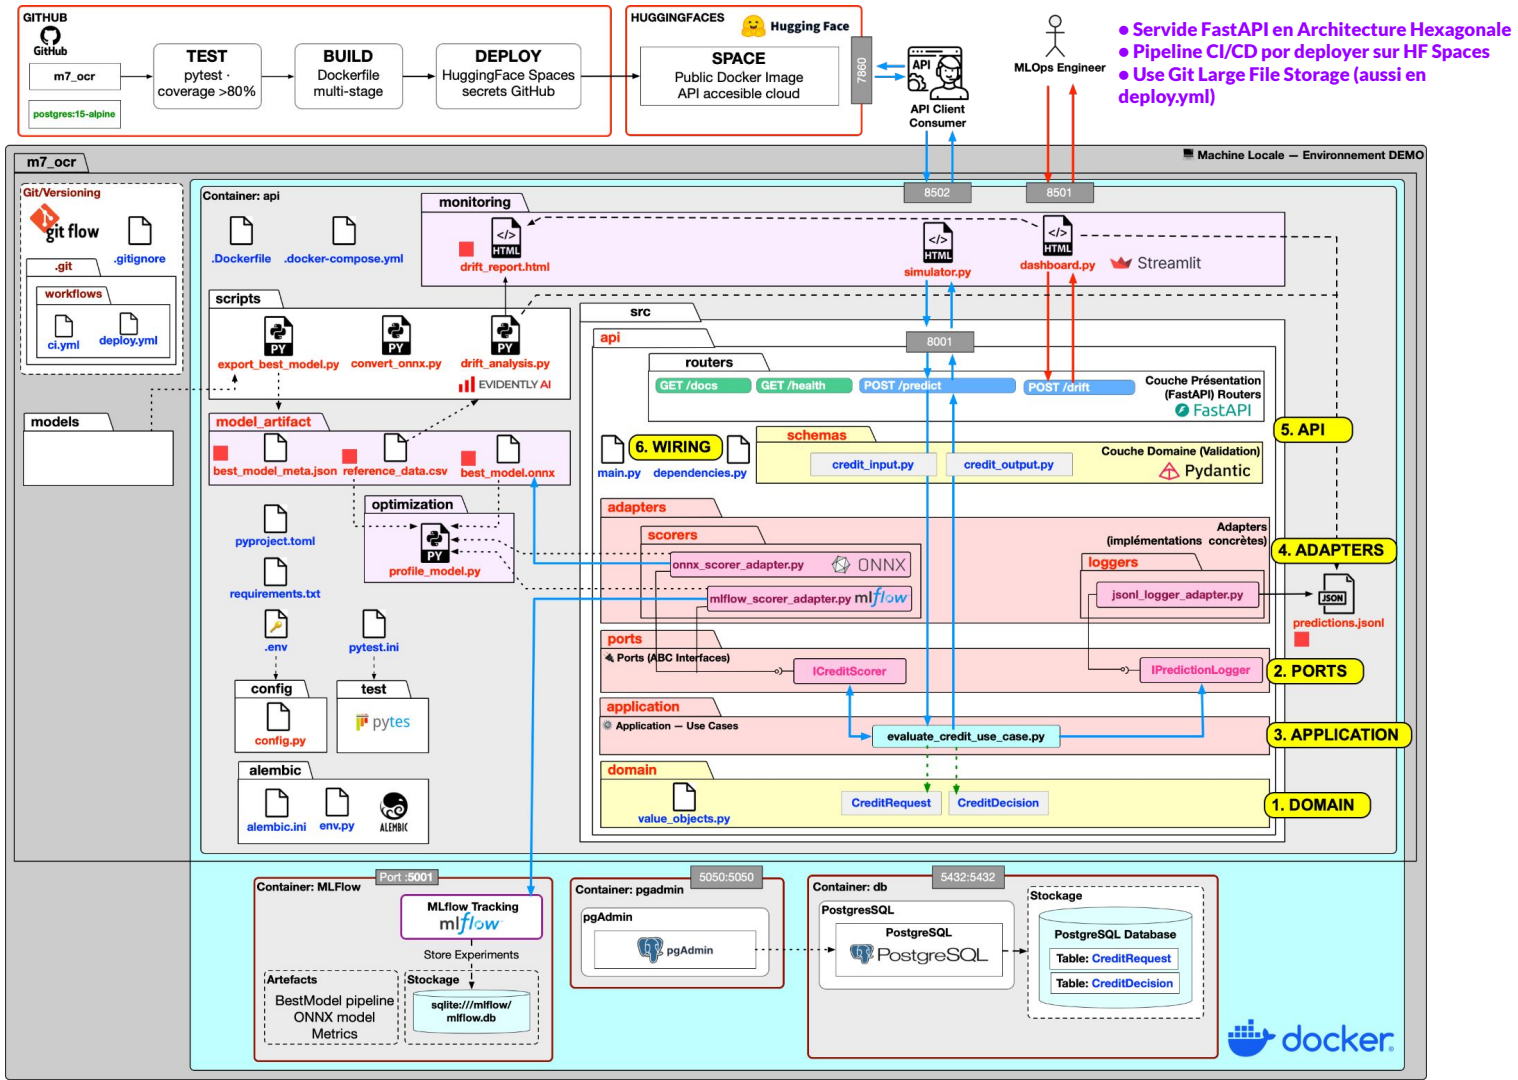
Prêt à dépenser
Smart | Fast | Secure

2

PARTIE 1/2 (Révision)
1.1 Architecture
1.2 Analyse Exploratoire
1.3 Feature Engineering
1.4 Expérimentations
1.5 Optimisation

Partie 2/2
2.1 Architecture
2.2 Best Model
2.3 Use Case
2.4 Drift Analyse
2.5 Performance

Bilan



Prêt à dépenser
Smart | Fast | Secure

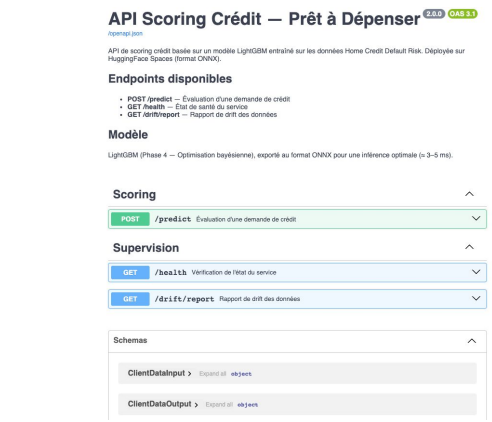
2

PARTIE 1/2 (Révision)
1.1 Architecture
1.2 Analyse Exploratoire
1.3 Feature Engineering
1.4 Expérimentations
1.5 Optimisation

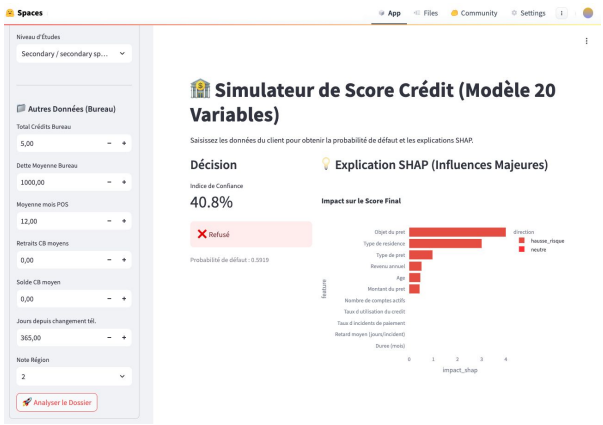
Partie 2/2
2.1 Architecture
2.2 Best Model
2.3 Use Case
2.4 Drift Analyse
2.5 Performance

Bilan

Docker Service: API
Port 8001



Docker Service: Simulator
Port 8502 en Local (Sur Huggingface 7860)



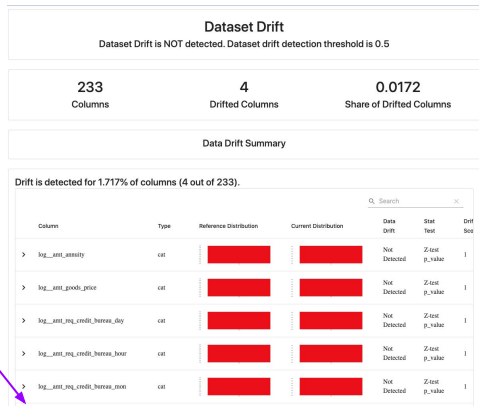


drift_analysis.py

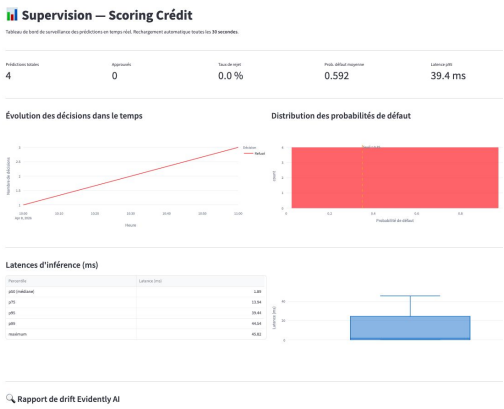
predictions.jsonl
Données de production



Rapport Evidently AI
drift_report.html



Docker Service: Dashboard
Port 8501



Use Case: Evaluate Credit (Calcul et Traitement des SHAP Values)

Étape 3 - Implémentez le stockage et l'analyse des données de production

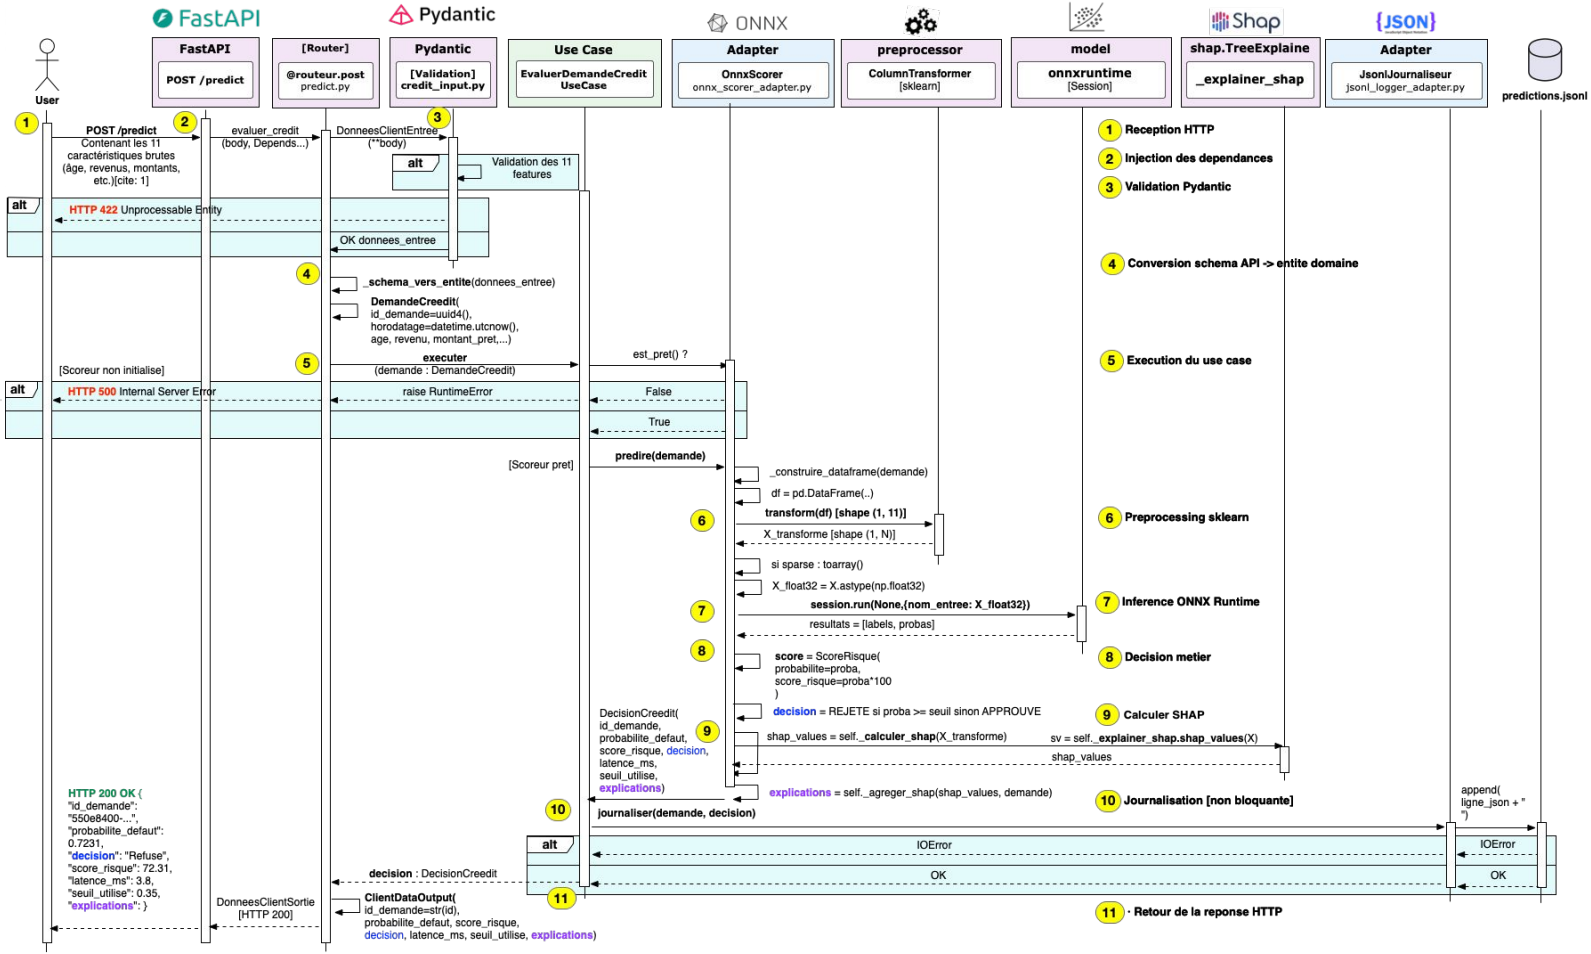
Prêt à dépenser
Smart | Fast | Secure

2

PARTIE 1/2 (Révision)
1.1 Architecture
1.2 Analyse Exploratoire
1.3 Feature Engineering
1.4 Expérimentations
1.5 Optimisation

Partie 2/2
2.1 Architecture
2.2 Best Model
2.3 Use Case
2.4 Drift Analyse
2.5 Performance

Bilan



Use Case: Evaluate Credit (Calcul et Traitement des SHAP Values)

Étape 3 - Implémentez le stockage et l'analyse des données de production

Prêt à dépenser
Smart | Fast | Secure

2

PARTIE 1/2 (Révision)
1.1 Architecture
1.2 Analyse Exploratoire
1.3 Feature Engineering
1.4 Expérimentations
1.5 Optimisation

Partie 2/2
2.1 Architecture
2.2 Best Model
2.3 Use Case
2.4 Drift Analyse
2.5 Performance

Bilan

ONNX

Adapter
OnnxScorer
onnx_scorer_adapter.py

SHAP (SHapley Additive exPlanations) Attribueà chaque feature un score d'impact, positif ou négatif, sur la décision finale.

Champ Python API	Nom colonne préprocesseur	Nom métier (réponse client)
age	days_birth	Age
revenu	amt_income_total	Revenu annuel
montant_pret	amt_credit	Montant du prêt
duree_pret_mois	duree_pret_mois	Durée (mois)
jours_retard_moyen	avg_dpd_per_delinquency	Retard moyen (jours/incident)
taux_incidents	delinquency_ratio	Taux d'incidents de paiement
taux_utilisation_credit	credit_utilization_ratio	Taux d'utilisation du crédit
nb_comptes_ouverts	num_open_accounts	Nombre de comptes actifs
type_residence	name_housing_type	Type de résidence
objet_pret	name_type_suite	Objet du prêt
type_pret	name_contract_type	Type de prêt

Pydantic
DemandeCredit
ext_source_2
ext_source_3
ext_source_1
install_payment_ratio_mean
days_birth
cc_amt_drawings_current_mean
install_payment_delay_mean
pos_months_balance_mean
amt_goods_price
name_education_type,
code_gender
...

demande

df_entree

preprocessor transform()

X_transforme

shap.sample

_background_shap (100, 232)
100 lignes max

ONNX Runtime transforme le modèle en un graphe de calcul optimisé mais perd la structure de l'arbre : il n'y a plus de nœuds de décision inspectables, uniquement des opérations matricielles.

ONNX
ONNX Runtime
inférence rapide
(~3 ms)

resultats

_extraire_probabilite

probabilite_defaut

LightGBM
LightGBM
Pour le calcul SHAP
(~5–20 ms)

LightGBM (Light Gradient Boosting Machine) est un algorithme de **Gradient Boosted Decision Trees (GBDT)** développé par Microsoft. Il construit une séquence d'arbres de décision, chaque arbre corrigeant les erreurs du précédent.

Le surcoût SHAP de ~5–20 ms est désactivable via parametres.activer_shap = False pour les environnements où la latence est critique.

model

data

SHAP
shap.TreeExplainer

Exploite la structure arborescente du modèle pour calculer les SHAP values de façon exacte en temps polynomial O(TLD²) où
- T = nombre d'arbres,
- L = nombre de feuilles,
- D = profondeur maximale.

shap_values

_agreger_shap

explications

ScoreRisque

score

score.vers_decision

decision

Pydantic
DecisionCredit
id_demande
score
decision
latence_ms
seuil_utilise
explications_shap

Script. Analyse du Drift du Modele

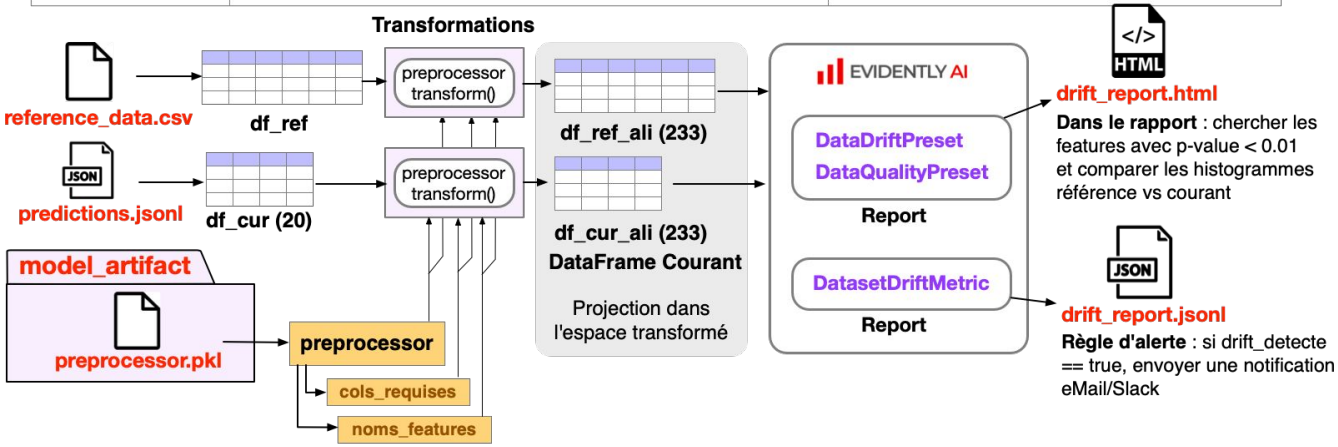
Étape 3 - Implémentez le stockage et l'analyse des données de production

drift_analysis.py

Les données entrantes en production ressemblent-elles encore aux données d'entraînement ?

Si la distribution des features change (drift), le modèle produit des prédictions moins fiables, même sans aucune modification du code.

Métrique Evidently	Rôle	Sensible à
DataDriftPreset	Analyse le drift colonne par colonne. Utilise le test statistique adapté à chaque type (KS pour numérique, Chi² pour catégoriel)	Changements de distribution sur les 232 features
DataQualityPreset	Analyse la qualité des données : valeurs manquantes, doublons, valeurs hors plage	Valeurs NaN, constantes, plages anormales
DatasetDriftMetric	Résumé global : nombre de features driftées, score de drift global	Vue agrégée pour le mode --format json



Type de feature	Test utilisé	H0 (hypothèse nulle)	Drift si
Numérique continue	Kolmogorov-Smirnov (KS)	Les deux distributions sont identiques	p-value < 0.05
Catégorielle (OHE binaire)	Chi-carré (χ^2)	Les fréquences des catégories sont identiques	p-value < 0.05
Catégorielle (string)	Chi-carré (χ^2)	Même distribution des modalités	p-value < 0.05

Seuil de drift global (drift_share): par défaut, Evidently considère que le dataset dérive si plus de 50 % des features ont un drift individuel.

Script. Profilage de performance du modèle

Étape 4 - Analysez et optimisez les performances du modèle

Prêt à dépenser
Smart | Fast | Secure

2

PARTIE 1/2 (Révision)
1.1 Architecture
1.2 Analyse Exploratoire
1.3 Feature Engineering
1.4 Expérimentations
1.5 Optimisation

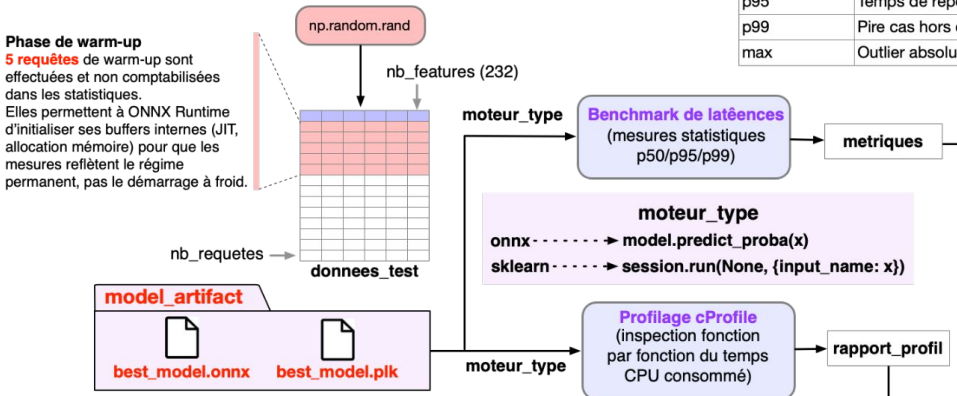
Partie 2/2
2.1 Architecture
2.2 Best Model
2.3 Use Case
2.4 Drift Analyse
2.5 Performance

Bilan

profile_model.py

Le modèle ONNX est-il assez rapide pour la production ?
Il mesure la latence d'inférence requête par requête et identifie les fonctions Python les plus coûteuses dans le pipeline d'exécution

Phase de warm-up
5 requêtes de warm-up sont effectuées et non comptabilisées dans les statistiques.
Elles permettent à ONNX Runtime d'initialiser ses buffers internes (JIT, allocation mémoire) pour que les mesures reflètent le régime permanent, pas le démarrage à froid.



Interprétation des percentiles

Métrique	Ce qu'elle mesure	Seuil acceptable (scoring crédit)
p50 (médiane)	Temps de réponse pour 50 % des requêtes	< 5 ms avec ONNX
p95	Temps de réponse pour 95 % des requêtes	< 10 ms (SLA typique)
p99	Pire cas hors outliers extrêmes	< 20 ms acceptable
max	Outlier absolu — peut être GC ou OS interrupt	Ignorer si isolé

Sortie console — rapport de benchmark

```
============================================================
RAPPORT DE BENCHMARK — INFÉRENCE ONNX RUNTIME
============================================================
  Moteur d'inférence.....: ONNX Runtime
  Nombre de requêtes.....: 500
------------------------------------------------------------
  Latence minimum.........: 2.841 ms
  Latence p50 (médiane)...: 3.127 ms      <- réponse typique
  Latence p75.............: 3.298 ms
  Latence p95.............: 4.201 ms      <- pic de charge
  Latence p99.............: 5.847 ms      <- pire cas habituel
  Latence maximum.........: 12.301 ms     <- outlier
  Latence moyenne.........: 3.219 ms
============================================================
```

Sortie JSON — format machine (--format json)

```
// optimization/rapports/benchmark_onnx.json
{
  "moteur"      : "ONNX Runtime",
  "nb_requetes" : 500,
  "latence_min" : 2.841,
  "latence_p50" : 3.127,
  "latence_p75" : 3.298,
  "latence_p95" : 4.201,
  "latence_p99" : 5.847,
  "latence_max" : 12.301,
  "latence_moy" : 3.219
}
// Note : latences_raw (liste des 500 valeurs) est omis du JSON
```

Sortie CSV — série temporelle (--format csv)

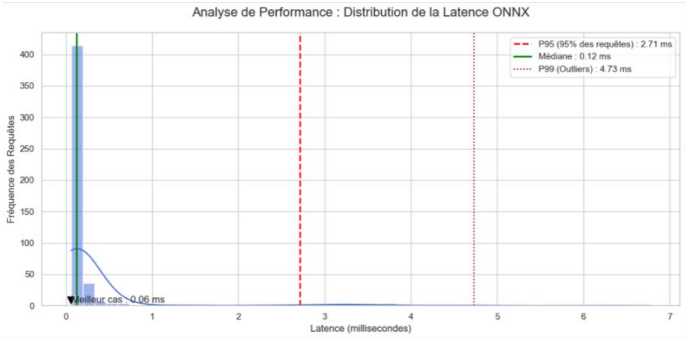
```
# optimization/rapports/benchmark_onnx_latences.csv
requete_num,latence_ms
0,3.241
1,3.108
2,2.956
...
499,3.187
```

Rapport cProfile — texte (toujours généré)

```
# optimization/rapports/cprofile_onnx.txt
         500 function calls in 1.614 seconds

   Ordered by: cumulative time
   List reduced from 247 to 20 due to restriction <20>

   ncalls  tottime  percall  cumtime  percall  filename:lineno(function)
      500    0.003    0.000    1.614    0.003  profile_model.py:168(run)
      500    0.001    0.000    1.611    0.003  backend.py:42(run)
      500    0.000    0.000    1.608    0.003  {built-in method run}
        1    0.000    0.000    0.004    0.004  numpy/random.py:221(rand)
```



Prêt à dépenser
Smart | Fast | Secure

2

PARTIE 1/2 (Révision)
1.1 Architecture
1.2 Analyse Exploratoire
1.3 Feature Engineering
1.4 Expérimentations
1.5 Optimisation

Partie 2/2
2.1 Architecture
2.2 Best Model
2.3 Use Case
2.4 Drift Analyse
2.5 Performance

Bilan

Concevoir un système de suivi du cycle de vie du modèle d'apprentissage.

Industrialisation complète

✓ Du modèle MLflow versionné à une API Docker-ready déployée sur HuggingFace
✓ Pipeline CI/CD automatisé lors d'un push sur la branche main

Robustesse & tests

✓ Validation stricte des inputs,
✓ Tests unitaires couvrant cas limites et erreurs, couverture > 80%

Monitoring proactif

✓ Mise en place d'un mecanisme de détection de drift (Evidently AI)
✓ Dashboard Streamlit pour montrer metriques de latence p95/p99 et le rapport du Drift
✓ Interface pour consulter l'API montran les SHAP Values (Pas de boîte noire en production)

Optimisation mesurée

✓ Identifie les goulots a l'aide des mesures de temps d'execution et l'utilisation de cProfile,
✓ Optimisation du modele en format ONNX Runtime réduit la latence. — Optimisation justifiée par données réelles

Prêt à dépenser
Smart | Fast | Secure

Q & A

Rafael CEREZO MARTIN April 2026

Script. Export Best Model

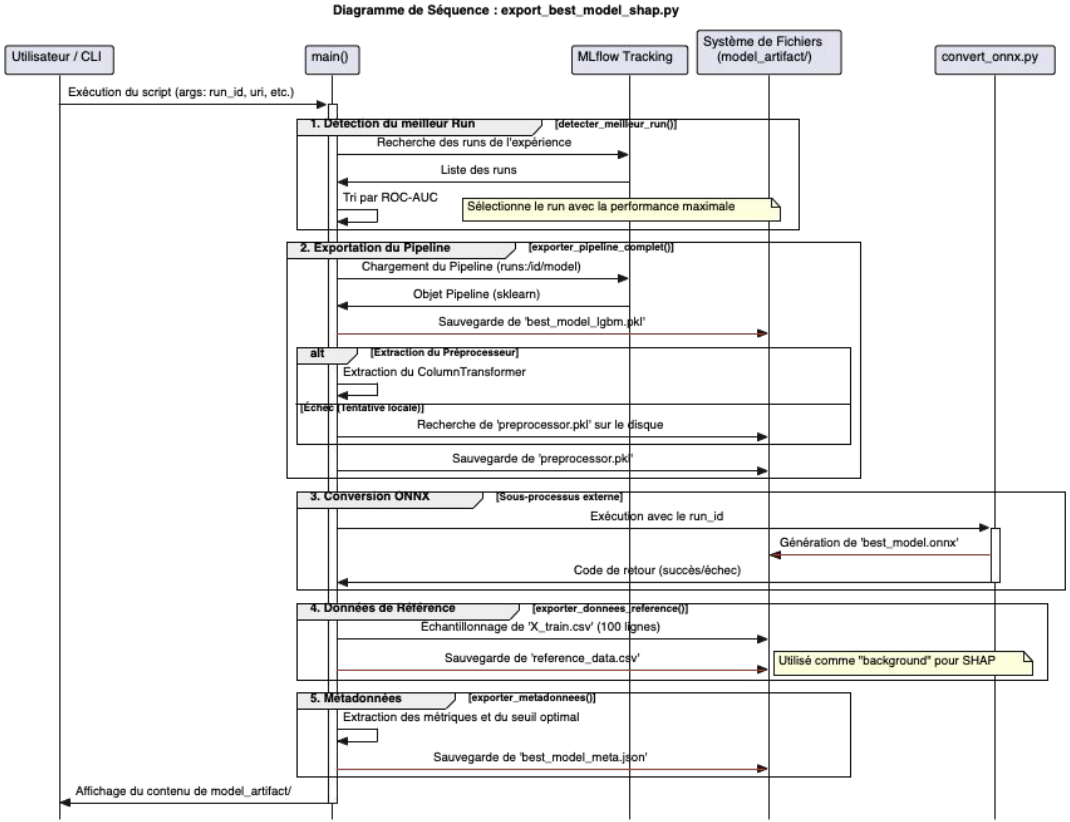
Prêt à dépenser
Smart | Fast | Secure

2

PARTIE 1/2 (Révision)
1.1 Architecture
1.2 Analyse Exploratoire
1.3 Feature Engineering
1.4 Expérimentations
1.5 Optimisation

Partie 2/2
2.1 Architecture
2.2 Best Model
2.3 Use Case
2.4 Drift Analyse
2.5 Performance

Bilan



best_model.pkl

preprocessor.pkl

best_model.onnx

reference_data.csv

best_model_meta.json

Comme placer le binaire du modele dans Huggingface ?

MLflow Tracking Server
MLflow Registry
- S3 bucket
- GCS bucket
- Azure Blob
- SFTP / NFS

A travers du code;
```
from huggingface_hub import upload_file
from huggingface_hub import hf_hub_download
• upload_file( path_or_fileobj= .. path_in_repo="model.pkl", .. )
• model_path = hf_hub_download( repo_id="user/model", filename="model.pkl" )
model = joblib.load(model_path)
```

Command CLI
huggingface-cli upload

Test Manuel

Git Large File Storage (aussi en deploy.yml)
```
git lfs install
git lfs track "model_artifact/*.onnx"
git lfs track "model_artifact/*.pkl"
```

Use Case: Evaluate Credit (Calcul et Traitement des SHAP Values)

Étape 3 - Implémentez le stockage et l'analyse des données de production

Prêt à dépenser
Smart | Fast | Secure

2

PARTIE 1/2 (Révision)
1.1 Architecture
1.2 Analyse Exploratoire
1.3 Feature Engineering
1.4 Expérimentations
1.5 Optimisation

Partie 2/2
2.1 Architecture
2.2 Best Model
2.3 Use Case
2.4 Drift Analyse
2.5 Performance

Bilan

DemandeCredit


```
{
  "age": 35,
  "amt_annuity": 25000,
  "amt_credit": 500000,
  "bureau_credit_total": 5,
  "bureau_debt_mean": 1000,
  "cc_balance_mean": 0,
  "cc_drawings_mean": 0,
  "code_gender": "F",
  "education_type": "Higher education",
  "ext_source_1": 0.5,
  "ext_source_2": 0.5,
  "ext_source_3": 0.5,
  "goods_price": 450000,
  "max_dpd": 0,
  "objet_pret": "Unaccompanied",
  "paymnt_delay_mean": 2,
  "paymnt_ratio_mean": 0.1,
  "phone_change_days": 365,
  "pos_months_mean": 12,
  "region_rating": 2,
  "revenu": 50000,
  "type_pret": "Cash loans",
  "type_residence": "House / apartment",
  "years_employed": 10
}
```


DecisionCredit


```
{
  "id_demande":
"1307f4fc-c0fc-4a85-9e01-588e41aea3ed",
  "probabilite_defaut": 0.6635897755622864,
  "decision": "Refusé",
  "score_risque": 0.6635897755622864,
  "latence_ms": 5.33,
  "seuil_utilise": 0.35,
  "explication_shap": [
     …,
     {
      "feature": "Score Externe 2",
      "valeur_client": "0.5",
      "impact_shap": 0.52102,
      "direction": "hausse_risque",
      "explication": null
    },
    {
      "feature": "Score Externe 3",
      "valeur_client": "0.5",
      "impact_shap": 0.51904,
      "direction": "hausse_risque",
      "explication": null
    },
    ....
  ]
}
```


predictions.jsonl


```
{"horodatage": "2026-04-22T15:56:18.852138Z",
 "id_demande":
"1307f4fc-c0fc-4a85-9e01-588e41aea3ed",
 "ext_source_1": 0.5,
 "ext_source_2": 0.5,
 "ext_source_3": 0.5,
 "paymnt_ratio_mean": 0.1,
 "age": 35,
 "cc_drawings_mean": 0.0,
 "paymnt_delay_mean": 2.0,
 "pos_months_mean": 12.0,
 "goods_price": 450000.0,
 "education_type": "Higher education",
 "code_gender": "F",
 "bureau_credit_total": 5.0,
 "max_dpd": 0.0,
 "amt_credit": 500000.0,
 "amt_annuity": 25000.0,
 "cc_balance_mean": 0.0,
 "years_employed": 10,
 "phone_change_days": 365.0,
 "region_rating": 2,
 "bureau_debt_mean": 1000.0,
 "probabilite_defaut": 0.66359,
 "decision": "Refusé",
 "latence_ms": 5.33}
```

Script. Analyse du Drift du Modele

Étape 3 - Implémentez le stockage et l'analyse des données de production

Prêt à dépenser
Smart | Fast | Secure

2

PARTIE 1/2 (Révision)
1.1 Architecture
1.2 Analyse Exploratoire
1.3 Feature Engineering
1.4 Expérimentations
1.5 Optimisation

Partie 2/2
2.1 Architecture
2.2 Best Model
2.3 Use Case
2.4 Drift Analyse
2.5 Performance

Bilan

"Drift Summary" Interprétation

HTML
drift_report.html

Drift is detected for 6.867% of columns (16 out of 233).

Search

Column	Type	Reference Distribution	Current Distribution	Data Drift	Stat Test	Drift Score
standard__ext_source_1	cat			Detected	chi-square p_value	0
standard__ext_source_2	cat			Detected	chi-square p_value	0
standard__ext_source_3	cat			Detected	chi-square p_value	0
standard__install_payment_ratio_mean	cat			Detected	chi-square p_value	0
standard__pos_months_balance_mean	cat			Detected	chi-square p_value	0
standard__region_rating_client	cat			Detected	chi-square p_value	0
log__amt_income_total	cat			Not Detected	Z-test p_value	1

Dataset Drift Score

6,87%

C'est le pourcentage de variables qui présentent une dérive.

Si ce score dépasse un seuil (souvent 50%), on considère que le jeu de données entier a dérivé.

Drift Detection

NOT detected

Indique "Detected" ou "Not Detected"

Si "Detected", une ré-évaluation du modèle est nécessaire.

Analyse des Variables Numériques (ex: Montant du crédit, Âge)

Mesurer si la **distribution statistique des valeurs** a changé (ex: les clients sont-ils plus jeunes en production qu'à l'entraînement ?).

P-Value : Si la p-value < 0.05, il y a dérive. Les distributions sont statistiquement différentes.

Analyse des Variables Catégorielles (ex: Type de contrat, Niveau d'éducation)

Détecter si les **proportions des catégories** ont changé ou si de nouvelles catégories sont apparues.

Drift Score : Mesure la divergence. Un score proche de 0 indique une stabilité parfaite.

✅ Modèle en production valide

✓ Le taux de dérive (6.87%) est largement en dessous du seuil critique (50%). Aucun réentraînement immédiat n'est nécessaire.

⚠️ Volume de données limité

✓ 27 requêtes en production vs 100 en référence. La dérive détectée peut être amplifiée par ce faible échantillon.
À surveiller avec plus de données.

📋 Action recommandée

✓ Relancer l'analyse Evidently après accumulation de 200+ prédictions. Si la dérive persiste sur ext_source_*, envisager un réentraînement partiel.

Script. Profilage de performance du modèle

Étape 4 - Analysez et optimisez les performances du modèle

Prêt à dépenser
Smart | Fast | Secure

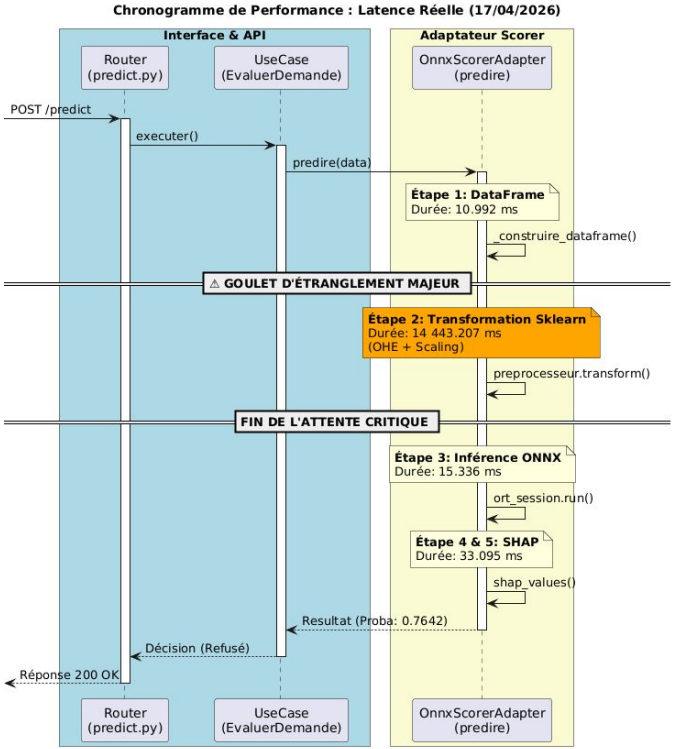
2

PARTIE 1/2 (Révision)
1.1 Architecture
1.2 Analyse Exploratoire
1.3 Feature Engineering
1.4 Expérimentations
1.5 Optimisation

Partie 2/2
2.1 Architecture
2.2 Best Model
2.3 Use Case
2.4 Drift Analyse
2.5 Performance

Bilan

API /predict Endpoint



Étape	Temps (ms)	% du total
DataFrame	11	0.08 %
Préproc	**14 443**	**99.59 %**
ONNX	15	0.10 %
SHAP	33	0.23 %
TOTAL	**14 502**	**100 %**

Script (Test Data, Inference Time)

```
============================================================
RAPPORT DE BENCHMARK — INFÉRENCE ONNX RUNTIME (DESPUÉS)
============================================================
  Moteur d'inférence......: ONNX Runtime
  Nombre de requêtes......: 500
------------------------------------------------------------
  Latence minimum.........: 0.049 ms
  Latence p50 (médiane)...: 0.063 ms      <- réponse typique
  Latence p75.............: 0.070 ms
  Latence p95.............: 0.107 ms      <- pic de charge
  Latence p99.............: 0.289 ms      <- pire cas habituel
  Latence maximum.........: 0.454 ms      <- outlier
  Latence moyenne.........: 0.071 ms
============================================================
2026-04-17 12:14:00,014 | INFO     | CSV exportado:
C:\Users\Public\IAE_DELL\pra_dell\m6_ocr\optimization\rapports\benchmark_onnx_latences.csv
2026-04-17 12:14:00,017 | INFO     | cProfile exportado:
C:\Users\Public\IAE_DELL\pra_dell\m6_ocr\optimization\rapports\profiling_onnx.txt

----------------------------RESUMEN FINAL----------------------------
   Scikit-Learn (Antes)           | p50:  1.916 ms  p95:  3.149 ms
   ONNX Runtime (Después)         | p50:  0.063 ms  p95:  0.107 ms
-----------------------------------------------------------------------
AMÉLIORATION DE LA VITESSE:  x30.51 fois plus rapide avec  ONNX
=======================================================================
```

Dashboard (Real Data, Response Time)

Latences d'inférence (ms)

Percentile	Latence (ms)
p50 (médiane)	2.12
p75	13.87
p95	64.1
p99	80.53
maximum	84.04