

CURELYTICS IA
HEALTHCARE INTELLIGENCE & ANALYTICS

Curelytics IA

Analyse des images médicales IRM cérébrales avec des méthodes semi-supervisées

Détection de tumeurs cérébrales avec peu de données annotées

Rafael CEREZO MARTIN

Juin 2026

CURELYTICS IA
HEALTHCARE INTELLIGENCE & ANALYTICS

1

1. Contexte & Problème

2. Approche Technique

3. Analyse Non Supervisée
• Chargement & Exploration du Dataset
• Prétraitement et Extraction de Embeddings
• Réduction Dimensionnelle
• Clustering Non-Supervisé

4. Méthode Semi-Supervisée
• Baseline Supervisée (Référence)
• Pseudo-Labellisation (SSL)
• Évaluation & Comparaison

5. Recommandations

6. Passage à l'échelle

7. Conclusions

Contexte et Problème



Données majoritairement non annotées

Dataset BrainScanAI :
- 100 images annotées
- 1 406 images sans labels
- Ratio : 7% annoté



Annotation coûteuse

L'annotation d'IRM nécessite des radiologues experts.
→ 0.10€ par image
→ 4M images = 400 000€



Enjeu médical critique

Faux Négatif = cancer non détecté
→ Conséquence grave
→ Priorité : maximiser le Recall

*"Notre budget actuel pour la labellisation par IA est de **300 euros** pour ce dataset"*

***Question** : 5 000€ / 4M images. faisable ?*

CURELYTICS IA
HEALTHCARE INTELLIGENCE & ANALYTICS

2

1. Contexte & Problème

2. Approche Technique

3. Analyse Non Supervisée
• Chargement & Exploration du Dataset
• Prétraitement et Extraction de Embeddings
• Réduction Dimensionnelle
• Clustering Non-Supervisé

4. Méthode Semi-Supervisée
• Baseline Supervisée (Référence)
• Pseudo-Labellisation (SSL)
• Évaluation & Comparaison

5. Recommandations

6. Passage à l'échelle

7. Conclusions

Approche Technique
Phases du Projet



CURELYTICS IA
HEALTHCARE INTELLIGENCE & ANALYTICS

2

1. Contexte & Problème

2. Approche Technique

3. Analyse Non Supervisée
• Chargement & Exploration du Dataset
• Prétraitement et Extraction de Embeddings
• Réduction Dimensionnelle
• Clustering Non-Supervisé

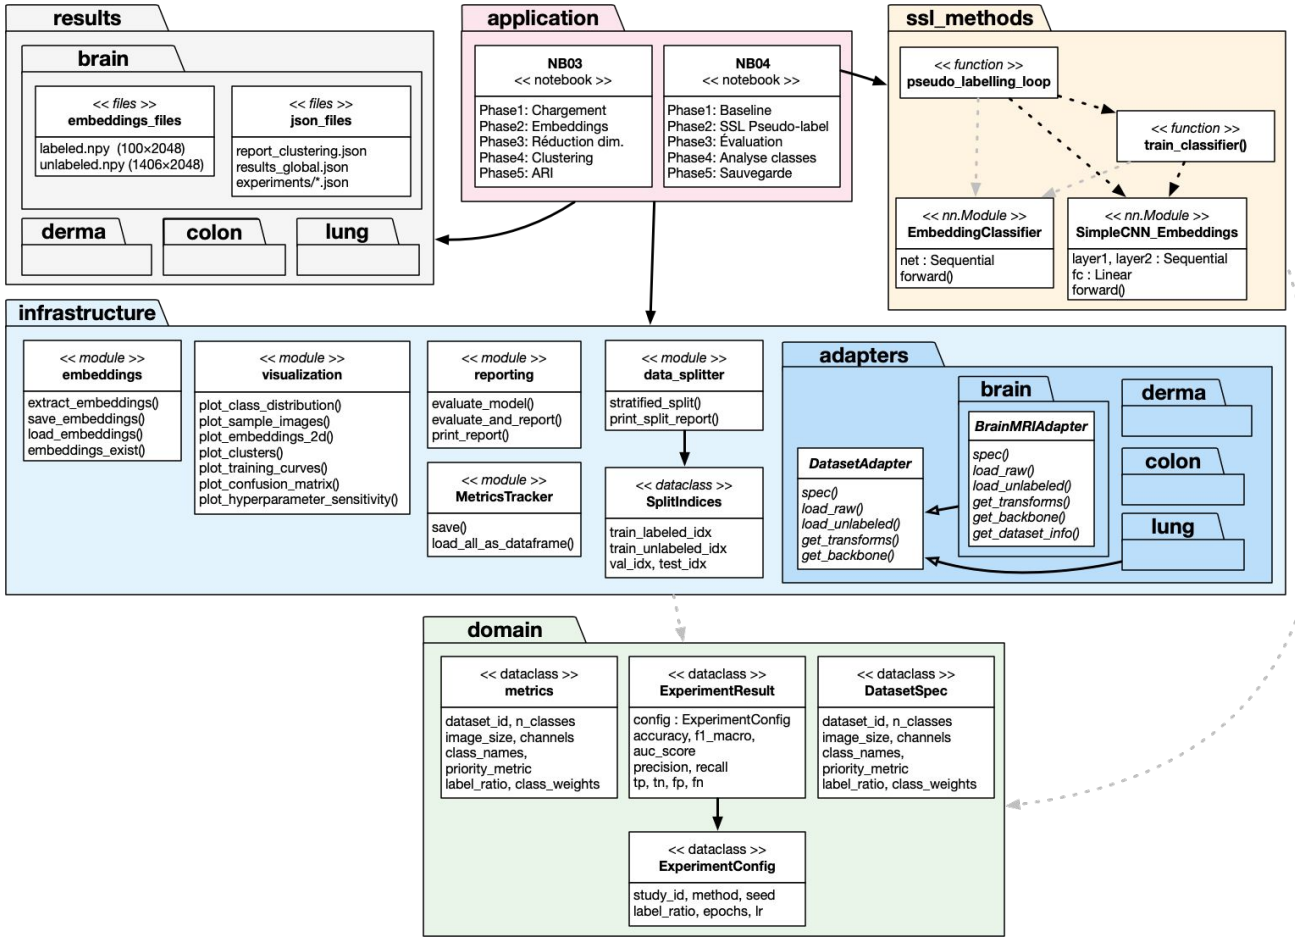
4. Méthode Semi-Supervisée
• Baseline Supervisée (Référence)
• Pseudo-Labellisation (SSL)
• Évaluation & Comparaison

5. Recommandations

6. Passage à l'échelle

7. Conclusions

Hexagonal Architecture



CURELYTICS IA
HEALTHCARE INTELLIGENCE & ANALYTICS

2

1. Contexte & Problème

2. Approche Technique

3. Analyse Non Supervisée
• Chargement & Exploration du Dataset
• Prétraitement et Extraction de Embeddings
• Réduction Dimensionnelle
• Clustering Non-Supervisé

4. Méthode Semi-Supervisée
• Baseline Supervisée (Référence)
• Pseudo-Labellisation (SSL)
• Évaluation & Comparaison

5. Recommandations

6. Passage à l'échelle

7. Conclusions

Métriques d'Évaluation. Choix et Justification

⭐ PRIORITAIRE

🎯 Cancer Recall

`TP / (TP + FN)`

Proportion de vrais cancers correctement détectés.
Un FN = cancer non détecté → conséquence grave.
Objectif : Cancer Recall = 1.00 (FN = 0).

Vue globale

✅ Accuracy

`(TP + TN) / (TP + TN + FP + FN)`

Proportion de prédictions correctes sur l'ensemble.
Trompeuse si classes déséquilibrées.
Utilisée comme indicateur secondaire.

Clustering uniquement

🔵 Score ARI

`ARI = (RI - E[RI]) / (max(RI) - E[RI])`

Adjusted Rand Index. mesure la concordance entre les clusters K-Means et la vérité terrain, corrigé pour le hasard. ARI=0 hasard | ARI=1 parfait.

En SSL. Ne s'applique. Calculé uniquement entre les clusters K-Means et les vrais labels.

Discrimination

📈 AUC-ROC

`Aire sous la courbe ROC`

Mesure la capacité du modèle à distinguer les deux classes pour différents seuils de décision.
0.5 = hasard | 1.0 = parfait.

Multi-classes

📊 F1-macro

`2 × (Precision × Recall) / (Precision + Recall)`

Moyenne harmonique Precision/Recall, non pondérée. Équilibre entre détecter les cancers et éviter les fausses alertes. Robuste aux classes déséquilibrées.

Clustering uniquement

🔷 Silhouette

`(b - a) / max(a, b)`

Qualité interne du clustering : compacité des clusters vs leur séparation. Ne nécessite pas de vrais labels.
-1 mauvais | 0 chevauchement | +1 parfait.

En SSL. mesure de la **séparabilité des embeddings** selon les classes prédites. Elle indique si le modèle produit des décisions bien délimitées dans l'espace latent.
Calcule sur les prédictions du modèle (preds) utilisées comme labels de groupes, avec embeddings_pca50 comme espace de représentation.

Contexte médical

Un Faux Négatif (cancer non détecté) est plus grave qu'un Faux Positif (fausse alerte)
→ la métrique prioritaire est le **Cancer Recall**, pas l'Accuracy.

Phase 1. Chargement & Exploration du Dataset

CURELYTICS IA
HEALTHCARE INTELLIGENCE & ANALYTICS

3

1. Contexte & Problème

2. Approche Technique

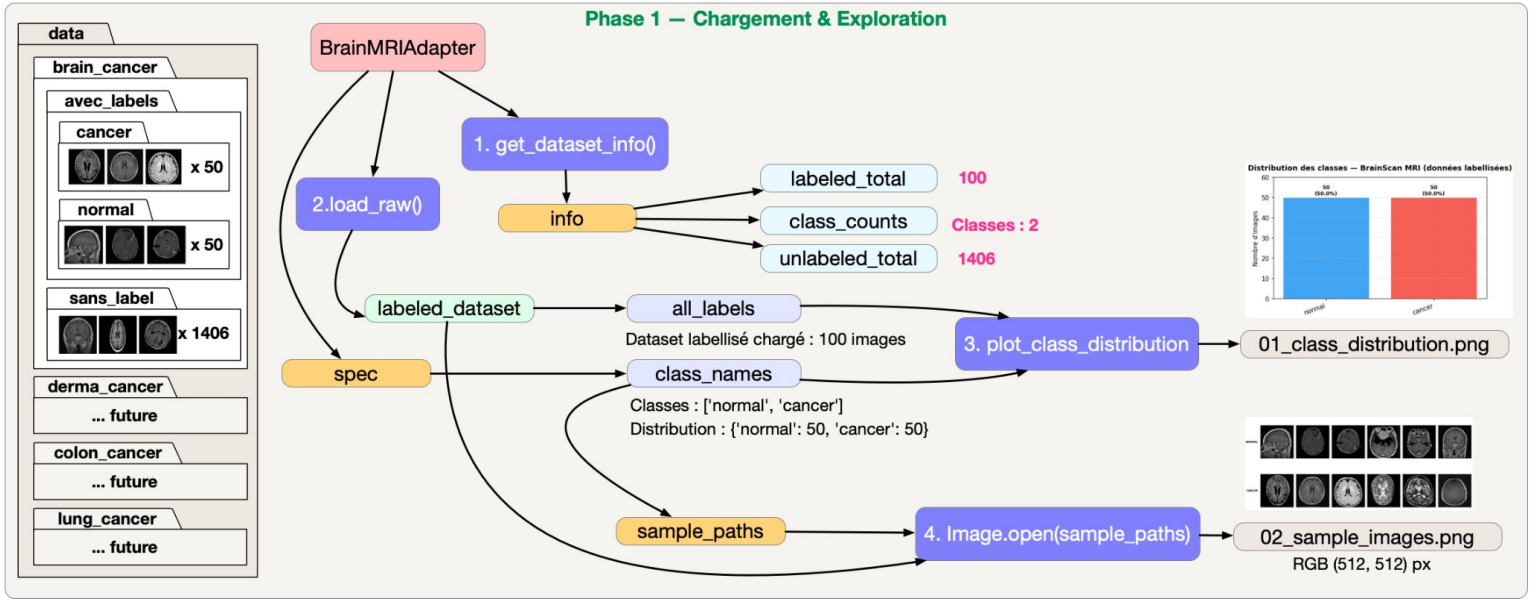
3. Analyse Non Supervisée
• Chargement & Exploration du Dataset
• Prétraitement et Extraction de Embeddings
• Réduction Dimensionnelle
• Clustering Non-Supervisé

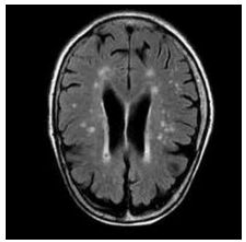
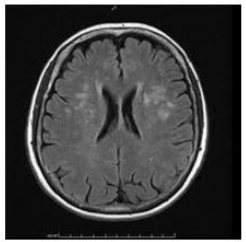
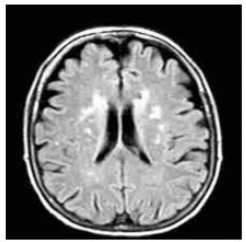
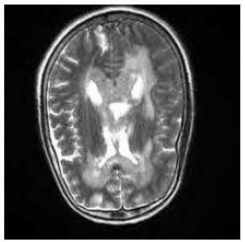
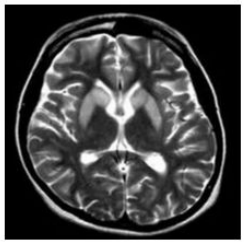
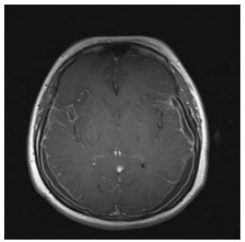
4. Méthode Semi-Supervisée
• Baseline Supervisée (Référence)
• Pseudo-Labellisation (SSL)
• Évaluation & Comparaison

5. Recommandations

6. Passage à l'échelle

7. Conclusions

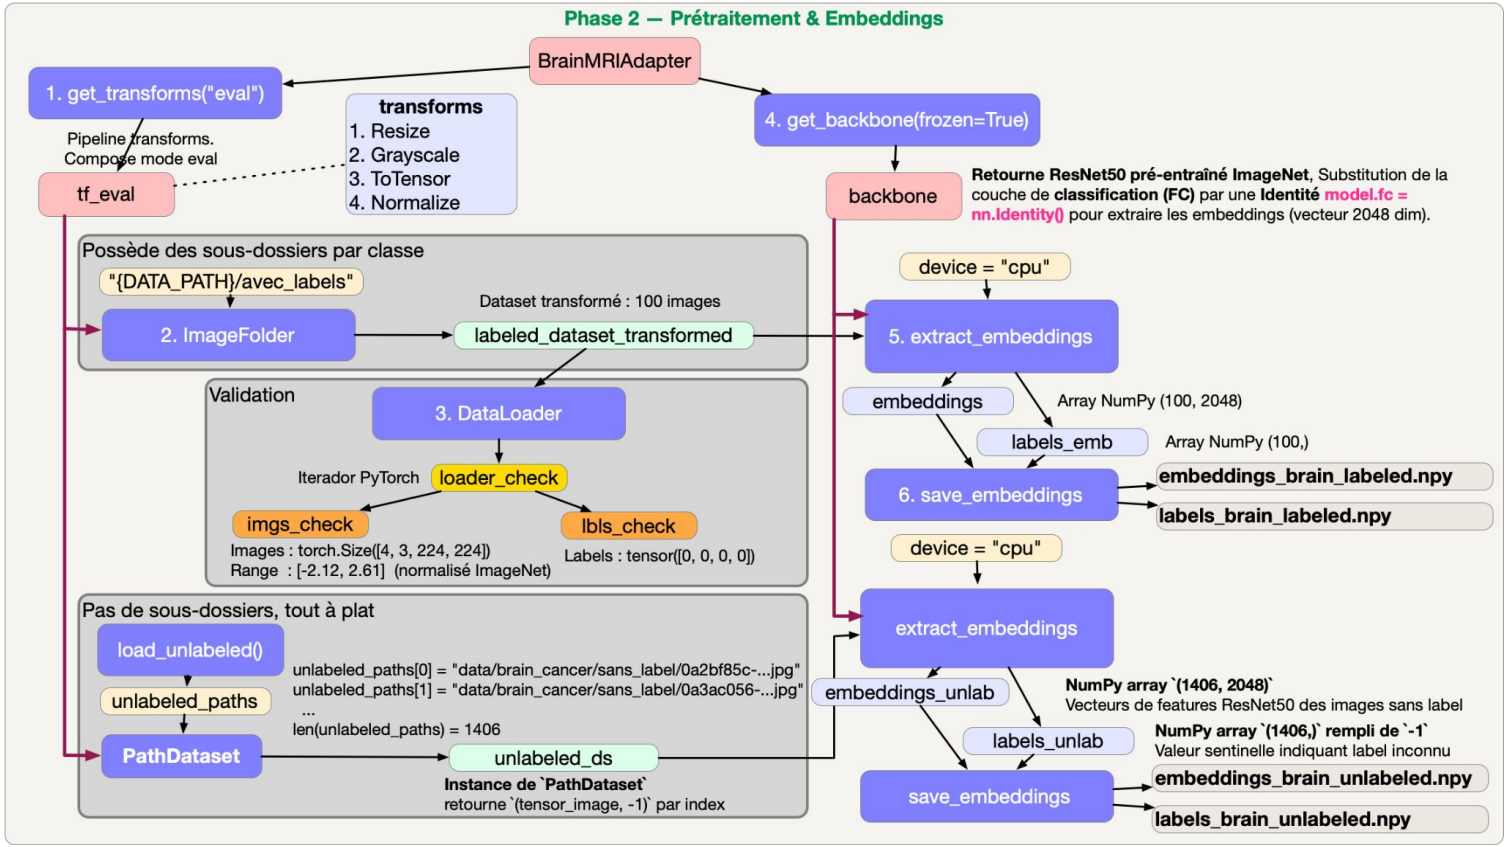


Phase 2. Prétraitement et Extraction de Embeddings

3

1. Contexte & Problème
2. Approche Technique
3. Analyse Non Supervisée
   • Chargement & Exploration du Dataset
   • Prétraitement et Extraction de Embeddings
   • Réduction Dimensionnelle
   • Clustering Non-Supervisé
4. Méthode Semi-Supervisée
   • Baseline Supervisée (Référence)
   • Pseudo-Labellisation (SSL)
   • Évaluation & Comparaison
5. Recommandations
6. Passage à l'échelle
7. Conclusions



Phase 3. Réduction Dimensionnelle

3

1. Contexte & Problème

2. Approche Technique

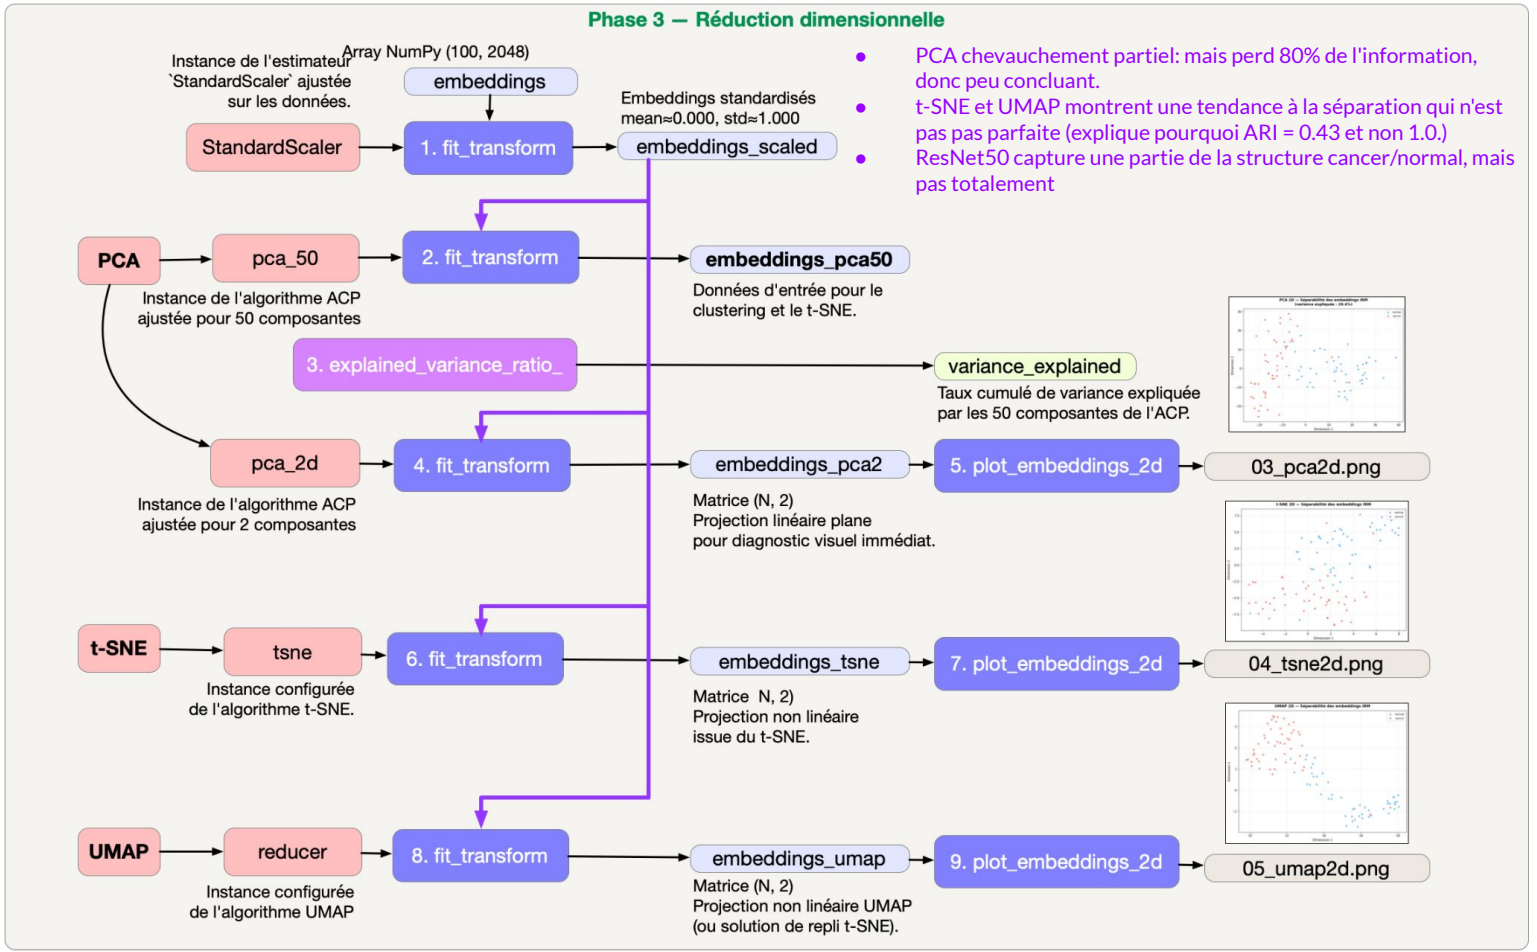
3. Analyse Non Supervisée
• Chargement & Exploration du Dataset
• Prétraitement et Extraction de Embeddings
• Réduction Dimensionnelle
• Clustering Non-Supervisé

4. Méthode Semi-Supervisée
• Baseline Supervisée (Référence)
• Pseudo-Labellisation (SSL)
• Évaluation & Comparaison

5. Recommandations

6. Passage à l'échelle

7. Conclusions



- PCA chevauchement partiel: mais perd 80% de l'information, donc peu concluant.
- t-SNE et UMAP montrent une tendance à la séparation qui n'est pas pas parfaite (explique pourquoi ARI = 0.43 et non 1.0.)
- ResNet50 capture une partie de la structure cancer/normal, mais pas totalement

Phase 4. Clustering Non-Supervisé

CURELYTICS IA
HEALTHCARE INTELLIGENCE & ANALYTICS

3

1. Contexte & Problème

2. Approche Technique

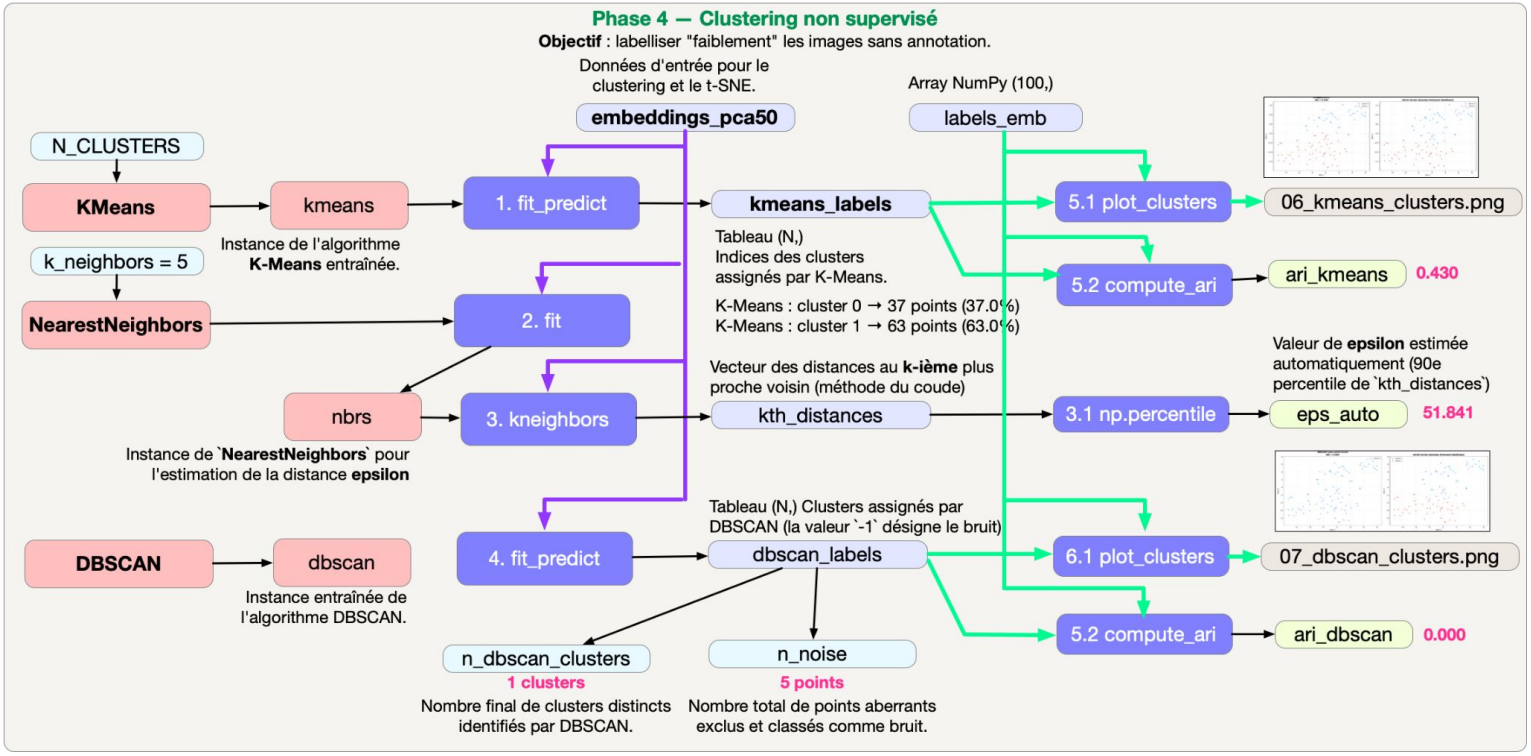
3. Analyse Non Supervisée
• Chargement & Exploration du Dataset
• Prétraitement et Extraction de Embeddings
• Réduction Dimensionnelle
• Clustering Non-Supervisé

4. Méthode Semi-Supervisée
• Baseline Supervisée (Référence)
• Pseudo-Labellisation (SSL)
• Évaluation & Comparaison

5. Recommandations

6. Passage à l'échelle

7. Conclusions



K-Means : impose K groupes de taille similaire
Trouve exactement 2 groupes en minimisant la distance entre chaque point et le centre de son groupe.

DBSCAN : découvre des groupes par densité
Rayon de voisinage très grand (eps_auto = 51.841)
Voit donc une seule grande zone dense et met tout le monde dans le même cluster

Phase 0. Setup & Chargement

CURELYTICS IA
HEALTHCARE INTELLIGENCE & ANALYTICS

4

1. Contexte & Problème

2. Approche Technique

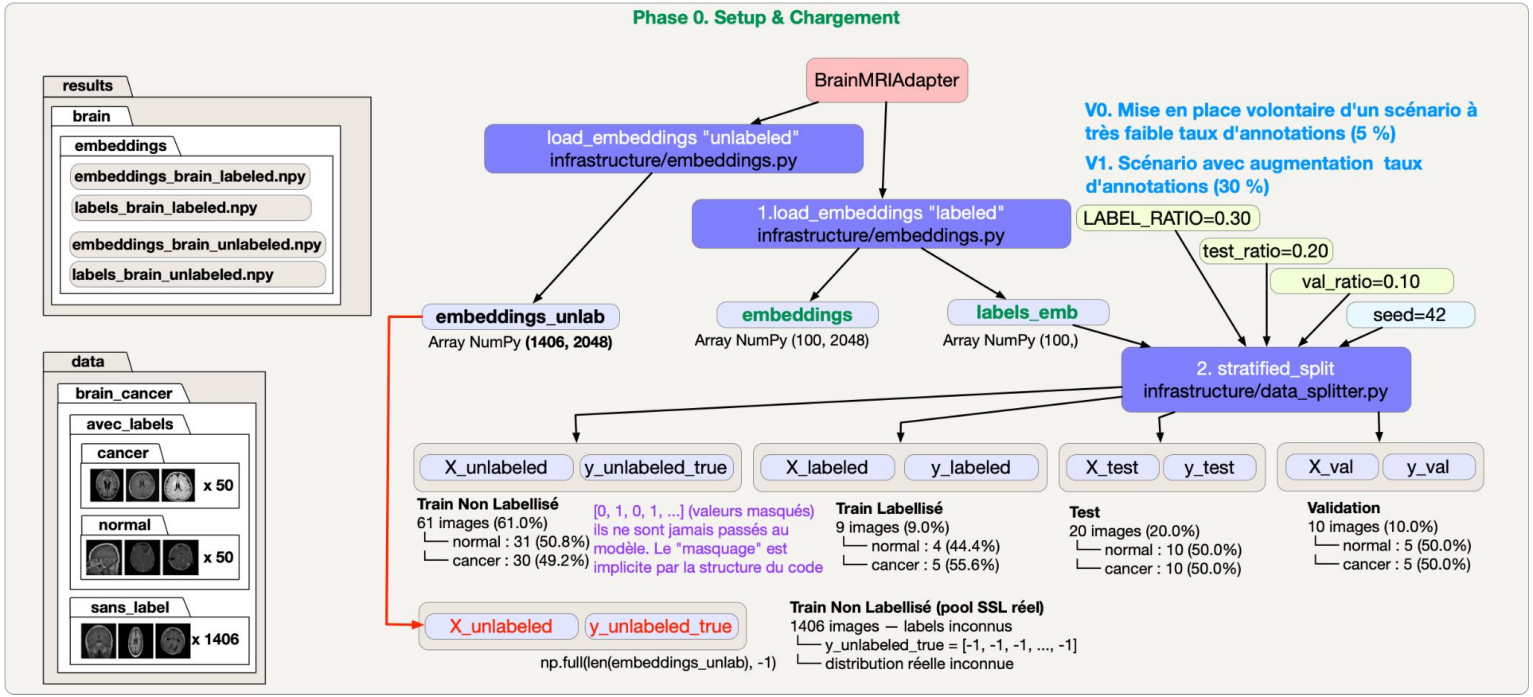
3. Analyse Non Supervisée
• Chargement & Exploration du Dataset
• Prétraitement et Extraction de Embeddings
• Réduction Dimensionnelle
• Clustering Non-Supervisé

4. Méthode Semi-Supervisée
• Baseline Supervisée (Référence)
• Pseudo-Labellisation (SSL)
• Évaluation & Comparaison

5. Recommandations

6. Passage à l'échelle

7. Conclusions



CURELYTICS IA
HEALTHCARE INTELLIGENCE & ANALYTICS

4

1. Contexte & Problème

2. Approche Technique

3. Analyse Non Supervisée
• Chargement & Exploration du Dataset
• Prétraitement et Extraction de Embeddings
• Réduction Dimensionnelle
• Clustering Non-Supervisé

4. Méthode Semi-Supervisée
• Baseline Supervisée (Référence)
• Pseudo-Labellisation (SSL)
• Évaluation & Comparaison

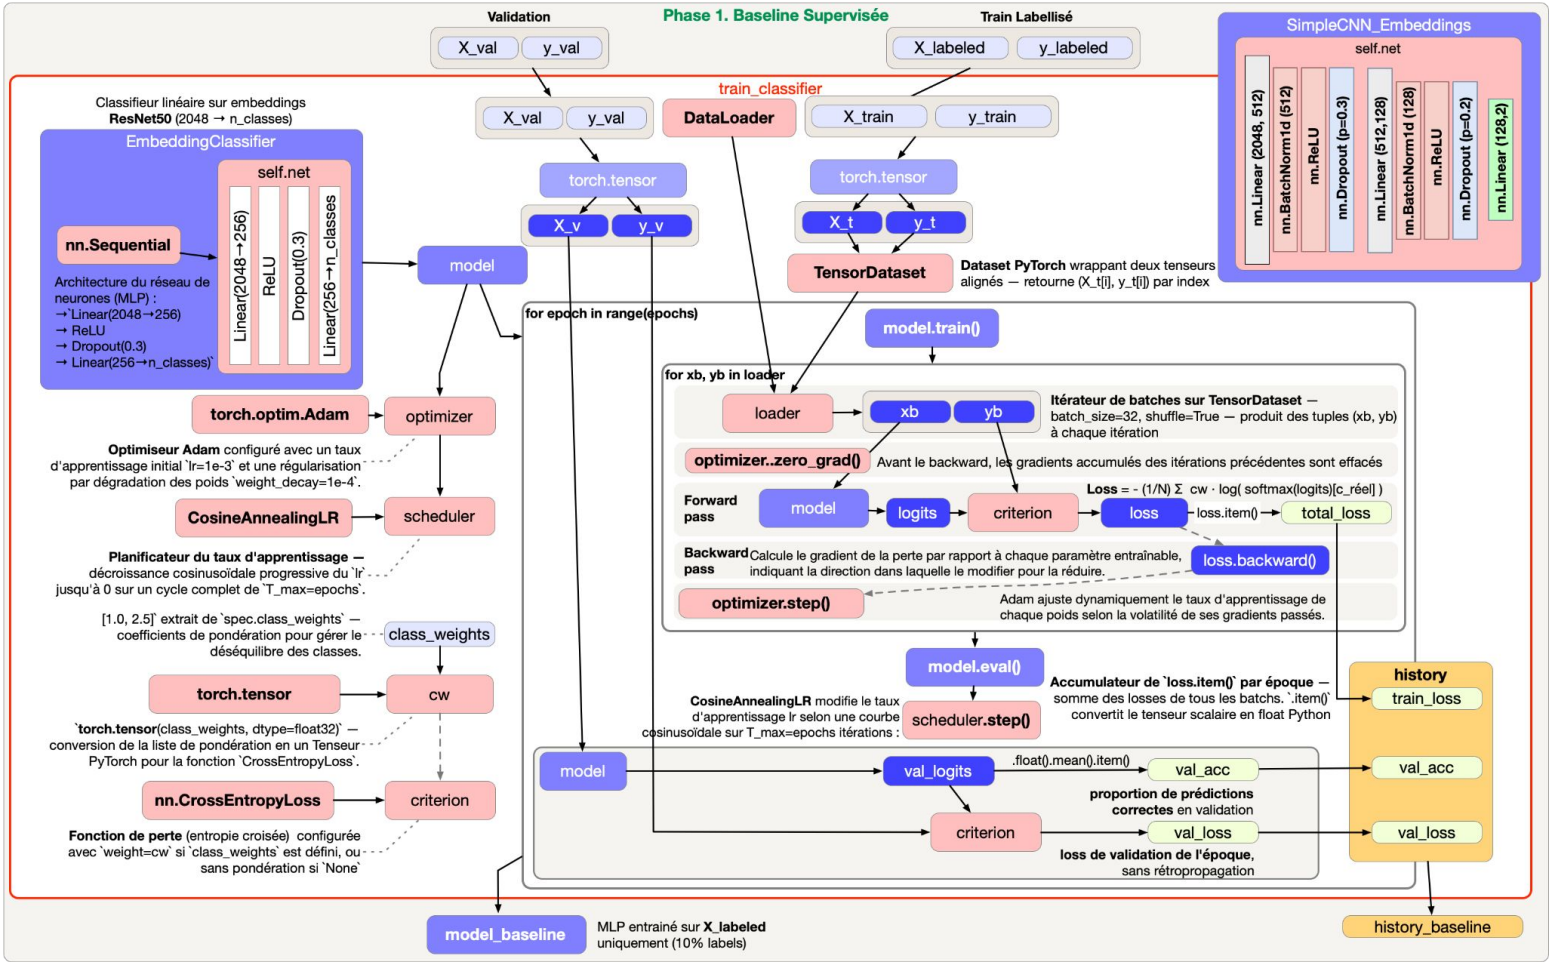
5. Recommandations

6. Passage à l'échelle

7. Conclusions

Méthode Semi-Supervisée (Pseudo-Labellisation)

Phase 1. Baseline Supervisée (Référence)



CURELYTICS IA
HEALTHCARE INTELLIGENCE & ANALYTICS

4

1. Contexte & Problème

2. Approche Technique

3. Analyse Non Supervisée
• Chargement & Exploration du Dataset
• Prétraitement et Extraction de Embeddings
• Réduction Dimensionnelle
• Clustering Non-Supervisé

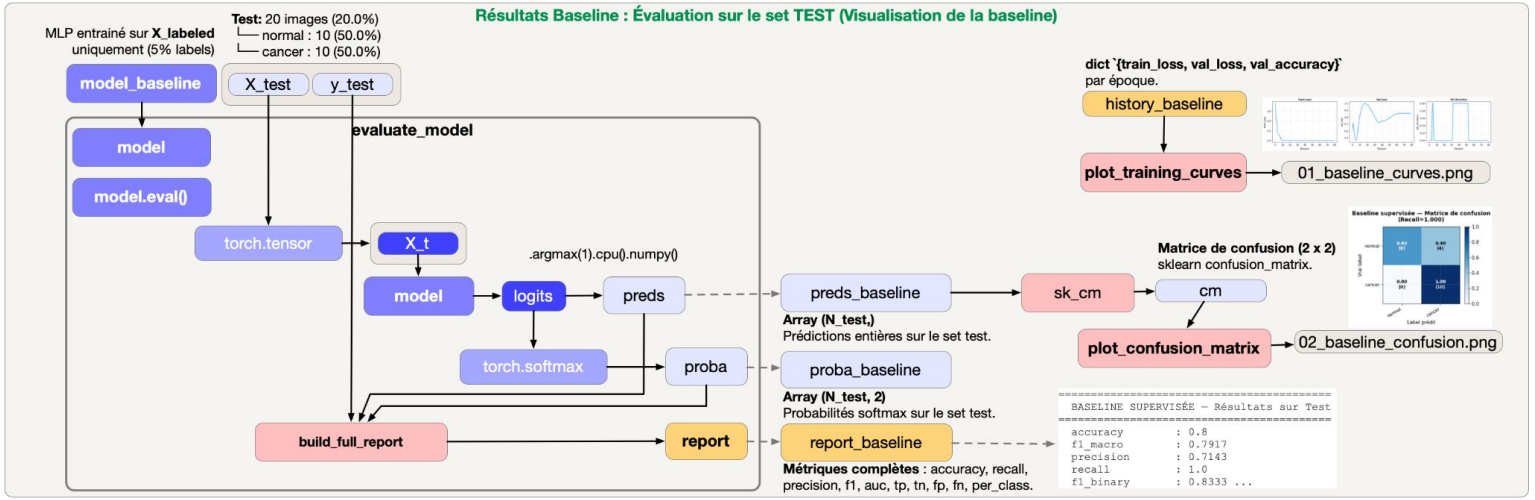
4. Méthode Semi-Supervisée
• Baseline Supervisée (Référence)
• Pseudo-Labellisation (SSL)
• Évaluation & Comparaison

5. Recommandations

6. Passage à l'échelle

7. Conclusions

Phase 1. Baseline Supervisée (Résultats)



Train Loss

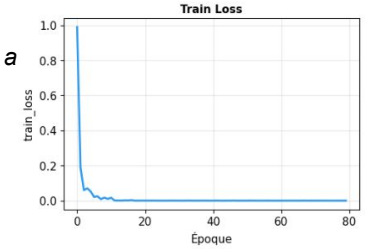
L'erreur du modèle sur les images qu'il a déjà vues pendant l'entraînement.

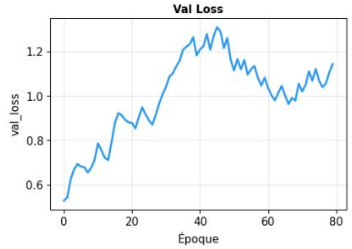
→ 0.0 mémorisation parfaite des 30 images

Val Loss

L'erreur du modèle sur des images nouvelles, jamais vues.

→ 1.2 échec total sur de nouvelles images





⚠️**Phénomène de surapprentissage (overfitting)**

Le modèle a appris les images d'entraînement par cœur mais n'a pas appris à reconnaître les tumeurs en général.

Raison pour appliquer SSL

CURELYTICS IA
HEALTHCARE INTELLIGENCE & ANALYTICS

4

1. Contexte & Problème

2. Approche Technique

3. Analyse Non Supervisée
• Chargement & Exploration du Dataset
• Prétraitement et Extraction de Embeddings
• Réduction Dimensionnelle
• Clustering Non-Supervisé

4. Méthode Semi-Supervisée
• Baseline Supervisée (Référence)
• Pseudo-Labellisation (SSL)
• Évaluation & Comparaison

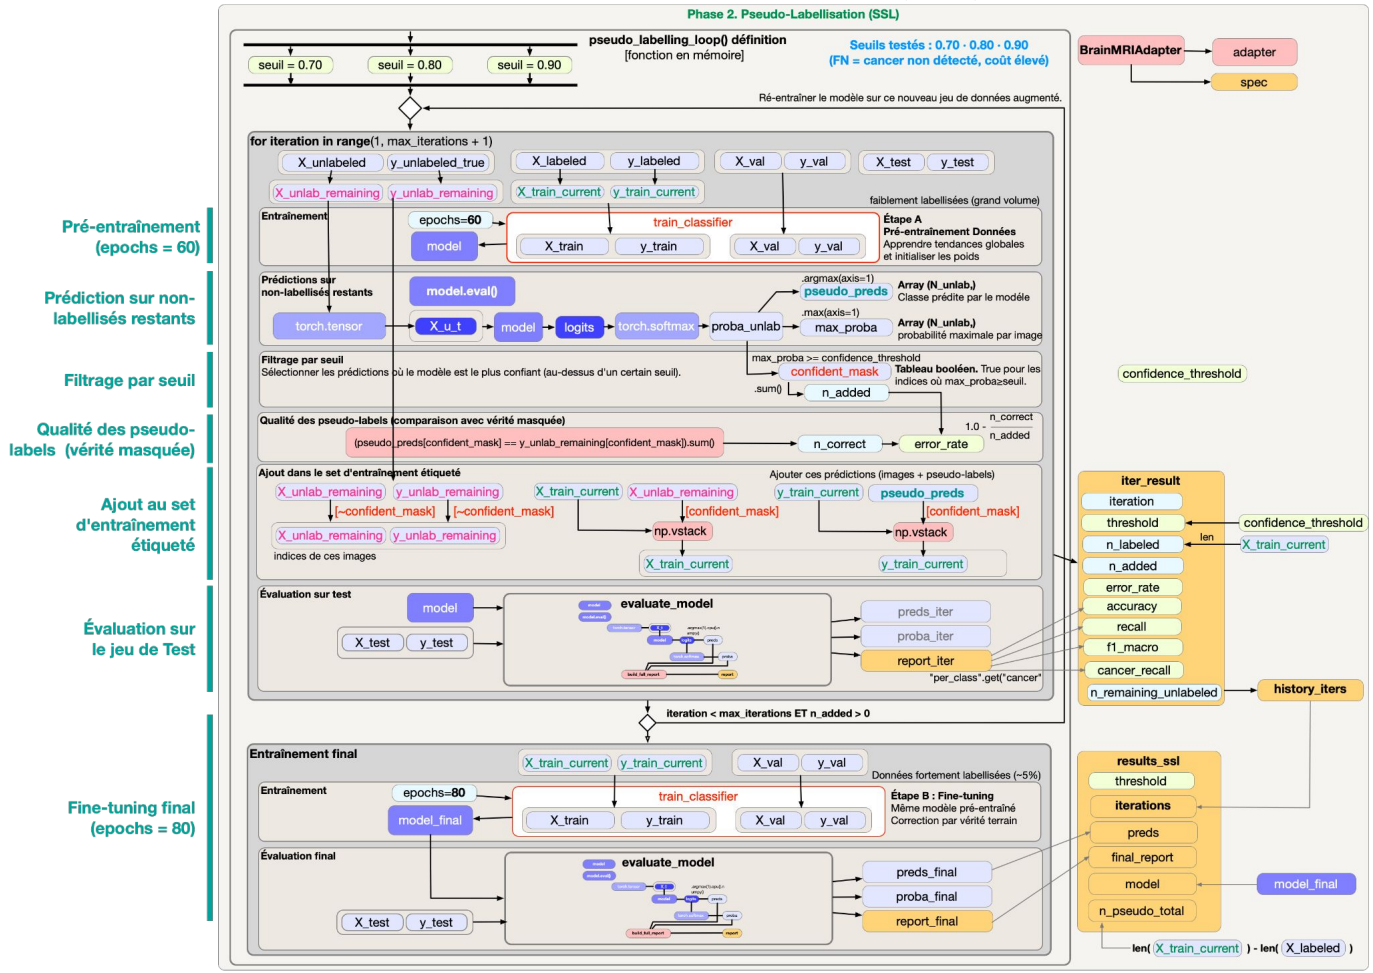
5. Recommandations

6. Passage à l'échelle

7. Conclusions

Méthode Semi-Supervisée (Pseudo-Labellisation)

Phase 2. Pseudo-Labellisation (SSL)



CURELYTICS IA
HEALTHCARE INTELLIGENCE & ANALYTICS

4

1. Contexte & Problème

2. Approche Technique

3. Analyse Non Supervisée
• Chargement & Exploration du Dataset
• Prétraitement et Extraction de Embeddings
• Réduction Dimensionnelle
• Clustering Non-Supervisé

4. Méthode Semi-Supervisée
• Baseline Supervisée (Référence)
• Pseudo-Labellisation (SSL)
• Évaluation & Comparaison

5. Recommandations

6. Passage à l'échelle

7. Conclusions

Évaluation et Comparaison

Tableau comparatif simplifié

Méthode	FN	Cancer Recall	F1-macro	Accuracy	N pseudo-labels
Clustering K-Means *	2	0.960	0.827	0.830	100 (100%)
Baseline MLP (30%)	0	1.000	0.899	0.900	0
SSL seuil=0.70	0	1.000	0.792	0.800	1402
SSL seuil=0.90	0	1.000	0.733	0.750	1406

** Après remapping cluster → classe via linear_sum_assignment*

0

Faux Négatifs

cancers non détectés

1.00

Cancer Recall

FN=0 dès 5 images

90%

Accuracy

Baseline supervisée

0.43

Score ARI

Clustering K-Means

CURELYTICS IA
HEALTHCARE INTELLIGENCE & ANALYTICS

4

1. Contexte & Problème

2. Approche Technique

3. Analyse Non Supervisée
• Chargement & Exploration du Dataset
• Prétraitement et Extraction de Embeddings
• Réduction Dimensionnelle
• Clustering Non-Supervisé

4. Méthode Semi-Supervisée
• Baseline Supervisée (Référence)
• Pseudo-Labellisation (SSL)
• Évaluation & Comparaison

5. Recommandations

6. Passage à l'échelle

7. Conclusions

Limites identifiées et Pistes d'Amélioration

⚠️ Limites identifiées

Dataset trop petit et trop parfait: 100 images parfaitement équilibrées (50/50) **ne ressemble pas à la réalité clinique**, où les cancers sont rares et les données déséquilibrées. Métriques fragiles, +/-5%

On ne peut pas mesurer les erreurs du SSL: les 1406 images sans label **(-1)** n'ont aucune étiquette connue, donc **impossible de vérifier si le modèle s'est trompé** en leur assignant un pseudo-label.

ResNet50 a appris sur des photos génériques et ses **caractéristiques visuelles** viennent d'ImageNet (chats, voitures…). Elles fonctionnent bien ici, mais **ne sont pas optimisées pour l'imagerie médicale.**

Le SSL s'emballe dès la première itération: ~1300 images pseudo-labellisées en une seule passe, il reste très peu d'images pour les itérations suivantes. La **boucle converge trop vite.**

✅ Pistes d'amélioration

1. **Utiliser un Seuil asymétrique**
P(cancer) > 0.30 ⟶ alerter radiologue
Recall > Precision en médecine

2. **Choisir intelligemment quoi annoter**. (Active Learning).
Annoter les cas ambigus en priorité
Meilleure rentabilité que l'aléatoire

3. **Transfer Learning avec un backbone médical**: **RadImageNet** est pré-entraîné sur 1.35 millions d'images médicales réelles. Il partirait d'une bien **meilleure base que ResNet50** ImageNet.

4. **Utiliser Mean Teacher**. une méthode SSL **plus robuste** : **deux modèles** travaillent ensemble, **se corrigent mutuellement progressivement** sur 3 960K images non annotées

*" .. passage à l'échelle (budget de **5 000 euros** pour **4 millions d'images** à labelliser)"*

💰 **Budget 5 000€ / 4M images**
✗ 100% humain : 4M × 0.10€ = 400 000€ hors budget
✓ 1% annoté (40K) : 40K × 0.10€ = 4 000€
✓ + Mean Teacher sur 3 960K restantes

Déterminer:
• Coût pour **Annotation %X des 4M images**
• Coût pour **GPU cloud extraction embeddings**
• Coût pour **GPU entraînement SSL**

Annotation 40K des 4M images → ~4 000€

CURELYTICS IA
HEALTHCARE INTELLIGENCE & ANALYTICS

6

1. Contexte & Problème

2. Approche Technique

3. Analyse Non Supervisée
• Chargement & Exploration du Dataset
• Prétraitement et Extraction de Embeddings
• Réduction Dimensionnelle
• Clustering Non-Supervisé

4. Méthode Semi-Supervisée
• Baseline Supervisée (Référence)
• Pseudo-Labellisation (SSL)
• Évaluation & Comparaison

5. Recommandations

6. Passage à l'échelle

7. Conclusions

Annotation 40K des 4M images → ~4 000€

Service	Type	Prix indicatif en € / image
Amazon Mechanical Turk	Tâches simples	~0,001 € à 0,05 € / image
Amazon SageMaker Ground Truth / A2I	Tâches simples à intermédiaires	~0,01 € à 0,10 € / image
Scale AI	Étiquetage général	~0,02 € / image au minimum public repéré
Label Your Data	Étiquetage général	~0,02 € / objet ou image simple
iMerit	Médical	~0,20 € à 2 €+ / image
Aya Data	Médical	~0,20 € à 2 €+ / image
Segmentation médicale complexe	Médical avancé	~2 € à 8 €+ / image

Hypothèse → 0.10€ par image (tarif Mechanical Turk / Scale AI)	40 000 × 0.10 € = **4 000 €** (**3 960 000** restantes)
Vision plus réaliste Pour des IRM médicales annotées par des radiologues. → tarif réel : 1€ à 5€ par image	40 000 × 1 € = **40 000 €** (**3 999 200** restantes)

Estimations indicatives
Basées sur les tarifs cloud publics (AWS/GCP) au moment de la rédaction. Le coût dominant est l'annotation humaine. qui dépend fortement du profil de l'annotateur :

Combien peut-on annoter avec 5 000€ ?

Scénario A. Généraliste
0.05–0.10 €/image
→ 5 000€ / 0.10€ = **50 000 images** annotables

Scénario B. Technicien médical
0.50–2 €/image
→ 5 000€ / 1€ = **5 000** images annotables

Scénario C. Radiologue expert
5€/image
→ 5 000€ / 5€ = **1 000** images annotables

CURELYTICS IA
HEALTHCARE INTELLIGENCE & ANALYTICS

6

1. Contexte & Problème

2. Approche Technique

3. Analyse Non Supervisée
• Chargement & Exploration du Dataset
• Prétraitement et Extraction de Embeddings
• Réduction Dimensionnelle
• Clustering Non-Supervisé

4. Méthode Semi-Supervisée
• Baseline Supervisée (Référence)
• Pseudo-Labellisation (SSL)
• Évaluation & Comparaison

5. Recommandations

6. Passage à l'échelle

7. Conclusions

Coûts d'infrastructure GPU

GPU cloud extraction embeddings → ~200€	
ResNet50 inférence sur 4M images : 4M images / 1000 img/sec (GPU A100) = ~4 000 secondes ≈ 1h AWS p3.2xlarge : ~3€/heure → ~3€	En réalité bien moins que **200€**

GPU entraînement SSL → ~300€	
Entraînement Pseudo-Labelisation sur images restantes: 3 960 000 images / 500 img/s = 7 920 secondes ≈ 2.2h par epoch 3 999 200 images / 500 img/s = 7 998.4 secondes ≈ 2.2217h par epoch 10 epochs × 2.2h = 22h Avec overhead (chargement données, validation, checkpoints) × 2 → ~44h ≈ 48h GPU ← estimation raisonnable AWS p3.2xlarge : ~3€/h × 48h = ~150€ **Option: Mean Teacher** (2 modèles: étudiant + enseignant) = 2 forward passes par image par batch Temps révisé : 48h × 1.5 = ~72h Coût révisé : 3€/h × 72h = ~216€	**150–300€** Selon le nombre d'epochs

CURELYTICS IA
HEALTHCARE INTELLIGENCE & ANALYTICS

6

1. Contexte & Problème

2. Approche Technique

3. Analyse Non Supervisée
• Chargement & Exploration du Dataset
• Prétraitement et Extraction de Embeddings
• Réduction Dimensionnelle
• Clustering Non-Supervisé

4. Méthode Semi-Supervisée
• Baseline Supervisée (Référence)
• Pseudo-Labellisation (SSL)
• Évaluation & Comparaison

5. Recommandations

6. Passage à l'échelle

7. Conclusions

Budget final estimé

Annotation **Généraliste** **40000** images × 0.10€ (Active Learning)	4 000€
GPU cloud extraction embeddings 4M	200€
GPU cloud entraînement SSL (**3 960 000** restantes)	300€
TOTAL	**4 500€**
Budget disponible	5 000€
Marge	500€

CURELYTICS IA
HEALTHCARE INTELLIGENCE & ANALYTICS

7

1. Contexte & Problème

2. Approche Technique

3. Analyse Non Supervisée
• Chargement & Exploration du Dataset
• Prétraitement et Extraction de Embeddings
• Réduction Dimensionnelle
• Clustering Non-Supervisé

4. Méthode Semi-Supervisée
• Baseline Supervisée (Référence)
• Pseudo-Labellisation (SSL)
• Évaluation & Comparaison

5. Recommandations

6. Passage à l'échelle

7. Conclusions

Réponse à la question : '5 000€ / 4M images. faisable ?'

Faisable avec la bonne stratégie !

1.00	FN = 0	4 500€
Cancer Recall baseline	Cancers non détectés	Budget estimé / 4M images

Avec :

- Transfer learning utilisant le modèle pré-entraîne (**ResNet50**) , et
- 5 images labellisés → La métrique prioritaire Cancer Recall = 1.00 est atteinte dès la baseline

On dispose d'un **Framework SSL** (multi-dataset) prêt à passer à l'échelle

Sur **données réelles** (déséquilibrées, ambiguës), le **SSL** apporte un **gain mesurable**

On a stimé un budget de 4 500€ pour annoter 4M images en combinant:

- **Active Learning** (Un modèle détermine les images sur lesquelles il a des doutes, afin de demander à un annotateur humain de les étiqueter en priorité.)
- **SSL**. en confiant au modèle le soin de labelliser de manière autonome les **images non annotées** par des mécanismes de **consistance** et de **pseudo-labellisation**. À partir d'un **contexte de fortes contraintes de ressources**, nous avons réussi à développer une **méthode d'apprentissage à la fois robuste et performante**.



Q et R

Rafael CEREZO MARTIN

Juin 2026

CURELYTICS IA
HEALTHCARE INTELLIGENCE & ANALYTICS

2

1. Contexte & Problème

2. Approche Technique

3. Analyse Non Supervisée
• Chargement & Exploration du Dataset
• Prétraitement et Extraction de Embeddings
• Réduction Dimensionnelle
• Clustering Non-Supervisé

4. Méthode Semi-Supervisée
• Baseline Supervisée (Référence)
• Pseudo-Labellisation (SSL)
• Évaluation & Comparaison

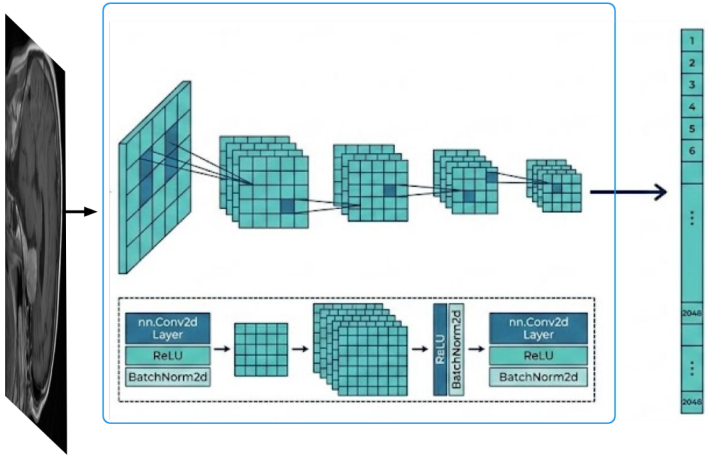
5. Recommandations

6. Passage à l'échelle

7. Conclusions

Embeddings et Classificateurs

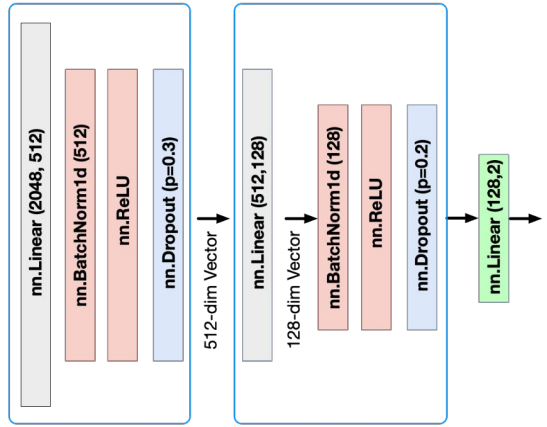
Notebook 1



L'Extracteur de Caractéristiques
ResNet50 compresse l'image médicale via ses convolutions en un embedding (vecteur de 2048D) condensant ses caractéristiques.

Vector d'Embedding Unidimensional
(Dimension 2048)

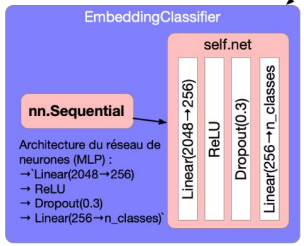
Notebook 2

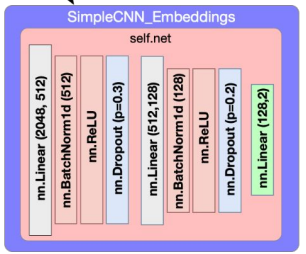


Layer 1 Caché dense 1
Stabilisation & Pojection

Layer 2 Caché dense
Compression Métrique

Le Classificateur (Head)
Un petit réseau linéaire qui prend cet embedding de 2048 et le mappe vers les classes finales.





Step 1

Extraction des Embeddings

CURELYTICS IA
HEALTHCARE INTELLIGENCE & ANALYTICS

2

1. Contexte & Problème

2. Approche Technique

3. Analyse Non Supervisée
• Chargement & Exploration du Dataset
• Prétraitement et Extraction de Embeddings
• Réduction Dimensionnelle
• Clustering Non-Supervisé

4. Méthode Semi-Supervisée
• Baseline Supervisée (Référence)
• Pseudo-Labellisation (SSL)
• Évaluation & Comparaison

5. Recommandations

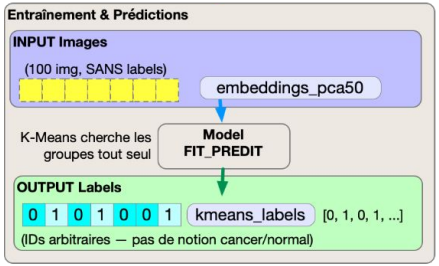
6. Passage à l'échelle

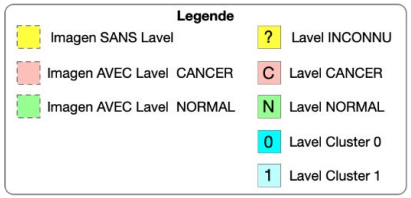
7. Conclusions

Approche Technique
Entraînement et Prédictions

Step 2

Clustering K-Means

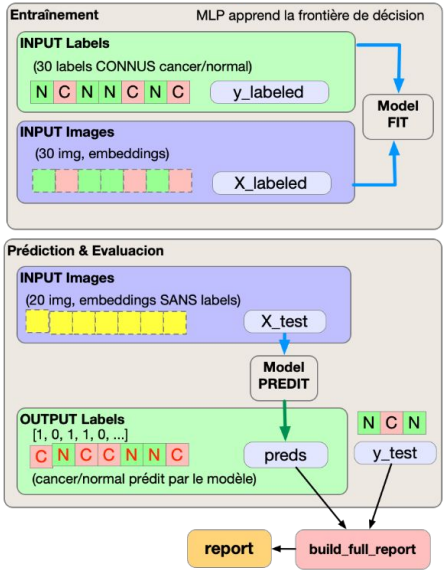




Step 3

epochs = 60

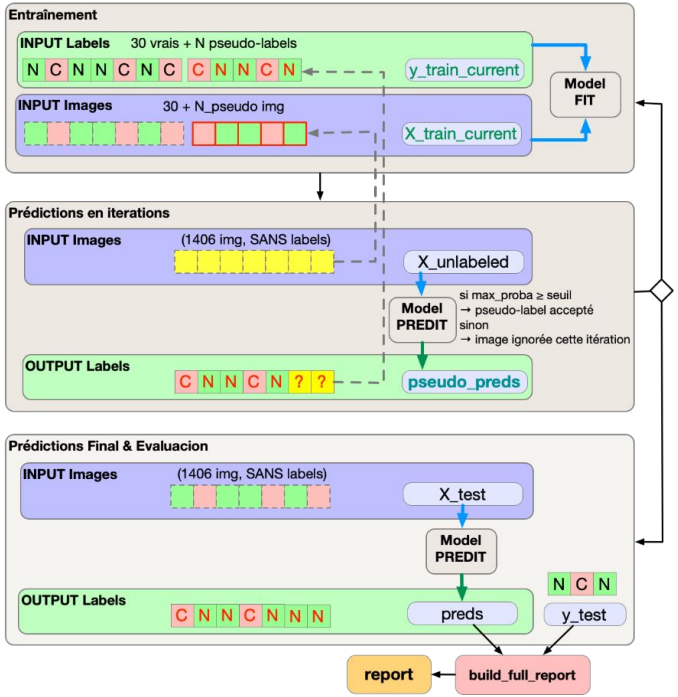
Baseline Supervisée



Step 4

max_iterations = 5
epochs par iteración = 60
epochs train final = 80

SSL Pseudo-labellisation



Score ARI *: mesure la concordance entre les clusters et la vérité terrain*

CURELYTICS IA
HEALTHCARE INTELLIGENCE & ANALYTICS

4

1. Contexte & Problème

2. Approche Technique

3. Analyse Non Supervisée
• Chargement & Exploration du Dataset
• Prétraitement et Extraction de Embeddings
• Réduction Dimensionnelle
• Clustering Non-Supervisé

4. Méthode Semi-Supervisée
• Baseline Supervisée (Référence)
• Pseudo-Labellisation (SSL)
• Évaluation & Comparaison

5. Recommandations

6. Passage à l'échelle

7. Conclusions

Évaluation et Comparaison

	Clustering non supervisé	Baseline supervisée (5%)	SSL Pseudo-label (5%)	Baseline supervisée (5%)	SSL Pseudo-label (5%)	Baseline supervisée (10%)	SSL Pseudo-label (10%)	Baseline supervisée (10%)	SSL Pseudo-label (10%)
Model	K-Means	MLP	MLP	S.CNN	S.CNN	MLP	MLP	S.CNN	S.CNN
FN	2 *	0	0	0	0	0	0	_	_
Accuracy	0.830 *	0.900	0.800	0.900	0.750	0.700	0.900	0.700	0.850
Cancer Recall	0.960 *	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000
F1-macro	0.827 *	0.899	0.792	0.899	0.733	0.6703	0.899	0.6703	0.847
Score ARI	0.430	N.A	N.A	N.A	N.A	N.A	N.A	N.A	N.A
Silhouette	0.1225	0.1029	0.0807	0.1029	0.0847	0.0779	0.1029	0.0779	0.0868
N pseudo-labels	100 (100%)	0	1402	0	1406	0	1404	0	1406
Training time (s)	0.103s	3.9s	197.8s	4.733s	157.8s	4.127s	218.5	4.85s	216.0s
[[TN FP] [FN TP]]	[[35 15] [2 48]]	[[8 2] [0 10]]	[[6 4] [0 10]]	[[8 2] [0 10]]	[[5 5] [0 10]]	[[4 6] [0 10]]	[[8 2] [0 10]]	[[4 6] [0 10]]	[[7 3] [0 10]]

Train Labellisé : **5 images** (5.0%)
└ normal : 2 (40.0%)
└ cancer : 3 (60.0%)

Train Labellisé : **9 images** (9.0%)
└ normal : 4 (44.4%)
└ cancer : 5 (55.6%)

* Après Remapping : trouver la meilleure correspondance cluster → classe

1. Contexte & Problème

2. Approche Technique

3. Analyse Non Supervisée
• Chargement & Exploration du Dataset
• Prétraitement et Extraction de Embeddings
• Réduction Dimensionnelle
• Clustering Non-Supervisé

4. Méthode Semi-Supervisée
• Baseline Supervisée (Référence)
• Pseudo-Labellisation (SSL)
• Évaluation & Comparaison

5. Recommandations

6. Passage à l'échelle

7. Conclusions

Interprétation des Résultats

💬 Transfer Learning trop efficace pour ce dataset

ResNet50 ImageNet produit des embeddings si discriminants que 5 images suffisent pour obtenir Cancer Recall = 1.00, FN = 0.
La frontière normal/cancer est triviale dans cet espace latent.
Le modèle n'a rien de difficile à apprendre.

💬 SSL : pas de gain mesurable. Résultat honnête et valide

La baseline est déjà au plafond (FN=0). Le SSL ajoute ~1 400 pseudo-labels mais introduit du bruit sur la classe 'normal'
(Les FP augmentent sans améliorer le Cancer Recall).
Ce n'est pas un échec : *le SSL est conçu pour améliorer un modèle FAIBLE*. Ici le modèle de départ est déjà fort.

💬 Sur données réelles, le SSL apporterait un gain mesurable

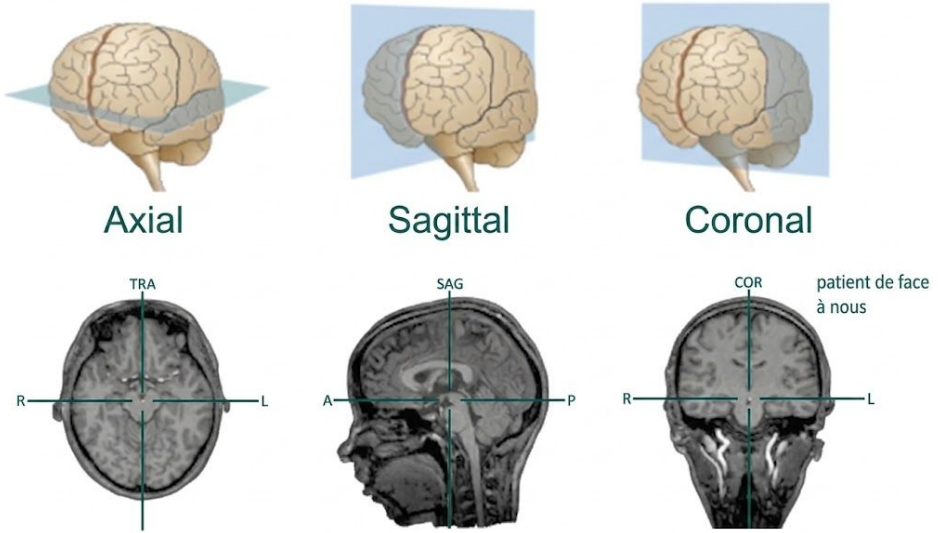
4M images réelles = classes déséquilibrées + cas ambigus + variabilité inter-patient → gains mesurables attendus.

Limites et Pistes d'Amélioration

4

1. Contexte & Problème
2. Approche Technique
3. Analyse Non Supervisée
   • Chargement & Exploration du Dataset
   • Prétraitement et Extraction de Embeddings
   • Réduction Dimensionnelle
   • Clustering Non-Supervisé
4. Méthode Semi-Supervisée
   • Baseline Supervisée (Référence)
   • Pseudo-Labellisation (SSL)
   • Évaluation & Comparaison
5. Recommandations
6. Passage à l'échelle
7. Conclusions

Notre dataset (PNG sans métadonnées DICOM) ne distingue pas les plans d'acquisition.



→ ResNet50 doit apprendre à **reconnaître un cancer quel que soit l'angle de coupe**
→ Cela augmente la variabilité intra-classe
→ Un modèle spécialisé par plan serait plus précis mais nécessiterait des données taguées

En pratique dans les hôpitaux, les DICOM contiennent le plan d'acquisition (ImageOrientationPatient)
→l'amélioration est faisable sur données réelles.

CURELYTICS IA
HEALTHCARE INTELLIGENCE & ANALYTICS

6

1. Contexte & Problème

2. Approche Technique

3. Analyse Non Supervisée
• Chargement & Exploration du Dataset
• Prétraitement et Extraction de Embeddings
• Réduction Dimensionnelle
• Clustering Non-Supervisé

4. Méthode Semi-Supervisée
• Baseline Supervisée (Référence)
• Pseudo-Labellisation (SSL)
• Évaluation & Comparaison

5. Recommandations

6. Passage à l'échelle

7. Conclusions

Budget final estimé

Annotation **Généraliste** **40000** images × 0.10€ (Active Learning)	4 000€
GPU cloud extraction embeddings 4M	200€
GPU cloud entraînement SSL (**3 960 000** restantes)	300€
TOTAL	**4 500€**
Budget disponible	5 000€
Marge	500€

Annotation **Généraliste** **40000** images × 0.10€ (Active Learning)	4 000€
Mean Teacher SSL (extraction + entraînement)	400€
TOTAL	**4 400€**
Budget disponible	5 000€
Marge	600€

Annotation **Radiologue expert** **800** images × 5€ (Active Learning)	4 000€
GPU cloud extraction embeddings 4M	200€
GPU cloud entraînement SSL (**3 999 200** restantes)	300€
TOTAL	**4 500€**
Budget disponible	5 000€
Marge	500€

⚠️ Scénario radiologue expert (800 images = 0.02% de 4M) : volume insuffisant pour amorcer le SSL de façon fiable. **Recommandation minimale** : 5 000 images (0.1%) avant SSL. → Envisager un financement complémentaire ou un partenariat hospitalier pour atteindre ce seuil critique.

CURELYTICS IA
HEALTHCARE INTELLIGENCE & ANALYTICS

1

1. Contexte & Problème

2. Approche Technique

3. Analyse Non Supervisée
• Chargement & Exploration du Dataset
• Prétraitement et Extraction de Embeddings
• Réduction Dimensionnelle
• Clustering Non-Supervisé

4. Méthode Semi-Supervisée
• Baseline Supervisée (Référence)
• Pseudo-Labellisation (SSL)
• Évaluation & Comparaison

5. Recommandations

6. Passage à l'échelle

7. Conclusions

Conclusion

Objectifs Mesurables

Préparer et Transformer les données

✅ Transformations adaptées : resize 224×224, normalisation ImageNet

✅ Embeddings ResNet50 (100×2048) exploitables pour le clustering et le SSL

✅ Code commenté et lisible dans les deux notebooks

✅ Séparation stricte données faibles ≠ données fortes respectée

Identifier un Modèle Adapté

✅ Plusieurs méthodes de clustering testées : K-Means et DBSCAN

✅ Score ARI calculé pour valider la qualité du clustering non-supervisé

✅ Métriques pertinentes : Cancer Recall ⭐, F1-macro, AUC, Silhouette

✅ Hyperparamètres ajustés : seuils 0.70–0.99, epochs 60/80

Justifier et Recommander

✅ Support de présentation avec recommandations passage à l'échelle

✅ Réponse chiffrée : 5 000€ / 4M images. 3 scénarios détaillés

✅ Choix techniques liés aux contraintes métier (budget, volume, délai)

✅ Cohérence vérifiée entre notebooks et support de présentation